

Teoría de Integración

Basado en las clases impartidas por Santiago Saglietti en el primer semestre del 2026

Contents

1	1	3
1.1	Espacios de medida	3
1.1.1	Ejemplos de medidas	4
1.1.2	Propiedades de una medida	4
1.1.3	Ejemplos de espacios de probabilidad	5
1.1.4	Propiedades adicionales de una probabilidad	5
1.2	Análisis vs Probabilidad	5
1.3	Funciones medibles y variables aleatorias	6
1.3.1	En Análisis	6
1.3.2	En Probabilidad	6
1.4	Distribución de una variable aleatoria	7
1.4.1	Diferencia de enfoques	8
1.5	Función de distribución	8
1.6	Tipos de variables aleatorias	9
1.7	Integración y Esperanza	10
1.8	Teorema de existencia y unicidad de variable aleatoria con distribución dada	12
1.8.1	Forma canónica:	13
1.8.2	Forma constructiva: inversa generalizada	14
1.9	Medidas Producto	17
1.10	Independencia	18
1.10.1	Aplicación	22
1.11	Ley 0-1 de Kolmogorov	24
1.12	Lemas de Borel-Cantelli	25
1.13	Existencia de sucesiones independientes	27
2	Procesos Estocásticos (Notas de Anton Bovier)	28
2.1	Perspectiva Trayectorial	28
2.1.1	Construcción de medidas en S^I	31
3	Leyes de los grandes números	36
3.1	Convergencia en distribución.	39
3.1.1	Aplicaciones	45
4	Esperanza Condicional	49
4.0.1	Esperanza Condicional dada una variable aleatoria	53
4.1	Probabilidad Condicional Regular	56

5	Martingalas	57
5.0.1	Contraejemplo para la convergencia en L^1	64
5.0.2	Contraejemplo $(X_n \not\xrightarrow{L^1} X_\infty)$	65
5.1	Convergencia de Martingalas en L^p ($p > 1$)	66
5.1.1	Martingalas reversas	74
6	Cadenas de Markov	75
6.0.1	Propiedad Fuerte de Markov	81
6.1	Estructura de Clases	82
6.1.1	Aperiodicidad	84

Chapter 1

1

Clase 1

4 de Marzo

1.1 Espacios de medida

- Un espacio E será cualquier conjunto no vacío.
- Cualquier colección de subconjuntos de un espacio E será denominada una *clase* (de subconjuntos de E).

Definición 1.1 (σ -álgebra). Una clase Σ de subconjuntos de un espacio E se dirá una σ -álgebra si cumple que:

- i) $\emptyset \in \Sigma$ (en particular, Σ es no vacía).
- ii) $A \in \Sigma \Rightarrow A^c \in \Sigma$.
- iii) $(A_n)_{n \in \mathbb{N}} \subset \Sigma \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \Sigma$.

Definición 1.2 (Espacio medible). Un *espacio medible* es cualquier par (E, Σ) donde E es un espacio y Σ es una σ -álgebra (de subconjuntos de E).

Definición 1.3 (Medida). Dado un espacio medible (E, Σ) , una aplicación $\mu : \Sigma \rightarrow [0, \infty]$ se dirá una *medida (no negativa)* sobre (E, Σ) si cumple que:

- i) $\mu(\emptyset) = 0$,
- ii) si $(A_n)_{n \in \mathbb{N}} \subset \Sigma$ son conjuntos disjuntos, entonces

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

Si μ cumple (ii) decimos que μ es σ -aditiva.

Definición 1.4 (Espacio de medida). Un *espacio de medida* será cualquier terna (E, Σ, μ) donde (E, Σ) es un espacio medible y μ es una medida sobre (E, Σ) .

1.1.1 Ejemplos de medidas

Ejemplo (Medida de Lebesgue).

- $E = \mathbb{R}^d$
- $\Sigma = \{\text{conjuntos medibles Lebesgue}\}$
- $\mu = \text{medida de Lebesgue en } \mathbb{R}^d$

Ejemplo (Medida de contar).

- E un espacio arbitrario
- $\Sigma = 2^E$ (partes de E)
- $\mu = \text{medida de contar } (\mu(A) = \#A)$

Ejemplo (Medidas de Hausdorff).

- $E = \mathbb{R}^d$
- $\Sigma = \{\text{Borelianos de } \mathbb{R}^d\}$
- Fijado $s \in [0, \infty)$, $\mu = \mathcal{H}^s = \text{medida de Hausdorff } s\text{-dimensional}$

1.1.2 Propiedades de una medida

Propiedad 1.5. Si μ es una medida sobre (E, Σ) , entonces:

- i) **Monotonía:** $A \subseteq B \Rightarrow \mu(A) \leq \mu(B)$.
- ii) **Subaditividad:** $A \subseteq \bigcup_{n=1}^{\infty} A_n \Rightarrow \mu(A) \leq \sum_{n=1}^{\infty} \mu(A_n)$.
- iii) **Continuidad inferior:** $A_n \nearrow A \Rightarrow \mu(A_n) \nearrow \mu(A)$.
- iv) **Continuidad superior:** $A_n \searrow A$ y $\mu(A_n) < \infty$ para algún n (o $\mu(A_1) < \infty$) $\Rightarrow \mu(A_n) \searrow \mu(A)$. (Puede ser falso sin la condición de finitud.)

Definición 1.6. Un espacio de medida (E, Σ, μ) se llamará un *espacio de probabilidad* si $\mu(E) = 1$. En este caso, μ recibe el nombre de *medida de probabilidad* (o probabilidad a secas).

Notación.

- El espacio E se denota Ω , y lo llamamos *espacio muestral*.
- Los elementos de Ω se denotan ω (y a veces se llaman *realizaciones*).

- La σ -álgebra Σ se suele denotar por $\mathcal{F}$.
- Los elementos de la σ -álgebra $\mathcal{F}$ se llaman *eventos*.
- La medida μ se denota $\mathbb{P}$ o P .

1.1.3 Ejemplos de espacios de probabilidad

Ejemplo (Espacios equiprobables). Se llaman así porque todas las realizaciones tienen la misma probabilidad.

- Ω un conjunto finito.
- $\mathcal{F} = 2^\Omega$ (partes de Ω).
- $\mathbb{P}(A) = \frac{\#A}{\#\Omega}$.

Ejemplo (Espacios discretos).

- Ω un conjunto finito o numerable.
- $\mathcal{F} = 2^\Omega$.
- $\mathbb{P}(A) = \sum_{\omega \in A} p(\omega)$, donde $(p(\omega))_{\omega \in \Omega}$ es algún vector fijo que satisface $p(\omega) \geq 0 \forall \omega \in \Omega$ y $\sum_{\omega \in \Omega} p(\omega) = 1$.

Ejemplo (Un ejemplo no discreto). $\Omega = [0, 1]$, $\mathcal{F} = \{\text{Borelianos de } [0, 1]\}$, $\mathbb{P}(A) = |A|$ (medida de Lebesgue).

1.1.4 Propiedades adicionales de una probabilidad

Propiedad 1.7. Si $\mathbb{P}$ es una probabilidad sobre $(\Omega, \mathcal{F})$, entonces a las propiedades anteriores se suman:

- iv) **Continuidad superior:** $A_n \searrow A \Rightarrow \mathbb{P}(A_n) \searrow \mathbb{P}(A)$. (la finitud está dada.)
- v) **Complemento:** $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.

1.2 Análisis vs Probabilidad

Aunque tanto en Análisis (Teoría de la medida) como en Probabilidad se trabaja con espacios de medida, la interpretación en cada área es muy diferente:

- **En Análisis:**
 - E suele ser un espacio topológico (i.e. con alguna noción de geometría dentro), típicamente $\mathbb{R}^d$.
 - Σ representa la clase de “conjuntos medibles”, i.e. conjuntos suficientemente buenos geoméricamente como para poder “medirlos”.
 - **Ejemplo:** la clase de conjuntos medibles Lebesgue en $\mathbb{R}^d$.

- $\mu(A)$ representa la “medida” del conjunto A .
- Fijado el espacio E bajo estudio, típicamente Σ queda fija y μ cambia.

• **En Probabilidad:**

- Ω es el conjunto de posibles resultados de un experimento bajo estudio. No tiene por qué haber geometría subyacente.
- $\mathcal{F}$ representa el conjunto de “información observable” sobre el experimento en cuestión.
- $\mathbb{P}(A)$ representa la probabilidad de que ocurra el evento A .
- Fijado el experimento bajo estudio, típicamente $\mathbb{P}$ queda fija y $\mathcal{F}$ cambia.

Clase 2

6 de Marzo

1.3 Funciones medibles y variables aleatorias

1.3.1 En Análisis

Sean $(\Omega, \mathcal{F})$ y (E, Σ) dos espacios medibles. Una aplicación $f : \Omega \rightarrow E$ se dirá *medible* de $(\Omega, \mathcal{F})$ a (E, Σ) (o $(\mathcal{F}, \Sigma)$ -medible o medible a secas) si

$$f^{-1}(B) \in \mathcal{F} \text{ para todo } B \in \Sigma.$$

Si $(\Omega, \mathcal{F}, \mu)$ es un espacio de medida y $f : \Omega \rightarrow E$ es $(\mathcal{F}, \Sigma)$ -medible, la medida μ_f sobre (E, Σ) dada por la fórmula

$$\mu_f(B) := \mu \circ f^{-1}(B) = \underbrace{\mu(f^{-1}(B))}_{\in \mathcal{F}}$$

se denomina la *medida inducida* o *push-forward* de μ por f .

1.3.2 En Probabilidad

Una *variable aleatoria* es una aplicación $X : \Omega \rightarrow \mathbb{R}$ medible de $(\Omega, \mathcal{F})$ a $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, donde:

- $(\Omega, \mathcal{F})$ es algún espacio medible,
- $\mathcal{B}(\mathbb{R})$ es la clase de los **borelianos** en $\mathbb{R}$.

Es decir, una variable aleatoria es cualquier aplicación medible a valores en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Notación. Las variables aleatorias se denotan por X en lugar de f .

Observación. A veces se reemplaza $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ por $(\overline{\mathbb{R}}, \mathcal{B}(\overline{\mathbb{R}}))$ en la definición.

En general, si $X : \Omega \rightarrow E$ es medible, vamos a decir que X es un *elemento aleatorio* sobre E (o variable aleatoria a valores en E). A lo largo del curso, trabajaremos con elementos aleatorios en donde el espacio E es un espacio topológico.

Definición 1.8. Un *espacio topológico* es un par (E, τ) donde:

- E es un espacio;
- τ es una topología sobre E .

Una *topología* sobre E es una clase τ de subconjuntos de E que satisface:

- i) $\emptyset$ y E pertenecen a τ ;
- ii) $(U_i)_{i \in I} \subset \tau \Rightarrow \bigcup_{i \in I} U_i \in \tau$;
- iii) $U_1, \dots, U_k \in \tau \Rightarrow \bigcap_{i=1}^k U_i \in \tau$.

A los conjuntos de la clase τ se los llama *abierto*s de E .

En cualquier espacio topológico tenemos una σ -álgebra canónica:

Definición 1.9. Dado un espacio E y una clase $\mathcal{C}$ de subconjuntos de E , definimos la σ -álgebra *generada por* $\mathcal{C}$, y la notamos por $\sigma(\mathcal{C})$, como la menor σ -álgebra de subconjuntos de E que contiene a $\mathcal{C}$, i.e, tal que:

- i) $\mathcal{C} \subseteq \sigma(\mathcal{C})$;
- ii) $\mathcal{F}$ σ -álgebra, $\mathcal{C} \subseteq \mathcal{F} \Rightarrow \sigma(\mathcal{C}) \subseteq \mathcal{F}$.

Observación. Puede verificarse que vale la fórmula

$$\sigma(\mathcal{C}) := \bigcap_{\substack{\mathcal{F} \text{ } \sigma\text{-álgebra} \\ \mathcal{C} \subseteq \mathcal{F}}} \mathcal{F}.$$

Definición 1.10. Dado un espacio topológico (E, τ) , definimos su σ -álgebra *de Borel*, y la notamos $\mathcal{B}(E)$, como aquella generada por τ , i.e.

$$\mathcal{B}(E) := \sigma(\tau).$$

Luego, un *elemento aleatorio* sobre un espacio topológico E es una aplicación medible $X : \Omega \rightarrow E$ desde un espacio medible $(\Omega, \mathcal{F})$ al espacio medible $(E, \mathcal{B}(E))$.

1.4 Distribución de una variable aleatoria

Por último, si $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad y $X : \Omega \rightarrow E$ es $(\mathcal{F}, \mathcal{B}(E))$ -medible, entonces la medida $\mathbb{P}_X$ inducida sobre $(E, \mathcal{B}(E))$ recibe el nombre de *distribución de X* (sobre $(E, \mathcal{B}(E))$), i.e,

$$\mathbb{P}_X(B) := \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{B}(E).$$

A los eventos $X^{-1}(B)$ se los suele notar (en probabilidad) como $\{X \in B\}$, i.e,

$$\{X \in B\} := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{F}.$$

(Es decir, se suprime el rol de ω en la notación.)

1.4.1 Diferencia de enfoques

- **En Análisis:** interesan propiedades de las funciones medibles f que dependen de su dominio (continuidad, derivabilidad, convexidad, gráfico, etc.).
- **En Probabilidad:** no interesa el dominio de una variable aleatoria X , sino su distribución en el codominio.

1.5 Función de distribución

La distribución de una variable aleatoria X (a valores en $\mathbb{R}$) se suele describir mediante su **función de distribución (acumulada)** $F_X : \mathbb{R} \rightarrow [0, 1]$ dada por la fórmula

$$F_X(x) := \mathbb{P}(X \leq x).$$

Propiedad 1.11. La función de distribución F_X satisface:

- i) F_X es monótona creciente;
- ii) $F_X(-\infty) := \lim_{x \rightarrow -\infty} F_X(x) = 0$ y $F_X(+\infty) := \lim_{x \rightarrow +\infty} F_X(x) = 1$;
- iii) F_X es continua a derecha, i.e. $F_X(x^+) := \lim_{y \rightarrow x^+} F_X(y) = F_X(x)$;
- iv) $F_X(x^-) := \lim_{y \rightarrow x^-} F_X(y) = \mathbb{P}(X < x)$;
- v) $\Delta F_X(x) := F_X(x) - F_X(x^-) = \mathbb{P}(X = x)$.

Si una función $F : \mathbb{R} \rightarrow [0, 1]$ satisface (i), (ii) y (iii) arriba, diremos que se trata de una *función de distribución* (no necesariamente asociada a alguna variable aleatoria X).

El siguiente resultado nos dice por qué es suficiente F_X para describir $\mathbb{P}_X$.

Teorema 1.12. Sea F una función de distribución. Entonces:

1. Existe una variable aleatoria X (definida en algún espacio de probabilidad) tal que $F \equiv F_X$.
2. La distribución de dicha variable es única, i.e.

$$F_{X_1} = F_{X_2} \Rightarrow \mathbb{P}_{X_1} = \mathbb{P}_{X_2}$$

(si $\mathbb{P}_{X_1} = \mathbb{P}_{X_2}$ lo notamos $X_1 \stackrel{\mathcal{L}}{=} X_2$).

Corolario 1.13.

1. Dada una probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \beta(\mathbb{R}))$, la función $F : \mathbb{R} \rightarrow [0, 1]$ definida por $F(x) := \mathbb{P}((-\infty, x])$ es una función de distribución.
2. Dada una función de distribución F , existe una única probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \beta(\mathbb{R}))$ tal que $\mathbb{P}((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$. De hecho, $\mathbb{P} = \mathbb{P}_X$ donde X es la variable del teorema.

En particular, existe una correspondencia biunívoca entre

$$\begin{aligned}\mathcal{A} &:= \{\mathbb{P} : \mathbb{P} \text{ medida de probabilidad en } (\mathbb{R}, \beta(\mathbb{R}))\}; \\ \mathcal{B} &:= \{F : F \text{ función de distribución}\}; \\ \mathcal{C} &:= \{\mathbb{P}_X : X \text{ variable aleatoria (a valores en } \mathbb{R})\};\end{aligned}$$

dada por:

$$\begin{aligned}\alpha: \mathcal{A} &\rightarrow \mathcal{B} \\ \mathbb{P} &\mapsto F(x) := \mathbb{P}((-\infty, x]); \\ \\ \beta: \mathcal{B} &\rightarrow \mathcal{C} \\ F &\mapsto \mathbb{P}_X \text{ donde } F_X = F; \\ \\ \gamma: \mathcal{C} &\rightarrow \mathcal{A} \\ \mathbb{P}_X &\mapsto \mathbb{P}_X.\end{aligned}$$

Como consecuencia del Teorema, son inversas

$$\begin{cases} \alpha \text{ y } \gamma \circ \beta \\ \beta \text{ y } \alpha \circ \gamma \\ \gamma \text{ y } \beta \circ \alpha \end{cases}$$

Por otro lado, demostraremos únicamente el teorema; la deducción del corolario a partir de éste es sencilla. Además, lo haremos de dos formas:

1. **Forma canónica:** tomamos $(\Omega, \mathcal{F}) := (\mathbb{R}, \beta(\mathbb{R}))$ y $X := \text{id}_\Omega$ ($X(\omega) = \omega$) y definimos $\mathbb{P}$ sobre $(\Omega, \mathcal{F})$ de manera tal que en $(\Omega, \mathcal{F}, \mathbb{P})$ la variable $X := \text{id}_\Omega$ cumpla lo buscado.
2. **Forma constructiva:** tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ((0, 1), \beta((0, 1)), \text{Leb}_{(0,1)})$ y definimos allí una variable X que cumpla lo buscado.

1.6 Tipos de variables aleatorias

Trabajaremos frecuentemente con dos tipos de variables aleatorias.

Definición 1.14. Una variable aleatoria X se dice *discreta* si existe $S \subseteq \mathbb{R}$ a lo sumo numerable tal que $\mathbb{P}_X(S) = 1$. (Es decir, si X toma a lo sumo numerables valores, salvo medida nula.)

Equivalentemente, X es discreta $\Leftrightarrow \mathbb{P}_X(\mathcal{A}_X) = 1$, donde

$$\mathcal{A}_X = \{x \in \mathbb{R} : \mathbb{P}(X = x) > 0\}$$

es el conjunto de *átomos* (siempre a lo sumo numerable) de X .

Si X es discreta, definimos su *función de probabilidad puntual* como la función $p_X : \mathcal{A}_X \rightarrow [0, 1]$ dada por

$$p_X(x) := \mathbb{P}_X(\{x\}).$$

Definición 1.15. Una variable aleatoria X se dice *absolutamente continua* si existe una función $f_X : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ medible Borel tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad \text{para todo } x \in \mathbb{R}.$$

En tal caso, la función f_X se llama la *densidad* de X .

Puede verificarse que X es absolutamente continua $\Leftrightarrow F_X$ es absolutamente continua, i.e. F_X es derivable en casi todo punto, $F'_X \in L^1(\mathbb{R})$ y se verifica que

$$F_X(x) = \int_{-\infty}^x F'_X(t) dt \quad \text{para todo } x \in \mathbb{R}.$$

Además, en tal caso vale que $f_X = F'_X$ en casi todo punto.

Observación. Existen variables aleatorias que no son ni discretas ni absolutamente continuas, ni una “mezcla” de ambas (ver Práctica).

Clase 3

9 de Marzo

1.7 Integración y Esperanza

Sean $(\Omega, \mathcal{F}, \mu)$ un espacio de medida y $f : \Omega \rightarrow \mathbb{R}$ ($\mathcal{F}, \beta(\mathbb{R})$)-medible. Entonces, definimos $\int_{\Omega} f d\mu$, la *integral de f respecto a μ* , como:

i) Si f es *simple*, i.e.,

$$f = \sum_{i=1}^k a_i \mathbb{1}_{A_i}$$

con $(A_i)_{i=1, \dots, k} \subseteq \mathcal{F}$ partición finita de Ω , entonces

$$\int_{\Omega} f d\mu := \sum_{i=1}^k a_i \mu(A_i).$$

ii) Si $f \geq 0$,

$$\int_{\Omega} f d\mu := \sup \left\{ \int_{\Omega} g d\mu : g \text{ simple, } 0 \leq g \leq f \right\} \in [0, \infty].$$

iii) Si f cambia de signo, consideramos

$$\begin{cases} f^+(\omega) := f(\omega)\mathbb{1}_{f(\omega) \geq 0} \\ f^-(\omega) := -f(\omega)\mathbb{1}_{f(\omega) < 0} \end{cases}$$

y, si $\int_{\Omega} f^+ d\mu < \infty$ ó $\int_{\Omega} f^- d\mu < \infty$, definimos

$$\int_{\Omega} f d\mu := \int_{\Omega} f^+ d\mu - \int_{\Omega} f^- d\mu \in [-\infty, \infty].$$

iv) Si $\int_{\Omega} f^+ d\mu = \int_{\Omega} f^- d\mu = \infty$, la integral de f respecto de μ no se encuentra bien definida.

Además,

- Diremos que f es μ -integrable (o absolutamente integrable) si

$$\int_{\Omega} |f| d\mu < +\infty$$

($\Leftrightarrow \int_{\Omega} f^+ d\mu < \infty$ y $\int_{\Omega} f^- d\mu < \infty$) y débilmente μ -integrable si

$$\min \left\{ \int_{\Omega} f^+ d\mu, \int_{\Omega} f^- d\mu \right\} < \infty.$$

- Por último, si $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad y X es una variable aleatoria (a valores en $\mathbb{R}$) en este espacio, definimos $\mathbb{E}(X)$, la *esperanza de X* (o *media de X*), como

$$\mathbb{E}(X) := \int_{\Omega} X d\mathbb{P}$$

siempre que la integral se encuentre bien definida.

Nota. Valen para la esperanza todas las propiedades de la integral que ya se conocen (linealidad, monotonía, teoremas de paso al límite, etc.)

Definición 1.16. Sean μ y ν dos medidas sobre $(\Omega, \mathcal{F})$. Diremos que:

1. ν es *absolutamente continua* respecto de μ , y lo notamos $\nu \ll \mu$, si $\mu(A) = 0 \Rightarrow \nu(A) = 0$.
2. μ y ν son *equivalentes* si $\nu \ll \mu$ y $\mu \ll \nu$.
3. ν es *singular* respecto de μ , y lo notamos $\nu \perp \mu$, si existe $A \in \mathcal{F}$ tal que $\mu(A) = 0$ y $\nu(A^c) = 0$.

Ejemplo.

1. X discreta $\Rightarrow \mathbb{P}_X \perp \text{Lebesgue}$ (no vale la vuelta!);
2. X absolutamente continua $\Leftrightarrow \mathbb{P}_X \ll \text{Lebesgue}$;
3. X discreta $\Leftrightarrow \mathbb{P}_X \ll N_{\mathcal{A}_X}$ (medida de contar en $\mathcal{A}_X$).

Teorema 1.17 (Radon-Nikodym). Sean μ y ν dos medidas σ -finitas sobre (E, Σ) . Entonces las siguientes afirmaciones son equivalentes:

1. $\nu \ll \mu$
2. Existe una función $f : E \rightarrow \mathbb{R}_{\geq 0}$ ($\mathcal{F}, \beta(\mathbb{R})$)-medible tal que

$$\nu(A) = \int_A f(\omega) d\mu(\omega) \quad \text{para todo } A \in \mathcal{F}.$$

La función f es única salvo conjuntos de μ -medida nula y se la llama *derivada de Radon-Nikodym* de ν respecto de μ , denotada por $f = \frac{d\nu}{d\mu}$.

1.8 Teorema de existencia y unicidad de variable aleatoria con distribución dada

Volvamos al teorema de la clase pasada para demostrarlo:

Teorema 1.18. Sea F una función de distribución. Entonces:

1. Existe una variable aleatoria X (definida en algún espacio de probabilidad) tal que $F = F_X$.
2. La distribución de dicha variable es única, i.e.

$$F_{X_1} = F_{X_2} \Rightarrow \mathbb{P}_{X_1} = \mathbb{P}_{X_2}$$

(si $\mathbb{P}_{X_1} = \mathbb{P}_{X_2}$ lo notamos $X_1 \stackrel{\mathcal{L}}{=} X_2$).

Corolario 1.19.

1. Dada una probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \beta(\mathbb{R}))$, la función $F : \mathbb{R} \rightarrow [0, 1]$ definida por $F(x) := \mathbb{P}((-\infty, x])$ es una función de distribución.
2. Dada una función de distribución F , existe una única probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \beta(\mathbb{R}))$ tal que $\mathbb{P}((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$. De hecho, $\mathbb{P} = \mathbb{P}_X$ donde X es la variable del teorema.

Demostraremos únicamente el teorema; la deducción del corolario a partir de éste es sencilla. Además, lo haremos de dos formas:

1. **Forma canónica:** tomamos $(\Omega, \mathcal{F}) := (\mathbb{R}, \beta(\mathbb{R}))$ y $X := \text{id}_{\Omega}$ ($X(\omega) = \omega$) y definimos $\mathbb{P}$ sobre $(\Omega, \mathcal{F})$ de manera tal que en $(\Omega, \mathcal{F}, \mathbb{P})$ la variable $X := \text{id}_{\Omega}$ cumpla lo buscado.
2. **Forma constructiva:** tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ((0, 1), \beta((0, 1)), \text{Leb}_{(0,1)})$ y definimos allí una variable X que cumpla lo buscado.

1.8.1 Forma canónica:

Para esta forma, utilizamos el Teorema de Carathéodory.

Definición 1.20. Una clase $\mathcal{S}$ de subconjuntos de un espacio E se dice una *semialgebra* si satisface las siguientes propiedades:

- i) $\mathcal{S}$ es no vacía;
- ii) $S, T \in \mathcal{S} \Rightarrow S \cap T \in \mathcal{S}$ (es cerrada por intersecciones);
- iii) $S \in \mathcal{S} \Rightarrow \exists T_1, \dots, T_n \in \mathcal{S}$ disjuntos tales que $S^c = \bigcup_{i=1}^n T_i$.

Observación. $\emptyset \in \mathcal{S}$: si $S \in \mathcal{S}$ y $S = \bigcup_{i=1}^n T_i$ con T_i disjuntos, $\emptyset = S \cap \emptyset \in \mathcal{S}$ por (ii).

Teorema 1.21 (Extensión de Carathéodory). Sean $\mathcal{S}$ una semialgebra de subconjuntos de un espacio E y $\mu_0 : \mathcal{S} \rightarrow [0, 1]$ una aplicación que satisface:

S0) $\mu_0(\emptyset) = 0$.

S1) μ_0 es finitamente aditiva en $\mathcal{S}$:

$$(A_n)_{n=1, \dots, N} \subseteq \mathcal{S} \text{ disjuntos, } \bigcup_{n=1}^N A_n \in \mathcal{S} \Rightarrow \mu_0\left(\bigcup_{n=1}^N A_n\right) = \sum_{n=1}^N \mu_0(A_n).$$

S2) μ_0 es σ -subaditiva en $\mathcal{S}$:

$$(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{S} \text{ disjuntos, } A \in \mathcal{S}, A \subseteq \bigcup_{n \in \mathbb{N}} A_n \Rightarrow \mu_0(A) \leq \sum_{n \in \mathbb{N}} \mu_0(A_n).$$

Entonces existe una medida μ sobre $(E, \sigma(\mathcal{S}))$ tal que $\mu|_{\mathcal{S}} = \mu_0$.

Además, si μ_0 es σ -finita, entonces la extensión μ es única; donde σ -finita significa que existen $(E_n)_{n \in \mathbb{N}} \subseteq \mathcal{S}$ tales que $E = \bigcup_n E_n$ y $\mu_0(E_n) < \infty$ para todo n .

Idea de demostración del teorema (forma canónica)

- Consideramos la semialgebra $\mathcal{S} = \{(a, b] : -\infty \leq a \leq b \leq \infty\}$ con la convención $(a, a] = \emptyset$ y (a, ∞) si $b = \infty$.
- Definimos $\mu_0 : \mathcal{S} \rightarrow [0, 1]$ como $\mu_0((a, b]) = F(b) - F(a)$.
- Probamos que μ_0 satisface (s0), (s1), (s2). (La demostración de (s2) requiere trabajo!)
- Por el teorema de Carathéodory, existe extensión μ a todo $\sigma(\mathcal{S}) = \beta(\mathbb{R})$.
- Tomamos $\mathbb{P} := \mu$ y vemos que en el espacio de probabilidad $(\mathbb{R}, \beta(\mathbb{R}), \mathbb{P})$ la variable aleatoria $X := \text{id}_{\mathbb{R}}$ cumple que

$$F_X(x) = \mathbb{P}(\{\omega : X(\omega) \leq x\}) = \mathbb{P}((-\infty, x]) = F(x) - F(-\infty) = F(x).$$

- Si $F_{X_1} = F_{X_2} = F$, entonces $\mathbb{P}_{X_1}$ y $\mathbb{P}_{X_2}$ son extensiones de μ_0 a $\sigma(\mathcal{S})$. Como $\mu_0(\mathbb{R}) = F(\infty) - F(-\infty) = 1$, por la unicidad en el teorema de Carathéodory, $\mathbb{P}_{X_1} = \mathbb{P}_{X_2}$.

Observación. La forma canónica lleva bastante trabajo (que no hicimos), que es el mismo que se suele hacer al construir la medida de Lebesgue. La forma constructiva es más rápida (y útil), pero asume que ya tenemos construida la medida de Lebesgue de antemano.

1.8.2 Forma constructiva: inversa generalizada

Para la demostración de forma constructiva, introducimos la inversa generalizada.

Definición 1.22 (Inversa generalizada). Sea $F : \mathbb{R} \rightarrow [0, 1]$ una función. Definimos su *inversa generalizada* $F^{-1} : [0, 1] \rightarrow \overline{\mathbb{R}}$ mediante la fórmula

$$F^{-1}(y) := \sup\{z \in \mathbb{R} : F(z) < y\},$$

donde convenimos que $\sup \emptyset = -\infty$ y $\sup A = \infty$ si A no está acotado superiormente.

Lema 1.23. Sea $F : \mathbb{R} \rightarrow [0, 1]$ una función de distribución. Entonces, si U es una variable aleatoria tal que $\mathbb{P}_U = \mathcal{L}|_{[0,1]}$, i.e. $\mathbb{P}(U \in B) = |B \cap [0, 1]|$ para todo Borel B , resulta que $X := F^{-1}(U)$ es una variable aleatoria y satisface $F_X = F$.

Demostración. 1. En primer lugar, observemos que F^{-1} es medible Borel por ser monótona creciente por definición.

2. En particular, $X := F^{-1}(U)$ es variable aleatoria (pues $X^{-1}(B) = U^{-1}((F^{-1})^{-1}(B)) \in \mathcal{F}$ para todo $B \in \beta(\mathbb{R})$).

3. Además, vale que

$$\{X \leq x\} = \{U \leq F(x)\} \quad \forall x \in \mathbb{R}, \quad (1)$$

de manera tal que

$$\begin{aligned} F_X(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) \\ &= |(-\infty, F(x)] \cap [0, 1]| \\ &= |[0, F(x)]| \\ &= F(x). \end{aligned}$$

En efecto, para ver (1) notemos:

($\subseteq$) Si $\omega \in \Omega$ es tal que $X(\omega) \leq x$ entonces debe valer que $U(\omega) \leq F(x)$. En caso contrario, si $F(x) < U(\omega)$, como F es continua a

derecha, existiría $\varepsilon > 0$ tal que $F(x + \varepsilon) < U(\omega)$. En particular, $x + \varepsilon \in \{z \in \mathbb{R} : F(z) < U(\omega)\}$ y, por lo tanto,

$$x + \varepsilon \leq \sup\{z : F(z) < U(\omega)\} = F^{-1}(U(\omega)) = X(\omega),$$

lo que implica $X(\omega) > x$, y esto contradice nuestra suposición..

($\supseteq$) Si ω cumple que $U(\omega) \leq F(x)$, entonces

$$x \notin \{z \in \mathbb{R} : F(z) < U(\omega)\} =: I_\omega.$$

En efecto, si $I_\omega \neq \emptyset$, entonces I_ω es un intervalo no acotado inferiormente por ser monótona creciente (i.e. si $z \in I_\omega$ y $z' \leq z$, entonces $F(z') \leq F(z) < U(\omega)$ y, por ende, $z' \in I_\omega$), entonces x es cota superior de I_ω y, por lo tanto,

$$X = F^{-1}(U(\omega)) = \sup I_\omega \leq x$$

y así vemos que vale la contención.

Así queda demostrada la igualdad (1). $\square$

Observación. F^{-1} se llama inversa generalizada de F puesto que satisface la igualdad $\{y : F^{-1}(y) \leq x\} = \{y : y \leq F(x)\}$ dada en (1) y, si en vez de $\leq$ tuviésemos $=$ en (1), entonces sería la inversa tradicional.

Ahora estamos listos para dar la demostración de forma constructiva.

Demostración (Demostración del Teorema-(1), Forma constructiva). Tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ([0, 1], \beta([0, 1]), \mathcal{L}|_{[0, 1]})$ y $U := \text{id}_{[0, 1]}$. Como $\mathbb{P}_U = \mathcal{L}|_{[0, 1]}$ por definición, por el lema previo, $X := F^{-1}(U)$ es la variable aleatoria buscada. $\square$

Para demostrar la unicidad (teorema, parte 2) necesitamos otro resultado.

Definición 1.24 (π -sistema). Una clase $\mathcal{P}$ de subconjuntos de un espacio E se dice un π -sistema si es cerrada por intersecciones finitas, i.e., si $A, B \in \mathcal{P}$ entonces $A \cap B \in \mathcal{P}$.

Definición 1.25 (λ -sistema). Una clase $\mathcal{D}$ de subconjuntos de un espacio E se dice un λ -sistema si verifica las siguientes condiciones:

- I) $E \in \mathcal{D}$.
- II) $A \in \mathcal{D} \Rightarrow A^c \in \mathcal{D}$.
- III) $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{D}$ disjuntos $\Rightarrow \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{D}$.

Teorema 1.26 (π - λ de Dynkin). Si $\mathcal{P}$ es un π -sistema y $\mathcal{D}$ es un λ -sistema tales que $\mathcal{P} \subseteq \mathcal{D}$, entonces $\sigma(\mathcal{P}) \subseteq \mathcal{D}$.

Demostración. Ver Apéndice I o [Teorema 3.2] de Billingsley (P & M). $\square$

Como consecuencia, tenemos el siguiente corolario.

Corolario 1.27. Supongamos que $\mathbb{P}_1$ y $\mathbb{P}_2$ son probabilidades en $\sigma(\mathcal{P})$, donde $\mathcal{P}$ es un π -sistema. Si $\mathbb{P}_1$ y $\mathbb{P}_2$ coinciden en $\mathcal{P}$ entonces también coinciden en todo $\sigma(\mathcal{P})$.

Demostración. Sea $\mathcal{D} = \{A \in \sigma(\mathcal{P}) : \mathbb{P}_1(A) = \mathbb{P}_2(A)\}$.

- Por hipótesis, $\mathcal{P} \subseteq \mathcal{D}$.
- Si vemos que $\mathcal{D}$ es un λ -sistema, entonces por el teorema de Dynkin tendremos que $\sigma(\mathcal{P}) \subseteq \mathcal{D}$ y, por lo tanto, $\mathbb{P}_1 \equiv \mathbb{P}_2$ en $\sigma(\mathcal{P})$.

Veamos que $\mathcal{D}$ es un λ -sistema:

- i) $\mathbb{P}_1(\Omega) = 1 = \mathbb{P}_2(\Omega)$ por ser probabilidades. Luego $\Omega \in \mathcal{D}$.
- ii) $A \in \mathcal{D} \Rightarrow \mathbb{P}_1(A) = \mathbb{P}_2(A) \Rightarrow 1 - \mathbb{P}_1(A) = 1 - \mathbb{P}_2(A) \Rightarrow \mathbb{P}_1(A^c) = \mathbb{P}_2(A^c) \Rightarrow A^c \in \mathcal{D}$.
- iii) Si $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{D}$ son disjuntos, entonces

$$\mathbb{P}_1\left(\bigcup_n A_n\right) = \sum_n \mathbb{P}_1(A_n) = \sum_n \mathbb{P}_2(A_n) = \mathbb{P}_2\left(\bigcup_n A_n\right),$$

por la σ -aditividad de las probabilidades. Luego $\bigcup_n A_n \in \mathcal{D}$.

Luego $\mathcal{D}$ es un λ -sistema y esto concluye la demostración. $\square$

Ahora estamos listos para terminar la demostración del Teorema.

Demostración (Demostración de Teorema-(2), Forma Constructiva). Dado $x \in \mathbb{R}$ y dos variables aleatorias X_1 y X_2 (no necesariamente definidas en el mismo EdP)

$$\begin{aligned} F_{X_1}(x) = F_{X_2}(x) &\Leftrightarrow \mathbb{P}(X_1 \leq x) = \mathbb{P}(X_2 \leq x) \\ &\Leftrightarrow \mathbb{P}(X_1 \in (-\infty, x]) = \mathbb{P}(X_2 \in (-\infty, x]) \\ &\Leftrightarrow \mathbb{P}_{X_1}((-\infty, x]) = \mathbb{P}_{X_2}((-\infty, x]). \end{aligned}$$

Como $\mathcal{P} = \{(-\infty, x] : x \in \mathbb{R}\}$ es un π -sistema, por el corolario anterior, tenemos que $F_{X_1} \equiv F_{X_2} \Rightarrow \mathbb{P}_{X_1} = \mathbb{P}_{X_2}$ en $\sigma(\mathcal{P})$. Luego, para concluir sólo resta ver que $\sigma(\mathcal{P}) = \beta(\mathbb{R})$.

$\boxed{\subseteq}$ $\beta(\mathbb{R})$ contiene a todos los abiertos y es cerrada por complementos. Luego, $\beta(\mathbb{R})$ contiene a todos los cerrados y, en particular, a todos los elementos de $\mathcal{P}$. Por minimalidad de $\sigma(\mathcal{P})$, $\sigma(\mathcal{P}) \subseteq \beta(\mathbb{R})$.

$\boxed{\supseteq}$ $\sigma(\mathcal{P})$ contiene a todos los intervalos de la forma $(a, b] = (-\infty, b] \cap$

$((-\infty, a]^c)$ y, por lo tanto, a todos los intervalos abiertos $(a, b) = \bigcup_{n \in \mathbb{N}} (a, b - \frac{1}{n}]$. Como cualquier abierto en $\mathbb{R}$ es unión numerable de intervalos (a, b) (por ser $\mathbb{R}$ separable), $\sigma(\mathcal{P})$ contiene a cualquier abierto en $\mathbb{R}$. Por minimalidad de $\beta(\mathbb{R})$, resulta que $\beta(\mathbb{R}) \subseteq \sigma(\mathcal{P})$. $\square$

Clase 4

11 de Marzo

1.9 Medidas Producto

Definición 1.28. Dado un espacio Ω , un espacio medible $(E, \mathcal{M})$ y una función $f: \Omega \rightarrow E$, definimos la σ -álgebra generada por f como la menor σ -álgebra $\sigma(f)$ de subconjuntos de Ω que hace que f sea medible, i.e.

$$\sigma(f) := \{f^{-1}(B) \mid B \in \mathcal{M}\}.$$

Sea $(f_i)_{i \in I}$ una familia de funciones $f_i: \Omega \rightarrow E_i$ donde $(E_i, \mathcal{M}_i)$ es espacio medible para cada i . Entonces, definimos la σ -álgebra generada por $(f_i)_{i \in I}$ como la menor σ -álgebra $\sigma(f_i : i \in I)$ que hace que todas las f_i sean medibles, i.e.

$$\begin{aligned} \sigma(f_i : i \in I) &:= \sigma\left(\bigcup_{i \in I} \sigma(f_i)\right) \\ &= \sigma(\{f_i^{-1}(B) : B \in \mathcal{M}_i, i \in I\}) \end{aligned}$$

Definición 1.29. Sean $(E_1, \mathcal{M}_1, \mu_1)$ y $(E_2, \mathcal{M}_2, \mu_2)$ espacios de medida σ -finita. Definimos la σ -álgebra producto $\mathcal{M}_1 \times \mathcal{M}_2$ en $E_1 \times E_2$ como aquella generada por las proyecciones $\pi_i: E_1 \times E_2 \rightarrow E_i$ ($i = 1, 2$) dadas por

$$\pi_1(x, y) = x, \quad \pi_2(x, y) = y$$

Nota. Puede verificarse que si definimos la clase $\mathcal{R}$ de rectángulos en $E_1 \times E_2$

$$\mathcal{R} := \{A \times B : A \in \mathcal{M}_1, B \in \mathcal{M}_2\},$$

entonces $\mathcal{M}_1 \times \mathcal{M}_2 = \sigma(\mathcal{R})$.

Teorema 1.30. Existe una única medida $\mu_1 \times \mu_2$ en $\mathcal{M}_1 \times \mathcal{M}_2$ tal que

$$\mu_1 \times \mu_2(A \times B) = \mu_1(A)\mu_2(B) \quad \forall A \in \mathcal{M}_1, B \in \mathcal{M}_2.$$

Dicha medida recibe el nombre de la *medida producto* entre μ_1 y μ_2 .

Ejemplo. $\mathcal{L}(\mathbb{R}^d) = \mathcal{L}(\mathbb{R}^j) \times \mathcal{L}(\mathbb{R}^{d-j})$ para $1 \leq j \leq d-1$.

Teorema 1.31 (Fubini-Tonelli). Sea $f: E_1 \times E_2 \rightarrow [0, \infty]$ medible. Entonces:

- i) Para cada $x \in E_1$, la aplicación $y \mapsto f(x, y)$ es $\mathcal{M}_2$ -medible;
- ii) Para cada $y \in E_2$, la aplicación $x \mapsto f(x, y)$ es $\mathcal{M}_1$ -medible;
- iii) Las aplicaciones $x \mapsto \int_{E_2} f(x, y) d\mu_2(y)$, $y \mapsto \int_{E_1} f(x, y) d\mu_1(x)$ son medibles;
- iv) Valen las igualdades:

$$\begin{aligned} \int_{E_1 \times E_2} f(x, y) d(\mu_1 \times \mu_2)(x, y) &= \int_{E_1} \left[\int_{E_2} f(x, y) d\mu_2(y) \right] d\mu_1(x) \\ &= \int_{E_2} \left[\int_{E_1} f(x, y) d\mu_1(x) \right] d\mu_2(y). \end{aligned}$$

Teorema 1.32 (Fubini). Sea $f: E_1 \times E_2 \rightarrow [-\infty, \infty]$ (μ_1, μ_2) -integrable. Entonces:

- i) $y \mapsto f(x, y)$ es μ_2 -integrable para μ_1 -casi todo $x \in E_1$;
- ii) $x \mapsto f(x, y)$ es μ_1 -integrable para μ_2 -casi todo $y \in E_2$;
- iii) Las aplicaciones $x \mapsto \int_{E_2} f(x, y) d\mu_2(y)$, $y \mapsto \int_{E_1} f(x, y) d\mu_1(x)$ son integrables;
- iv) Valen las igualdades:

$$\begin{aligned} \int_{E_1 \times E_2} f(x, y) d(\mu_1 \times \mu_2)(x, y) &= \int_{E_1} \left[\int_{E_2} f(x, y) d\mu_2(y) \right] d\mu_1(x) \\ &= \int_{E_2} \left[\int_{E_1} f(x, y) d\mu_1(x) \right] d\mu_2(y). \end{aligned}$$

Por inducción, podemos extender la definición de medida producto a cualquier cantidad finita de factores, i.e. $\mu = \mu_1 \times \cdots \times \mu_n$ ($n \geq 2$).

1.10 Independencia

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $A, B \in \mathcal{F}$ con $\mathbb{P}(B) > 0$. Definimos la *probabilidad condicional de A dado B* como

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

(la parte derecha de la igualdad representa las chances que ocurra A si restringimos nuestro espacio a únicamente los casos donde ocurre B) y diremos que A es independiente de B si $\mathbb{P}(A|B) = \mathbb{P}(A)$.

Observación. Si $\mathbb{P}(A|B) = \mathbb{P}(A) \Rightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$.

Esto nos permite dar la siguiente definición más general.

Definición 1.33. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad

- Decimos que 2 eventos son *independientes* si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

- Dadas 2 variables aleatorias X e Y , decimos que son *independientes* si $\forall B_1, B_2 \in \beta(\mathbb{R})$,

$$\mathbb{P}(X \in B_1, Y \in B_2) = \mathbb{P}(X \in B_1) \cdot \mathbb{P}(Y \in B_2).$$

- Dadas 2 sub- σ -álgebras $\mathcal{G}_1$ y $\mathcal{G}_2$, decimos que son *independientes* si $\forall A \in \mathcal{G}_1$ y $B \in \mathcal{G}_2$, A y B son independientes de acuerdo a i).

Proposición 1.34.

1. A y B son independientes $\Leftrightarrow \mathbb{1}_A$ y $\mathbb{1}_B$ son independientes.
2. X e Y son independientes $\Leftrightarrow \sigma(X)$ y $\sigma(Y)$ son independientes.
3. $\mathcal{G}_1$ y $\mathcal{G}_2$ son independientes $\Leftrightarrow$ Para todo par de variables aleatorias X e Y con X $\mathcal{G}_1$ -medible e Y $\mathcal{G}_2$ -medible se tiene que X e Y son independientes.

Demostración. i) $\{\mathbb{1}_A \in C\} \in \{\emptyset, A, A^c, \Omega\}$ y $\{\mathbb{1}_B \in D\} \in \{\emptyset, B, B^c, \Omega\}$.
Luego, la implicación $\Leftarrow$) es inmediata.

Para ver $\Rightarrow$), hay que verificar 16 pares de eventos. Aquellos que involucran $\emptyset$ y/o Ω son inmediatos. Sólo resta ver A^c y B , A^c y B^c , $A \cap B^c$. Hacemos el primero:

$$\begin{aligned} \mathbb{P}(A^c \cap B) &= \mathbb{P}(B - A) \\ &= \mathbb{P}(B) - \mathbb{P}(A \cap B) \\ &= \mathbb{P}(B) - \mathbb{P}(A)\mathbb{P}(B) \\ &= (1 - \mathbb{P}(A))\mathbb{P}(B) \\ &= \mathbb{P}(A^c)\mathbb{P}(B). \end{aligned}$$

ii) Basta con observar que

$$\begin{cases} \sigma(X) = \{\{X \in B_1\} : B_1 \in \beta(\mathbb{R})\} \\ \sigma(Y) = \{\{Y \in B_2\} : B_2 \in \beta(\mathbb{R})\}. \end{cases}$$

iii) $\Leftarrow$ Notar que

$$\begin{aligned} \mathbb{P}(X \in B_1, Y \in B_2) &= \mathbb{P}(\{X \in B_1\} \cap \{Y \in B_2\}) \\ &= \mathbb{P}(X \in B_1)\mathbb{P}(Y \in B_2). \end{aligned}$$

Entonces, X e Y independientes.

$\Rightarrow$ Basta tomar $X = \mathbb{1}_A$, $Y = \mathbb{1}_B$ con $A \in \mathcal{G}_1$ y $B \in \mathcal{G}_2$.

□

Definición 1.35. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

- i) Dadas subclases $\mathcal{F}_1, \dots, \mathcal{F}_n \subseteq \mathcal{F}$, diremos que son *independientes* si para cada $J \subseteq \{1, \dots, n\}$ no vacío y toda elección $A_j \in \mathcal{F}_j$,

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j).$$

- ii) Dadas $X_1, \dots, X_n$ variables aleatorias, decimos que son *independientes* si $\sigma(X_1), \dots, \sigma(X_n)$ lo son (de acuerdo a (i)).
- iii) Dados eventos $A_1, \dots, A_n \in \mathcal{F}$, diremos que son *independientes* si las variables aleatorias lo son (de acuerdo a (ii)).

Nota. Cuidado! Que $A_1, \dots, A_n$ sean independientes **NO** significa que

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$$

sino que para cualquier $J \subseteq \{1, \dots, n\}$, $\mathbb{P}(\bigcap_{j \in J} A_j) = \prod_{j \in J} \mathbb{P}(A_j)$, lo cual en general es una condición estrictamente más fuerte. Tampoco basta con que sean independientes de a pares.

Ejemplo. Sea X_1, X_2, X_3 variables aleatorias independientes con

$$\mathbb{P}(X_i = 1) = \frac{1}{2} = \mathbb{P}(X_i = 0) \quad \forall i \in \{1, 2, 3\}.$$

Definimos los siguientes eventos

$$A_1 = \{X_1 = X_3\}, \quad A_2 = \{X_1 = X_2\}, \quad A_3 = \{X_2 = X_3\}.$$

Notar que

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(\text{todas cara}) + \mathbb{P}(\text{todas sello}) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4},$$

con $\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_2 \cap A_3)$. Además,

$$\mathbb{P}(A_1) = \mathbb{P}(2 \text{ y } 3 \text{ con cara}) + \mathbb{P}(2 \text{ y } 3 \text{ con sello}) = \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2},$$

con $\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3)$. Pero

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1 \cap A_2) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2) \cdot \mathbb{P}(A_3).$$

Clase 5

16 de Marzo

Extendemos ahora la noción de independencia a familias arbitrarias.

Definición 1.36. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

- Dada una familia arbitraria $(\mathcal{F}_i)_{i \in I}$ de subclases de $\mathcal{F}$, diremos que son *independientes* si cualquier subfamilia finita lo es.
- Dada una familia arbitraria de variables aleatorias $(X_i)_{i \in I}$, diremos que son *independientes* si las σ -álgebras $(\sigma(X_i))_{i \in I}$ lo son (es decir, si cualquier subfamilia finita $X_{i_1}, \dots, X_{i_n}$ es independiente).
- Dada una familia arbitraria de eventos $(A_i)_{i \in I} \subseteq \mathcal{F}$, diremos que son *independientes* si las variables aleatorias $(\mathbb{1}_{A_i})_{i \in I}$ lo son (es decir, si cualquier subfamilia finita $A_{i_1}, \dots, A_{i_n}$ es independiente).

Tenemos el siguiente resultado:

Teorema 1.37. Si $(\mathcal{P}_i)_{i \in I}$ son π -sistemas independientes, entonces las σ -álgebras $(\sigma(\mathcal{P}_i))_{i \in I}$ también son independientes.

Demostración. Basta con demostrar que si $J = \{i_1, \dots, i_n\} \subseteq I$ es finito, entonces las σ -álgebras $\sigma(\mathcal{P}_{i_1}), \dots, \sigma(\mathcal{P}_{i_n})$ son independientes. Para ello, basta con probar la siguiente afirmación:

$$\begin{array}{ccc} Q_1, \dots, Q_n & \pi\text{-sistemas} & \Rightarrow \sigma(Q_1), Q_2, \dots, Q_n \\ \text{independientes} & & \text{independientes} \end{array} \quad (*)$$

En efecto, como $\mathcal{P}_{i_1}, \dots, \mathcal{P}_{i_n}$ son independientes por hipótesis (ya que son una subfamilia finita de $(\mathcal{P}_i)_{i \in I}$), tomando $Q_j := \mathcal{P}_{i_j}$, por (*) concluimos que $\sigma(\mathcal{P}_{i_1}), \mathcal{P}_{i_2}, \dots, \mathcal{P}_{i_n}$ son independientes. Tomando luego

$$Q_1 := \mathcal{P}_{i_2}, \dots, Q_{n-1} := \mathcal{P}_{i_n}, Q_n := \sigma(\mathcal{P}_{i_1}),$$

por (*) de nuevo, $\sigma(\mathcal{P}_{i_2}), \mathcal{P}_{i_3}, \dots, \mathcal{P}_{i_n}, \sigma(\mathcal{P}_{i_1})$ resultan independientes. Iterando este proceso, obtenemos finalmente que $(\sigma(\mathcal{P}_{i_j}))_{j=1, \dots, n}$ son independientes.

Luego, mostremos (*). Tenemos que ver que para toda elección de $1 \leq i_1 < i_2 < \dots < i_k \leq n$ y toda elección de

$$A_i \in \begin{cases} \sigma(Q_1) & \text{si } i_1 = 1, \\ Q_{i_1} & \text{si } i_1 > 1, \end{cases}$$

$A_{i_j} \in Q_{i_j}$ si $j = 2, \dots, n$, vale que

$$\mathbb{P}(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \dots \mathbb{P}(A_{i_k}).$$

Por un lado, si $i_1 > 1$, entonces $A_{i_j} \in Q_{i_j}$ para todo $j = 1, \dots, k$, y la igualdad vale, pues $Q_{i_1}, \dots, Q_{i_k}$ son independientes.

Por el otro, si $i_1 = 1$, tengo 2 casos:

- a) $A_{i_1} \in Q_1$: en este caso, la igualdad vale por el mismo argumento que 1.

- b) $A_{i_1} \in \sigma(Q_1)$ cualquiera: para ver que la igualdad vale en este caso, definimos $F := \bigcap_{j=2}^k A_{i_j}$ y consideramos la clase

$$\mathcal{L}_1 := \{B \in \sigma(Q_1) : \mathbb{P}(B \cap F) = \mathbb{P} \prod_{j=2}^k \mathbb{P}(A_{i_j})\}.$$

Observar que $Q_1 \subseteq \mathcal{L}_1$ por el caso a). Si mostramos además que $\mathcal{L}_1$ es un λ -sistema, entonces por el Teorema de Dynkin $\sigma(Q_1) \subseteq \mathcal{L}_1$ ($\sigma(Q_1) = \mathcal{L}_1$, de hecho) y luego vale la igualdad en el caso b).

Luego, para concluir la demostración sólo resta ver que $\mathcal{L}_1$ es un λ -sistema. Pero esto es una cuenta similar a la de la clase 3, así que omitimos los detalles.

□

1.10.1 Aplicación

Si $X_1, \dots, X_d$ son variables aleatorias definidas en un mismo EdP, definimos su *función de distribución acumulada conjunta* $F_{X_1 \dots X_d}: \mathbb{R}^d \rightarrow [0, 1]$ por la fórmula

$$F_{X_1 \dots X_d}(x_1, \dots, x_d) := \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

Como consecuencia del Teorema anterior tenemos lo siguiente:

Teorema 1.38. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un EdP y $X_1, \dots, X_d: \Omega \rightarrow \mathbb{R}$ variables aleatorias. Entonces, el vector $(X_1, \dots, X_d): \Omega \rightarrow \mathbb{R}^d$ es $\mathcal{F}$ -medible (se dice un *vector aleatorio*) y las siguientes afirmaciones son equivalentes:

- i) $X_1, \dots, X_d$ son independientes;
- ii) $F_{X_1 \dots X_d} = \prod_{i=1}^d F_{X_i}$;
- iii) $\mathbb{P}_{X_1 \dots X_d} = \mathbb{P}_{X_1} \times \dots \times \mathbb{P}_{X_d}$;
- iv) Las proyecciones canónicas $\pi_i: \mathbb{R}^d \rightarrow \mathbb{R}$ ($i = 1, \dots, d$) son variables aleatorias independientes en $(\mathbb{R}^d, \beta(\mathbb{R}^d), \mathbb{P}_{X_1 \dots X_d})$ cada π_i con distribución $\mathbb{P}_{X_i}$ respectivamente.

Demostración. Ver práctica 2.

□

Nota. Si $X = (X_1, \dots, X_d)$ es un vector aleatorio,

- $\mathbb{P}_X = \mathbb{P}_{X_1 \dots X_d}$ se llama la *distribución conjunta* del vector X .
- Las distribuciones $\mathbb{P}_{X_j}$ ($j = 1, \dots, d$) se llaman *marginales* de X .

→ $\mathbb{P}_X$ determina las distribuciones marginales $\mathbb{P}_{X_i}$.

→ El Teorema dice que, en el caso independiente, vale la vuelta (en general no vale, $\mathbb{P}_X$ guarda más información que las $\mathbb{P}_{X_i}$).

El siguiente resultado nos será de utilidad:

Teorema 1.39. Sean X e Y variables aleatorias independientes. Entonces, si $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ es medible Borel con $h \geq 0$ ó $\mathbb{E}(|h(X, Y)|) < \infty$,

$$\mathbb{E}(h(X, Y)) = \int \int h(x, y) d\mathbb{P}_X(x) d\mathbb{P}_Y(y).$$

En particular, si $h(x, y) = f(x)g(y)$ con $f, g: \mathbb{R} \rightarrow \mathbb{R}$ medibles Borel tales que $f, g \geq 0$ o $\mathbb{E}(|f(X)|), \mathbb{E}(|g(Y)|) < \infty$, entonces

$$\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y)).$$

Demostración. Ver práctica 2. □

Observación. Notar que si $\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y)) \quad \forall f, g: \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ medibles Borel, entonces X e Y son independientes (o sea, ambas condiciones son equivalentes).

Corolario 1.40. Si X e Y son independientes, entonces, para todo $z \in \mathbb{R}$,

$$F_{X+Y}(z) := \int_{\mathbb{R}} F_X(z - y) d\mathbb{P}_Y(y) =: F_X * \mathbb{P}_Y(z).$$

En general,

$$\mathbb{P}_{X+Y}(B) = \int \int \mathbf{1}_B(x + y) d\mathbb{P}_X(x) d\mathbb{P}_Y(y) =: \mathbb{P}_X * \mathbb{P}_Y(B) \quad \forall B \in \beta(\mathbb{R}).$$

En particular, si X e Y son absolutamente continuas, entonces $X + Y$ es absolutamente continua y $f_{X+Y} = f_X * f_Y$.

Demostración. Notar que

$$\begin{aligned} \mathbb{P}_{X+Y}(B) &= \mathbb{P}(X + Y \in B) = \int \overbrace{\mathbf{1}_B(x + y)}^{h_B(x, y)} d\mathbb{P} \\ &= \int \mathbf{1}_B(x + y) d\mathbb{P}_{XY}(x, y) \\ (X, Y \text{ indep.}) &= \int \int \mathbf{1}_B(x + y) d\mathbb{P}_X(x) d\mathbb{P}_Y(y) \\ &= \mathbb{P}_X * \mathbb{P}_Y(B). \end{aligned}$$

En particular, si $B = (-\infty, z]$, obtenemos

$$\begin{aligned} F_{X+Y}(z) &= \mathbb{P}_{X+Y}(B) = \int \int \mathbf{1}_{(-\infty, z-y]}(x) d\mathbb{P}_X(x) d\mathbb{P}_Y(y) \\ &= \int \mathbb{P}_X((-\infty, z-y]) d\mathbb{P}_Y(y) \\ &= \int F_X(z-y) d\mathbb{P}_Y(y). \end{aligned}$$

Además, si X e Y son absolutamente continuas,

$$\begin{aligned} F_{X+Y}(z) &= \int \int \mathbf{1}_{(-\infty, z]}(x+y) d\mathbb{P}_X(x) d\mathbb{P}_Y(y) \\ &= \int \int \mathbf{1}_{(-\infty, z]}(x+y) f_X(x) f_Y(y) dx dy \\ (x' = x+y) &= \int \int \mathbf{1}_{(-\infty, z]}(x') f_X(x'-y) f_Y(y) dx' dy \\ &= \int \mathbf{1}_{(-\infty, z]}(x') \left(\int f_X(x'-y) f_Y(y) dy \right) dx' \\ &= \int_{-\infty}^z f_X * f_Y(x') dx'. \end{aligned} \quad \square$$

Clase 6

18 de Marzo

1.11 Ley 0-1 de Kolmogorov

Dada una sucesión $(X_n)_{n \in \mathbb{N}}$ de variables aleatorias independientes, definimos la σ -álgebra *cola* asociada a $(X_n)_{n \in \mathbb{N}}$ como

$$\mathcal{T} = \bigcap_{n \in \mathbb{N}} \sigma(X_i : i \geq n).$$

Los eventos en $\mathcal{T}$ se llaman *eventos cola*.

La idea es que un evento cola queda determinado únicamente por el comportamiento de la cola de la sucesión $(X_n)_{n \in \mathbb{N}}$.

Ejemplo. Los siguientes son eventos cola:

- i) $A = \{ \lim_{n \rightarrow \infty} X_n = 5 \}$.
- ii) $B = \{ (X_n)_{n \in \mathbb{N}} \text{ es de Cauchy} \}$.
- iii) $C = \{ (X_n)_{n \in \mathbb{N}} \text{ es acotada} \}$ (si cada X_n toma valores reales y no pueden valer $\pm\infty$).

Para eventos cola de $(X_n)_{n \in \mathbb{N}}$ independientes, tenemos:

Teorema 1.41 (Ley 0-1 de Kolmogorov). Si $(X_n)_{n \in \mathbb{N}}$ son independientes y $A \in \mathcal{T}$ es un evento cola, entonces $\mathbb{P}(A) = 0$ ó $\mathbb{P}(A) = 1$.

Demostración. Sean $\mathcal{F}_n = \sigma(X_i : 1 \leq i \leq n)$ y $\mathcal{G}_n = \sigma(X_i : i > n)$. Observar que si para $I \subseteq \mathbb{N}$ definimos

$$\mathcal{P}_I = \left\{ \bigcap_{j \in J} \{X_j \in B_j\} : B_j \in \beta(\mathbb{R}), J \subseteq I \text{ finito} \right\},$$

entonces:

- $\mathcal{P}_I$ es un π -sistema.
- $\sigma(\mathcal{P}_I) = \sigma(X_i : i \in I)$.
- si $I \cap I' = \emptyset$ entonces $\mathcal{P}_I$ y $\mathcal{P}_{I'}$ son independientes.

Se sigue del teorema visto la clase pasada que si $I \cap I' = \emptyset$, entonces $\sigma(\mathcal{P}_I)$ y $\sigma(\mathcal{P}_{I'})$ también lo son.

En particular, $\mathcal{F}_n = \sigma(\mathcal{P}_{\{1, \dots, n\}})$ y $\mathcal{G}_n = \sigma(\mathcal{P}_{\{n, n+1, \dots\}})$ son independientes para todo n . Luego, $\mathcal{G}_\infty$ es independiente de $\mathcal{F}_n$ para todo $n \in \mathbb{N}$.

En particular, $\mathcal{G}_\infty$ es independiente de $\bigcup_{n \in \mathbb{N}} \mathcal{F}_n$ y, como $\bigcup_{n \in \mathbb{N}} \mathcal{F}_n$ es un π -sistema, por el mismo Teorema $\mathcal{G}_\infty$ es independiente de $\sigma(\bigcup_{n \in \mathbb{N}} \mathcal{F}_n) = \mathcal{F}_\infty$.

Luego, si $A \in \mathcal{G}_\infty$, entonces

$$\mathbb{P}(A) = \mathbb{P}\left(\underbrace{A}_{\in \mathcal{G}_\infty} \cap \underbrace{A}_{\in \mathcal{F}_\infty}\right) = \mathbb{P}(A)\mathbb{P}(A)$$

y, por ende, $\mathbb{P}(A) \in \{0, 1\}$. □

1.12 Lemas de Borel-Cantelli

Definición 1.42. Dada una sucesión $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{F}$ de eventos, definimos el evento

$$\begin{aligned} \limsup_{n \rightarrow \infty} A_n &:= \{\text{ocurren infinitos } A_n\} \\ &= \{\omega \in \Omega : \omega \in A_n \text{ para infinitos } n\} \\ &= \bigcap_{N \in \mathbb{N}} \bigcup_{n=N}^{\infty} A_n. \end{aligned}$$

Notar que $\limsup A_n \in \mathcal{F}$. De hecho, se tiene que $\mathbf{1}_{\limsup A_n} = \limsup_{n \rightarrow \infty} \mathbf{1}_{A_n}$ (y por este motivo se llama $\limsup A_n$).

Lema 1.43 (Borel-Cantelli). Sea $(A_n)_{n \in \mathbb{N}}$ una sucesión de eventos. Entonces:

I) Si $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) < \infty$ entonces

$$\mathbb{P}(\text{ocurren infinitos } A_n) = 0.$$

II) Si $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n) = \infty$ y $(A_n)_{n \in \mathbb{N}}$ son independientes, entonces

$$\mathbb{P}(\text{ocurren infinitos } A_n) = 1.$$

Observación. El evento $\{\text{Ocurren infinitos } A_n\}$ es un evento cola para $(\mathbb{1}_{A_n})_{n \in \mathbb{N}}$. En efecto, esto se sigue del hecho que $\mathbb{1}_{\{\text{Ocurren } \infty's A_n\}} = \limsup_{n \rightarrow \infty} \mathbb{1}_{A_n}$. Luego, por la Ley 0-1 de Kolmogorov, si los $(A_n)_{n \in \mathbb{N}}$ son independientes, tenemos que $\mathbb{P}(\text{Ocurren } \infty's A_n) \in \{0, 1\}$.

El lema de Borel Cantelli caracteriza cuando vale 0 ó 1 en términos de $\sum_{n \in \mathbb{N}} \mathbb{P}(A_n)$.

Nota. La hipótesis de independencia en BC-II es **necesaria**. En efecto, si tomamos $A \in \mathcal{F}$ como $\mathbb{P}(A) \in (0, 1)$ y definimos $A_n := A \quad \forall n$, entonces

$$\limsup_{n \rightarrow \infty} A_n = A$$

y, por lo tanto,

$$\mathbb{P}(\text{Ocurren } \infty's A_n) = \mathbb{P}(A) \in (0, 1).$$

Demostración (Lemas de Borel-Cantelli). I. Si definimos $N := \sum_{n \in \mathbb{N}} \mathbb{1}_{A_n}$ entonces, por el Teorema de Convergencia Monótona,

$$\mathbb{E}(N) = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n) < \infty.$$

En particular,

$$\mathbb{P}(\text{Ocurren } \infty's A_n) = \mathbb{P}(N = \infty) = 0.$$

II. Basta con probar que $\mathbb{P}(\text{Ocurren finitos } A_n) = 0$. Pero,

$$\{\text{Ocurren finitos } A_n\} = (\limsup_{n \rightarrow \infty} A_n)^c = \bigcup_{N \in \mathbb{N}} \bigcap_{m \geq N} A_m^c,$$

con lo cual bastará con ver que $\mathbb{P}(\bigcap_{m \geq N} A_m^c) = 0$ para todo $N \in \mathbb{N}$. Por continuidad superior de $\mathbb{P}$,

$$\mathbb{P}\left(\bigcap_{m \geq N} A_m^c\right) = \lim_{k \rightarrow \infty} \mathbb{P}\left(\bigcap_{m=N}^k A_m^c\right).$$

Pero,

$$\begin{aligned}\mathbb{P}\left(\bigcap_{m=N}^k A_m^c\right) &= \prod_{m=N}^k \mathbb{P}(A_m^c) \\ &= \prod_{m=N}^k (1 - \mathbb{P}(A_m)) \\ &\leq e^{-\sum_{m=N}^k \mathbb{P}(A_m)} \xrightarrow{k \rightarrow \infty} 0,\end{aligned}$$

si $\sum_{m \in \mathbb{N}} \mathbb{P}(A_m) = \infty$. (notar que la primera igualdad está dada pues los A_m^c son independientes, pues los $\mathbb{1}_{A_n}$ son independientes, y que la desigualdad está dada por $1 - x \leq e^{-x} \quad \forall x \in \mathbb{R}$.) $\square$

Observación. El argumento de arriba muestra, en particular, que si $(B_n)_{n \in \mathbb{N}}$ son independientes, entonces

$$\mathbb{P}\left(\bigcap_{n \in \mathbb{N}} B_n\right) = \prod_{n \in \mathbb{N}} \mathbb{P}(B_n).$$

1.13 Existencia de sucesiones independientes

¿Existe realmente una sucesión $(X_n)_{n \in \mathbb{N}}$ de variables aleatorias independientes? (o, equivalentemente, de eventos $(A_n)_{n \in \mathbb{N}}$ independientes?).

Es decir, ¿existe un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ y una sucesión $(X_n)_{n \in \mathbb{N}}$ de variables aleatorias definidas sobre $(\Omega, \mathcal{F})$ tal que las $(X_n)_{n \in \mathbb{N}}$ sean independientes bajo $\mathbb{P}$?

Ejemplo. Basta considerar el caso en que las X_n son uniformes en $(0, 1)$; a partir de allí podemos cubrir cualquier otro caso.

- ¿Cómo construimos una variable $U \sim \text{Uniforme}(0, 1)$? Como $\mathbb{P} = \mathcal{L}|_{[0,1]}$, construir U es equivalente a construir la medida de Lebesgue en $[0, 1]$.
- ¿Cómo conseguimos $U_1, \dots, U_n$ independientes con distribución $U_i \sim \mathcal{U}([0, 1])$? Por el teorema anterior,

$$\mathbb{P}_{U_1, \dots, U_n} = \mathbb{P}_{U_1} \times \dots \times \mathbb{P}_{U_n} = \mathcal{L}|_{[0,1]} \times \dots \times \mathcal{L}|_{[0,1]} = \mathcal{L}|_{[0,1]^n}.$$

Por lo tanto, construir $(U_1, \dots, U_n)$ es equivalente a construir $\mathcal{L}|_{[0,1]^n}$. Siguiendo esta lógica, construir $(U_n)_{n \in \mathbb{N}}$ independientes con $U_n \sim \mathcal{U}([0, 1])$ es equivalente a construir la medida de Lebesgue en el cubo unitario infinito-dimensional $[0, 1]^{\mathbb{N}}$. Esto no es para nada trivial, pero puede hacerse. Lo haremos de dos formas:

1. **Forma canónica:** construiremos $\text{leb}_{[0,1]^n}$ con el teorema de Carathéodory. (No ahora.)
2. **Forma constructiva:** construiremos $(U_n)_{n \in \mathbb{N}}$ en $([0, 1], \beta([0, 1]), \mathcal{L}|_{[0,1]})$. Ejercicio Práctica 2.

Chapter 2

Procesos Estocásticos (Notas de Anton Bovier)

Clase 7

23 de Marzo

Definición 2.1. Dados:

- Un EdP $(\Omega, \mathcal{F}, \mathbb{P})$;
- Un esp. medible (S, β) (típicamente, S métrico y separable y $\beta = \sigma$ -álgebra de Borel);
- Un conjunto de índices I no vacío;

diremos que un *proceso estocástico con espacio de estados S indexado en I* es cualquier colección $(X_t)_{t \in I}$ de elementos aleatorios en (S, β) , todos definidos en el mismo EdP $(\Omega, \mathcal{F}, \mathbb{P})$.

Nota. • A veces se reserva el término "proceso estocástico" al caso en que $I = \mathbb{N}, \mathbb{Z}, \mathbb{R}_+$ ó $\mathbb{R}$. En estos casos, $t \in I$ es un *parámetro temporal* y hablamos de procesos a *tiempo discreto* o *continuo* dependiendo de si I lo es.

- Si $I = \mathbb{Z}^d, \mathbb{R}^d, G$ (grafo), hablamos de *campos estocásticos*.
- Para que $(X_t)_{t \in I}$ sea un PE, necesito que cada X_t sea $\mathcal{F}$ -medible. En particular, $\sigma(X_t : t \in I) \subseteq \mathcal{F}$.

2.1 Perspectiva Trayectorial

En lugar de pensar que para cada $t \in I$ tenemos $X_t: \Omega \rightarrow S$ tal que $\omega \mapsto X_t(\omega)$, podemos pensar que para cada $\omega \in \Omega$ tenemos $X(\omega): I \rightarrow S$ tal que $t \mapsto X_t(\omega)$. Llamamos a $X(\omega)$ una *trayectoria* o *realización* de $X = (X_t)_{t \in I}$.

Si ahora, variamos $\omega \in \Omega$, obtenemos una *trayectoria aleatoria*, i.e. podemos ver a $(X_t)_{t \in I}$ como un elemento aleatorio a valores en el espacio S^I de funciones. Es decir, $X: \Omega \rightarrow S^I$ tal que $\omega \mapsto X(\omega)$. Lo que nos gustaría es que X sea $\mathcal{F}$ -medible. Para esto, necesitamos una σ -álgebra $\mathcal{G}$ en S^I .

Condición: Vamos a querer que $\mathcal{G}$ sea tal que si $X: \Omega \rightarrow S^I$ es $(\mathcal{F}, \mathcal{G})$ -medible $\Rightarrow X_t: \Omega \rightarrow S$ $(\mathcal{F}, \beta)$ -medible para todo $t \in I$.

Pero $X_t = \pi_t \circ X$, donde $\pi_t: S^I \rightarrow S$ tal que $(x_i)_{i \in I} \mapsto x_t$ es la *proyección* en t . Esto será cierto si $\mathcal{G}$ es tal que π_t es $(\mathcal{G}, \beta)$ -medible $\forall t \in I$.

Lema 2.2. Sea $\beta^I := \bigtimes_{i \in I} \beta$ (esto no es producto cartesiano, sino producto de σ -álgebras) la menor σ -álgebra en S^I que contiene a los conjuntos de la forma

$$C(t, B) := \{(x_i)_{i \in I} \in S^I : x_t \in B\} \quad (= \pi_t^{-1}(B))$$

con $t \in I$, $B \in \beta$. Entonces, β^I es la menor σ -álgebra en S^I que hace que π_t sea β -medible $\forall t \in I$.

A su vez, $\sigma(X_t : t \in I)$ es la menor σ -álgebra tal que $X: \Omega \rightarrow S^I$ resulta β^I -medible

Corolario 2.3. La aplicación $X: \Omega \rightarrow S^I$ es $(\mathcal{F}, \beta^I)$ -medible si y solo si $X_t: \Omega \rightarrow S$ es $(\mathcal{F}, \beta)$ -medible $\forall t \in I$. Es decir, β^I es **exactamente** la σ -álgebra $\mathcal{G}$ que necesitamos poner en S^I para que ambas "definiciones" de PE sean **equivalentes**.

Demostración (Corolario). $\boxed{\Rightarrow}$ $X_t = \pi_t \circ X$ es medible por ser composición de medibles (π_t es medible por el Lema).

$\boxed{\Leftarrow}$ X_t es $\mathcal{F}$ -medible $\forall t \in I \Rightarrow \sigma(X_t : t \in I) \subseteq \mathcal{F} \Rightarrow X$ es $(\mathcal{F}, \beta^I)$ -medible (por el Lema). $\square$

Demostración (Lema). 1. Observar que $C(t, B) = \pi_t^{-1}(B) \quad \forall t \in I, B \in \beta$. Luego,

$$\begin{aligned} \sigma(\pi_t : t \in I) &= \sigma(\pi_t^{-1}(B) : B \in \beta, t \in I) \\ &= \sigma(C(t, B) : B \in \beta, t \in I) = \beta^I \end{aligned}$$

y esto implica la primera afirmación.

2. Sea $\mathcal{G} \subseteq \mathcal{F}$ una σ -álgebra.

$$\begin{aligned} X \text{ es } (\mathcal{G}, \beta^I)\text{-medible} &\Leftrightarrow X^{-1}(C(t, B)) \in \mathcal{G} \quad \forall t \in I, B \in \beta \\ (C(t, B) = \pi_t^{-1}(B)) &\Leftrightarrow X^{-1}(\pi_t^{-1}(B)) \in \mathcal{G} \quad \forall t \in I, B \in \beta \\ &\Leftrightarrow (\pi_t \circ X)^{-1}(B) \in \mathcal{G} \quad \forall t \in I, B \in \beta \\ &\Leftrightarrow X_t \text{ es } (\mathcal{G}, \beta)\text{-medible } \forall t \in I \\ &\Leftrightarrow \sigma(X_t : t \in I) \subseteq \mathcal{G}. \end{aligned}$$

Luego, vale la segunda afirmación. $\square$

Nota. Llamaremos a β^I la σ -álgebra producto en S^I .

Definición 2.4. Si $J \subseteq I$ es finito y no vacío, dado $B \in \beta^J$ (σ -álgebra producto en S^J , decimos que el conjunto

$$C(J, B) := \{(x_i)_{i \in I} \in S^I : (x_j)_{j \in J} \in B\} \quad (" = B \times S^{I-J} ")$$

es un *cilindro finito-dimensional* (de dimensión $n = |J|$).

Si B es de la forma $B = \times_{j \in J} B_j$ con $B_j \in \beta$, entonces $C(J, B) = \bigcap_{j \in J} C(j, B_j)$ se dice un *cilindro especial*.

Clase 8

25 de Marzo

Dados I conjunto de índices no vacío, (S^I, β^I) y (S, β) espacios medibles, sea $J \subseteq I$ finito y no vacío. Luego,

- Cilindro finito-dimensional:

$$C(J, B) = \{(x_i)_{i \in I} \in S^I : (x_j)_{j \in J} \in B\} \quad (B \in \beta).$$

- Cilindro especial:

$$C\left(J, \times_{j \in J} B_j\right) = \bigcap_{j \in J} C(j, B_j).$$

- $\beta^I = \sigma(C(i, B) : i \in I, B \in \beta)$.

Observación. 1. Los cilindros especiales forman un π -sistema (si I es finito, son la clase de rectángulos en $S^{|I|}$).

2. Los cilindros finito-dimensionales forman un álgebra.

3. Ambas clases generan a β^I .

Dado un PE $(X_t)_{t \in I}$, vimos que podemos verlo como elemento aleatorio X en (S^I, β^I) . Luego, definimos la *distribución del proceso* como aquella medida de probabilidad $\mathbb{P}_X$ inducida por el elemento aleatorio X sobre (S^I, β^I) .

Tener en cuenta que, dado un proceso estocástico con distribución μ sobre (S^I, β^I) , siempre podemos construir una versión del proceso en el EdP (S^I, β^I, μ) , tomando como X a la identidad; i.e. $X: S^I \rightarrow S^I$ tal que $x \mapsto X(x) = x$. Este X se conoce como la *versión canónica* del PE con distribución μ (o, simplemente, *proceso canónico*).

Observación. Si S es un espacio topológico y β es su σ -álgebra de Borel, también podemos considerar en S^I a $\beta(S^I)$, la σ -álgebra generada por los abiertos en S^I con la *topología producto*.

Pregunta. ¿Es cierto que $\beta(S^I) = \beta^I$?

Respuesta. En general, NO. Aunque siempre se tiene que $\beta^I \subseteq \beta(S^I)$. Si $\tau(S^I)$ admite una base numerable e I a lo sumo numerable, entonces SI (por ejemplo, $S^I = \mathbb{R}^{\mathbb{N}}$).

2.1.1 Construcción de medidas en S^I

Sea $I \neq \emptyset$ un conjunto de índices. Definimos

$$\mathbb{F}(I) := \{J \subseteq I : J \text{ finito y no vacío}\}.$$

Dados $J_1 \subseteq J_2 \subseteq I$, definimos la proyección $\pi_{J_2 \rightarrow J_1} : S^{J_2} \rightarrow S^{J_1}$ como

$$\pi_{J_2 \rightarrow J_1}((x_j)_{j \in J_2}) := (x_j)_{j \in J_1}.$$

En el caso en que $J_2 = I$, abreviamos $\pi_{J_1} := \pi_{I \rightarrow J_1}$.

Dada una medida μ sobre (S^I, β^I) , definimos para $J \in \mathbb{F}(I)$ la medida μ_J sobre (S^J, β^J) por la fórmula

$$\mu_J(A) := \pi_J \mu(A) := \mu(\pi_J^{-1}(A)) = \mu(\underbrace{C(J, A)}_{"A \times S^{I-J}"}).$$

Llamaremos a la colección $\mathbb{F}(\mu) := \{\mu_J : J \in \mathbb{F}(I)\}$ la *colección de distribuciones finito-dimensionales de μ* .

Como ejemplo, notemos que si

$$\mu = \mathbb{P}_{(U_n)_{n \in \mathbb{N}}} = \prod_{n \in \mathbb{N}} \mathcal{L}|_{[0,1]}$$

entonces,

$$\mathbb{F}(\mu) = \{\mathcal{L}|_{[0,1]^{|J|}} : J \in \mathbb{F}(I)\}.$$

Teorema 2.5 (Extensión de Kolmogorov-Daniell). Sea $I \neq \emptyset$ un conjunto de índices. Sea S un espacio métrico completo y separable con β su σ -álgebra de Borel. Supongamos que tenemos una familia $\mathcal{C} = \{\mu_J : J \in \mathbb{F}(I)\}$ tal que:

- i) para cada $j \in J$, μ_J es una medida de probabilidad en (S^J, β^J) ;
- ii) $\mathcal{C}$ es *consistente*; i.e. si $J_1, J_2 \in \mathbb{F}(I)$ son tal que $J_1 \subseteq J_2$, entonces $\pi_{J_2 \rightarrow J_1} \mu_{J_2} = \mu_{J_1}$ (i.e. $\mu_{J_2}(A \times S^{J_2-J_1}) = \mu_{J_1}(A) \quad \forall A \in \beta^{J_1}$).

Entonces, existe una única medida μ sobre (S^I, β^I) tal que $\pi_J \mu = \mu_J \quad \forall J \in \mathbb{F}(I)$; i.e. $\mathcal{C} = \mathbb{F}(\mu)$.

Demostración (Idea). Sea $\mathcal{A}$ el álgebra de cilindros finito-dimensionales de S^I . Definimos $\mu : \mathcal{A} \rightarrow [0, 1]$ por $\mu(C(J, B)) := \mu_J(B)$. Usando la consistencia, se puede ver que μ está bien definida.

Luego, si demostramos que μ es σ -aditiva en $\mathcal{A}$, por Carathéodory se puede extender a todo $\sigma(\mathcal{A}) = \beta^I$. Esto prueba la existencia.

Por otro lado, como $\mathcal{A}$ es un π -sistema que genera β^I , $\mathbb{F}(\mu_1) = \mathbb{F}(\mu_2) \Rightarrow \mu_1, \mu_2$ coinciden en $\mathcal{A} \Rightarrow \mu_1 = \mu_2$ (esto último por Dynkin). $\square$

Corolario 2.6. Sea S espacio métrico completo y separable, con β su σ -álgebra de Borel. Supongamos que tenemos una familia $\mathcal{C} = \{P_n : n \in \mathbb{N}\}$ tal que

- i) P_n es una medida en $(S^n, \beta^n := \beta \times \cdots \times \beta)$ para cada $n \in \mathbb{N}$;
- ii) $\mathcal{C}$ es *consistente*; i.e. $\pi_{\{1, \dots, n+1\} \rightarrow \{1, \dots, n\}} P_{n+1} = P_n \quad \forall n \in \mathbb{N}$.

Entonces, existe una única medida $\mathbb{P}$ en $(S^{\mathbb{N}}, \beta^{\mathbb{N}})$ tal que $\pi_{\{1, \dots, n\}} \mathbb{P} = P_n \quad \forall n \in \mathbb{N}$.

Clase 9

30 de Marzo

Teorema 2.7. Sea I un conjunto de índices no vacío y sean $(\mu_t)_{t \in I}$ un colección de probabilidades sobre (S, β) con S un espacio métrico completo y separable, y β su σ -álgebra de Borel. Entonces, existe una *única* medida de probabilidades μ en (S^I, β^I) tal que para todo $J \in \mathbb{F}(I)$ y $\bigtimes_{j \in J} B_j \in \beta^J$ vale que

$$\mu \left(C \left(J, \bigtimes_{j \in J} B_j \right) \right) = \prod_{j \in J} \mu_j(B_j).$$

En particular, en (S^I, β^I, μ) , las proyecciones $(\pi_t)_{t \in I}$ son variables aleatorias independientes, cada π_t con distribución μ_t . Decimos que

$$\mu = \bigtimes_{t \in I} \mu_t = \prod_{t \in I} \mu_t$$

es la *medida producto* de $(\mu_t)_{t \in I}$.

Demostración. Dado $J \in \mathbb{F}(I)$, sea $\mu^{(J)} := \bigtimes_{j \in J} \mu_j$, la medida producto sobre (S^J, β^J) . Sea $\mathcal{C} := \{\mu^{(J)} : J \in \mathbb{F}(I)\}$.

Notar que:

- (i) $\mu^{(J)}$ es una medida de probabilidad en (S^J, β^J) para cada $J \in \mathbb{F}(I)$;

(ii) $\mathcal{C}$ es consistente: Si $J_1 \subseteq J_2$, $J_1, J_2 \in \mathbb{F}(I)$ y $(B_j)_{j \in J_1} \subseteq \beta$, entonces

$$\begin{aligned}
 \left(\pi_{J_2 \rightarrow J_1} \mu^{(J_2)} \right) \left(\bigtimes_{j \in J_1} B_j \right) &:= \mu^{(J_2)} \left(\pi_{J_2 \rightarrow J_1}^{-1} \left(\bigtimes_{j \in J_1} B_j \right) \right) \\
 &= \mu^{(J_2)} \left(\left(\bigtimes_{j \in J_1} B_j \right) \times S^{J_2 - J_1} \right) \\
 &= \left(\prod_{j \in J_1} \mu_j(B_j) \right) \left(\prod_{j \in J_2 - J_1} \underbrace{\mu_j(S)}_{=1} \right) \\
 &= \prod_{j \in J_1} \mu_j(B_j) \\
 &= \mu^{(J_1)} \left(\bigtimes_{j \in J_1} B_j \right).
 \end{aligned}$$

Como los conjuntos de la forma $\bigtimes_{j \in J_1} B_j$ generan β^{J_1} y son un π -sistema (que contiene a S^J), resulta que $\pi_{J_2 \rightarrow J_1} \mu^{(J_2)} = \mu^{(J_1)}$ (i.e $\mathcal{C}$ es consistente).

Por el Teorema de extensión de Kolmogorov, existe una única medida μ sobre (S^I, β^I) tal que $\pi_J \mu = \mu^{(J)}$ para todo $J \in \mathbb{F}(I)$.

En particular,

$$\begin{aligned}
 \mu \left(C \left(J, \bigtimes_{j \in J} B_j \right) \right) &= \pi_J \mu \left(\bigtimes_{j \in J} B_j \right) \\
 &= \mu^{(J)} \left(\bigtimes_{j \in J} B_j \right) \\
 &= \prod_{j \in J} \mu_j(B_j), \tag{*}
 \end{aligned}$$

para todo $J \in \mathbb{F}(I)$ y $(B_j)_{j \in J} \subseteq \beta$.

Por último, como los cilindros especiales del tipo $C(J, \bigtimes_{j \in J} B_j)$ son un π -sistema que genera β^I , μ es la única medida que cumple (*).

La afirmación sobre las proyecciones $(\pi_t)_{t \in I}$ es un Ej. de la práctica 2. $\square$

Nota. Hasta acá la I1. Además, hasta acá con las notas de Anton Bovier (volver al Durrett).

Repasemos las formas de convergencia conocidas:

1. **Convergencia en probabilidad:** $X_n \xrightarrow{\mathbb{P}} X$ si para todo $\varepsilon > 0$ vale que

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

2. **Convergencia casi segura:** $X_n \xrightarrow[(a.s.)]{c.s.} X$ casi seguramente, i.e

$$\mathbb{P}(\{\omega : X_n(\omega) \not\rightarrow X(\omega)\}) = 0.$$

3. **Convergencia en L^p :** $X_n \xrightarrow{L^p} X$ si

$$\|X_n - X\|_p := (\mathbb{E}(|X_n - X|^p))^{1/p} \xrightarrow{n \rightarrow \infty} 0, \quad (p \in [1, \infty)).$$

Similarmente, $X_n \xrightarrow{L^\infty} X$ si

$$\|X_n - X\|_\infty \rightarrow 0.$$

Proposición 2.8. Valen las siguientes propiedades:

1. Se cumple

$$X_n \xrightarrow{c.s.} X \Leftrightarrow \mathbb{P}(|X_n - X| > \varepsilon \text{ i.o.}) = 0 \quad \forall \varepsilon > 0$$

($\Leftrightarrow \forall \varepsilon > 0, \lim_{n \rightarrow \infty} \mathbb{P}(\bigcup_{i \geq n} \{|X_i - X| > \varepsilon\}) = 0$). Donde i.o quiere decir "infinitely often" y

$$|X_n - X| > \varepsilon \text{ i.o.} = \limsup_{n \rightarrow \infty} \{|X_n - X| > \varepsilon\}.$$

2. $\sum_{n \in \mathbb{N}} \mathbb{P}(|X_n - X| > \varepsilon) < \infty \quad \forall \varepsilon > 0 \Rightarrow X_n \xrightarrow{c.s.} X$.

3. $X_n \xrightarrow{\mathbb{P}} X \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k \in \mathbb{N}}$ admite ella misma una subsucesión $(X_{n_{k_j}})_{j \in \mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow{c.s.} X \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k \in \mathbb{N}}$ admite ella misma una subsucesión $(X_{n_{k_j}})_{j \in \mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow{\mathbb{P}} X$.

4. **Desigualdad de Tchebychev:** si f es creciente, entonces $f(\delta)\mathbb{P}(X \geq \delta) \leq \mathbb{E}(f(X)\mathbb{1}_{\{X \geq \delta\}})$. En particular, si $f(\delta) > 0$, entonces $\mathbb{P}(X \geq \delta) \leq \mathbb{E}(f(X)\mathbb{1}_{\{X \geq \delta\}})$.

5. **Desigualdad de Jensen:** Si φ es convexa y $\mathbb{E}(|X|), \mathbb{E}(|\varphi(X)|) < \infty$, entonces $\varphi(\mathbb{E}(X)) \leq \mathbb{E}(\varphi(X))$. En particular, si $p \leq q$, entonces $\|X\|_p \leq \|X\|_q$ ($L^q \subseteq L^p$).

En particular, se tiene que:

- i) $X_n \xrightarrow{c.s.} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{L^p} X$.
- ii) $X_n \xrightarrow{L^p} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{L^q} X$.
- iii) $X_n \xrightarrow{L^q} X \Rightarrow X_n \xrightarrow{L^p} X \quad \forall 1 \leq p \leq q$.

Definición 2.9. Dada una V.A y $p > 0$, a la cantidad $\mathbb{E}(X^p)$ (si está bien definida) se la llama el p -ésimo momento de X .

Observar. Si X tiene q -ésimo momento finito entonces también tiene p -ésimo momento finito para todo $1 \leq p \leq q$.

Definición 2.10. Dada una V.A X con $\mathbb{E}(X^2) < \infty$, definimos su *varianza* como $\text{Var}(X) := \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \in [0, \infty)$.

Definición 2.11. Dadas V.A's X e Y definidas en el mismo EdP con $\mathbb{E}(X^2), \mathbb{E}(Y^2) < \infty$, definimos su *covarianza* como

$$\text{Cov}(X, Y) := \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Nota. $\text{Var}(X) = \text{Cov}(X, X)$.

Definición 2.12. Una colección $(X_i)_{i \in I}$ de V.A's se dicen *no correlacionadas* si $\text{Cov}(X_i, X_j) = 0 \quad \forall i \neq j, i, j \in I$.

Definición 2.13. Una colección $(X_i)_{i \in I}$ de V.A's se dicen *i.i.d* si son *independientes e idénticamente distribuidas*; i.e $X_i \stackrel{d}{=} X_j \quad \forall i, j \in I$.

Observar. $(X_i)_{i \in I}$ independientes + $\mathbb{E}(X_j^2) < \infty \quad \forall i \in I \Rightarrow (X_i)_{i \in I}$ no correlacionadas (la otra dirección no vale).

Chapter 3

Leyes de los grandes números

Clase 10

1 de Abril

Definición 3.1. Diremos que una sucesión $(X_n)_{n \in \mathbb{N}}$ de VA's definidas en un mismo EdP satisface una *ley de los grandes números* si existen constantes $(a_n)_{n \in \mathbb{N}}, (b_n)_{n \in \mathbb{N}} \subseteq \mathbb{R}$ tales que

$$\frac{\left(\sum_{i=1}^n X_i - a_n\right)}{b_n} \xrightarrow{(*)} 0,$$

donde la convergencia en $(*)$ es en algún sentido apropiado.

- Si la convergencia en $(*)$ es en probabilidad, decimos que la ley es *débil*.
- Si la convergencia en $(*)$ es casi segura, decimos que la ley es *fuerte*.

Nota. Vamos a empezar a estudiar la validez de LGN's en distintos contextos. De ahora en más, $S_0 := 0$, $S_n := X_1 + \cdots + X_n$.

Teorema 3.2. Si $(X_n)_{n \in \mathbb{N}}$ son VA's *no correlacionadas* tal que

$$\begin{cases} \mathbb{E}(X_n) =: \mu \\ \text{Var}(X_n) \leq c < \infty \quad \forall n \in \mathbb{N}, \end{cases}$$

entonces $\frac{S_n}{n} \xrightarrow[L^2]{\mathbb{P}} \mu$.

Demostración. Basta con ver la convergencia en L^2 . En efecto, observemos

que:

$$\begin{aligned}\mathbb{E}\left(\frac{S_n}{n}\right) &= \frac{1}{n}\mathbb{E}(S_n) \\ &= \frac{1}{n}\left(\sum_{i=1}^n \mathbb{E}(X_i)\right) \\ &= \frac{1}{n}n\mu = \mu.\end{aligned}$$

y

$$\begin{aligned}\left\|\frac{S_n}{n} - \mu\right\|_2^2 &= \mathbb{E}\left(\left(\frac{S_n}{n} - \mu\right)^2\right) \\ &= \text{Var}\left(\frac{S_n}{n}\right) \\ &= \frac{1}{n^2} \text{Var}(S_n) \\ &\leq \frac{1}{n^2}cn = \frac{c}{n} \rightarrow 0.\end{aligned}$$

Notar que se utilizó:

$$\begin{aligned}\text{Var}(S_n) &= \text{Cov}(S_n, S_n) = \text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\ &= \sum_{i,j=1}^n \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \text{Var}(X_i) \leq cn. \quad \square\end{aligned}$$

Observación. 1. Si $(X_n)_{n \in \mathbb{N}}$ son NC, entonces $\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n)$.

2. Que convergencia en L^2 implique convergencia en $\mathbb{P}$ se deduce de la siguiente desigualdad:

$$\mathbb{P}(|X - \mathbb{E}(X)| > \delta) \leq \frac{\mathbb{E}(|X - \mathbb{E}(X)|^2)}{\delta^2} = \frac{\text{Var}(X)}{\delta^2}.$$

Nota. A la desigualdad

$$\mathbb{P}(|X - \mathbb{E}(X)| > \delta) \leq \frac{\text{Var}(X)}{\delta^2}$$

se la llama Desigualdad de Tchebychev, y a la

$$\mathbb{P}(|X| > \delta) \leq \frac{\mathbb{E}(X)}{\delta}$$

se la llama desigualdad de Markov.

Nota. Las hipótesis sobre los momentos de $(X_n)_{n \in \mathbb{N}}$ se puede relajar mediante *truncamientos* de las variables; i.e, cambiar X_n por $\tilde{X}_n = X_n \mathbb{1}_{|X_n| \leq b_n}$.

Teorema 3.3. Sean $(X_n)_{n \in \mathbb{N}}$ VA's i.i.d. Entonces, existe $(a_n)_{n \in \mathbb{N}} \subseteq \mathbb{R}$ tal que

$$\frac{S_n}{n} - a_n \xrightarrow{\mathbb{P}} 0$$

si y solo si

$$\lim_{x \rightarrow \infty} x \mathbb{P}(|X_1| > x) = 0.$$

Además, en tal caso se puede tomar

$$a_n := \mathbb{E}(X_n \mathbb{1}_{|X_n| \leq n}).$$

Demostración. Ver Durrett. □

Observación. Se cumple que $\mathbb{E}(|X|) < \infty \Rightarrow \lim_{x \rightarrow \infty} x \mathbb{P}(|X| > x) = 0$. Eso sí, el converso no vale. Además, esto último implica que $\mathbb{E}(|X|^{1-\varepsilon}) < \infty \quad \forall \varepsilon > 0$.

Para ver la primera implicancia, notar que (por Tchebychev)

$$x \mathbb{P}(|X| > x) \leq \mathbb{E}(|X| \mathbb{1}_{|X| > x}).$$

Para ver la última implicancia, recordar que

$$\mathbb{E}(|X|^p) = \int_0^\infty p|x|^{p-1} \mathbb{P}(X > x) dx.$$

Corolario 3.4 (LA Ley débil de los grandes números). Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d con $\mathbb{E}(|X_n|) < \infty$ y $\mu := \mathbb{E}(X_n)$, entonces $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$.

Demostración. Por el Teorema anterior, $\frac{S_n}{n} - a_n \xrightarrow{\mathbb{P}} 0$. Luego, basta ver que $a_n \xrightarrow{n \rightarrow \infty} \mu$. Pero,

$$\begin{aligned} a_n &:= \mathbb{E}(X_n \mathbb{1}_{|X_n| \leq n}) = \mathbb{E}(f_n(X_n)) \\ &= \mathbb{E}(f_n(X_1)) \\ &= \mathbb{E}(\underbrace{X_1 \mathbb{1}_{|X_1| \leq n}}_{|\cdot| \leq |X_1|}) \longrightarrow \mathbb{E}(X_1) = \mu, \end{aligned}$$

donde la convergencia está dada por Teorema de Convergencia Dominada. □

Teorema 3.5 (LA Ley fuerte de los grandes números). Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d con primer momento finito y $\mu := \mathbb{E}(X_n)$, entonces

$$\frac{S_n}{n} \xrightarrow{c.s.} \mu.$$

Observación. La hipótesis de independencia se puede rebajar al menos de 2 formas:

- i) Basta que las $(X_n)_{n \in \mathbb{N}}$ sean independientes 2 a 2 (demostración de Etenadi, ver Durrett).
- ii) Basta que las $(X_n)_{n \in \mathbb{N}}$ tengan una σ -álgebra cola trivial (todos los elementos tienen probabilidad 0 o 1) y que $(X_n)_{n \in \mathbb{N}}$ sea *estacionario*, i.e $(X_n)_{n \in \mathbb{N}} \stackrel{d}{=} (X_{n+k})_{n \in \mathbb{N}} \quad \forall k \in \mathbb{N}$.

A diferencia de la ley débil, para la ley fuerte es necesario el primer momento finito.

Teorema 3.6. Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d con $\mathbb{E}(|X_n|) = \infty$, entonces

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} \in (-\infty, \infty)\right) = 0.$$

Demostración. Ver Durrett (Teorema 2.3.8). □

Nota. No obstante, si $\mathbb{E}(|X_n|) = \infty$, pero X_n es $\mathbb{P}$ -débil integrable, sigue valiendo la LFGN en el sentido esperable.

Teorema 3.7. Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d con $\mathbb{E}(X_n^+) = \infty$ y $\mathbb{E}(X_n^-) < \infty$, entonces

$$\frac{S_n}{n} \xrightarrow{c.s.} \infty.$$

Lo análogo vale si $\mathbb{E}(X_n^-) = \infty$ y $\mathbb{E}(X_n^+) < \infty$.

Demostración. Ver Durrett (Teorema 2.4.5). □

Ejemplo. Se tira n veces una moneda equilibrada. Entonces,

$$\frac{\# \text{ veces que salió cara}}{n} \xrightarrow{c.s.} \frac{1}{2}.$$

En efecto, si definimos

$$X_i := \begin{cases} 1 & \text{si la } i\text{-ésima moneda fue cara,} \\ 0 & \text{si no,} \end{cases}$$

entonces $X_1, \dots, X_n$ son i.i.d con $\text{Be}(\frac{1}{2})$. Por la ley fuerte para las $(X_i)_{i \in \mathbb{N}}$,

$$\frac{\# \text{ caras}}{n} = \frac{X_1 + \dots + X_n}{n} \xrightarrow{c.s.} \mathbb{E}(X_1) = \frac{1}{2}.$$

Clase 11

6 de Abril

3.1 Convergencia en distribución.

Definición 3.8. Diremos que:

- i) Una sucesión $(F_n)_{n \in \mathbb{N}}$ de funciones de distribución *converge débilmente* a una función de distribución F_∞ , y lo denotamos por $F_n \Rightarrow F_\infty$, si $\lim_{n \rightarrow \infty} F_n(x) = F_\infty(x)$ para todo x punto de continuidad de F_∞ .
- ii) Una sucesión $(X_n)_{n \in \mathbb{N}}$ de VA's *converge débilmente* o *converge en distribución* (o en ley) a una VA X_∞ , y lo denotamos por $X_n \Rightarrow X_\infty$ o $X_n \xrightarrow{d} X_\infty$, si $F_{X_n} \Rightarrow F_{X_\infty}$.

Ejemplo.

- X_∞ VA;
- $X_n := X_\infty + \frac{1}{n}$;
- $F_{X_n}(x) = \mathbb{P}(X_n \leq x) = \mathbb{P}(X_\infty \leq x - \frac{1}{n}) = F_{X_\infty}(x - \frac{1}{n}) \xrightarrow{n \rightarrow \infty} F_{X_\infty}(x^-)$.

Luego, $F_{X_n}(x) \rightarrow F_{X_\infty}(x)$ si y solo si x es punto de continuidad de F_{X_∞} . En particular, $X_n \xrightarrow{d} X_\infty$.

Ejemplo (Aproximación Poisson a la Binomial). Si $X_n \sim \text{Bi}(n, p_n)$ con $\lim_{n \rightarrow \infty} n \cdot p_n = \lambda > 0$ y $X_\infty \sim \mathcal{P}(\lambda)$, entonces $X_n \xrightarrow{d} X_\infty$ (es decir, $\text{Bi}(n, p) \xrightarrow{d} \mathcal{P}(\lambda)$ si $n \gg 1$ y $np \approx \lambda$).

Ejemplo. Si $X_n \sim \mathcal{G}(p_n)$ con $p_n \xrightarrow{n \rightarrow \infty} 0$ y $X_\infty \sim \varepsilon(1)$, entonces $p_n X_n \xrightarrow{d} X_\infty$.

Propiedad 3.9.

- i) $X_n \xrightarrow{\mathbb{P}} X_\infty \Rightarrow X_n \xrightarrow{d} X_\infty$ (el converso no vale).
- ii) $X_n \xrightarrow{d} c \in \mathbb{R} \Rightarrow X_n \xrightarrow{\mathbb{P}} c$. (ejemplo: $U \sim \mathcal{U}([0, 1])$, $X_n \equiv U \quad \forall n \in \mathbb{N}$, $X_\infty := 1 - U$. Así, $X_n \xrightarrow{d} X_\infty$ pero $X_n \not\xrightarrow{\mathbb{P}} X_\infty$ pues $U \neq 1 - U$).
- iii) $X_n \xrightarrow{d} X_\infty$, $Y_n \xrightarrow{d} c \Rightarrow \begin{cases} X_n Y_n \xrightarrow{d} c X_\infty \\ X_n + Y_n \xrightarrow{d} X_\infty + c \end{cases}$ (Teoremas de Slutsky).
- iv) $X_n \xrightarrow{X} \infty \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k \in \mathbb{N}}$ tiene ella misma una subsucesión $(X_{n_{k_j}})_{j \in \mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow{j \rightarrow \infty} X_\infty$.

Teorema 3.10 (Representación de Skorokhod). Si $X_n \xrightarrow{d} X_\infty$, entonces existe un EdP $(\Omega, \mathcal{F}, \mathbb{P})$ y VA's $(Y_n)_{n \in \mathbb{N} \cup \{\infty\}}$, todas definidas en dicho espacio, tales que:

i) $Y_n \stackrel{d}{=} X_n \quad \forall n \in \mathbb{N} \cup \{\infty\};$

ii) $Y_n \xrightarrow{cs} Y_\infty.$

Decimos que $(Y_n)_{n \in \mathbb{N} \cup \{\infty\}}$ es un *acoplamiento* de las $(X_n)_{n \in \mathbb{N} \cup \{\infty\}}$

Demostración. Sea $(\Omega, \mathcal{F}, \mathbb{P}) := ([0, 1], \beta([0, 1]), \mathcal{L}|_{[0, 1]})$. Definimos

$$Y_n(\omega) := F_{X_n}^{-1}(\omega) = \sup\{x : F_{X_n}(x) < \omega\}, \quad \omega \in [0, 1].$$

Ya vimos que $F_{Y_n} = F_{X_n}$ antes. Luego, $X_n \stackrel{d}{=} Y_n \quad \forall n \in \mathbb{N} \cup \{\infty\}$. Para ver que $Y_n \xrightarrow{cs} Y_\infty$, bastará ver que $Y_n(\omega) \rightarrow Y_\infty(\omega)$ para $\mathcal{L}$ -casi todo $\omega \in (0, 1)$.

Definimos para cada $y \in \mathbb{R}$,

$$a_y := \sup\{x : F_{X_\infty}(x) < y\}, \quad b_y := \inf\{x : F_{X_\infty}(x) > y\}.$$

Sea $\Omega_0 := \{y \in (0, 1) : a_y = b_y\}$.

- Si $y \notin \Omega_0$ entonces $F_{X_\infty} \cong y$ en (a_y, b_y) ;
- Hay a lo sumo numerables $y \notin \Omega_0$ (los (a_y, b_y) son disjuntos y cada uno contiene al menos un racional [distintos entre sí {creo}]).

Entonces, $\mathcal{L}([0, 1] \setminus \Omega_0) = 0$.

Luego, basta con ver que $Y_n(\omega) \rightarrow Y_\infty(\omega)$ para todo $\omega \in \Omega_0$.

Primero, veamos que $\liminf_{n \rightarrow \infty} Y_n(\omega) \geq Y_\infty(\omega)$:

- Sean $(y_k)_{k \in \mathbb{N}}$ puntos de continuidad de F_{X_∞} tal que $y_k \nearrow Y_\infty(\omega)$.
- $y_k < Y_\infty(\omega) \Rightarrow F_{X_\infty}(y_k) < \omega \Rightarrow F_{X_n}(y_k) < \omega$ para todo $n \in \mathbb{N}$ grande (notar que la última implicancia está dada pues $F_{X_n}(y_k) \rightarrow F_{X_\infty}(y_k)$ pues y_k punto de continuidad de F_{X_∞} .) $\Rightarrow y_k \leq Y_n(\omega) \quad \forall n$ grande $\Rightarrow y_k \leq \liminf_{n \rightarrow \infty} Y_n(\omega) \quad \forall k \in \mathbb{N} \Rightarrow Y_\infty(\omega) \leq \liminf_{n \rightarrow \infty} Y_n(\omega)$.

En segundo lugar, veamos que $\limsup_{n \rightarrow \infty} Y_n(\omega) \leq Y_\infty(\omega)$:

- Sean $(y_k)_{k \in \mathbb{N}}$ puntos de continuidad de F_{X_∞} tal que $y_k \searrow Y_\infty(\omega)$.
- $y_k > Y_\infty(\omega) = a_\omega \xrightarrow{\omega \in \Omega_0} y_k > b_\omega \Rightarrow F_{X_\infty}(y_k) > \omega \Rightarrow F_{X_n}(y_k) > \omega \quad \forall n$ grande $\Rightarrow \limsup_{n \rightarrow \infty} Y_n(\omega) \leq Y_\infty(\omega)$.

□

Corolario 3.11. $X_n \xrightarrow{d} x \Rightarrow X_n \xrightarrow{\mathbb{P}} c.$

Demostración. Debemos ver que, dado $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - c| > \varepsilon) = 0.$$

Pero

$$\begin{aligned} \mathbb{P}(|X_n - c| > \varepsilon) &= \mathbb{P}(X_n \notin \overline{B(x, \varepsilon)}) \\ &= \mathbb{P}(Y_n \notin \overline{B(c, \varepsilon)}) \\ &= \mathbb{P}(|Y_n - c| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0, \end{aligned}$$

pues $Y_n \xrightarrow{c.s.} c \Rightarrow Y_n \xrightarrow{\mathbb{P}} c$. $\square$

Clase 12

8 de Abril

Corolario 3.12. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(f(X_\infty)) \quad \forall f: \mathbb{R} \rightarrow \mathbb{R}$ continua y acotada.

Demostración. $\Rightarrow$ Por Skorokhod, existen $(Y_n)_{n \in \mathbb{N} \cup \{\infty\}}$ tal que $Y_n \stackrel{d}{=} X_n \quad \forall n \in \mathbb{N} \cup \{\infty\}$ e $Y_n \xrightarrow{c.s.} Y_\infty$. Luego:

- $Y_n \xrightarrow{c.s.} Y_\infty \Rightarrow f(Y_n) \xrightarrow{c.s.} f(Y_\infty) \Rightarrow \mathbb{E}(f(Y_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(f(Y_\infty))$.
(donde la primera implicancia está dada por la continuidad de f y la segunda por T.C.D.)
- $Y_n \stackrel{d}{=} X_n \Rightarrow \mathbb{E}(f(Y_n)) = \mathbb{E}(f(X_n))$. En combinación con lo anterior, esto nos da $(\Rightarrow)$.

$\Leftarrow$ Sea para cada $x \in \mathbb{R}$ y $\varepsilon > 0$, la función $g_{x,\varepsilon}$ de gráfico (foto). Notar que cada $g_{x,\varepsilon}$ es continua y acotada. Además, tenemos que $\mathbb{1}_{(-\infty, x]} \leq g_{x,\varepsilon} \leq \mathbb{1}_{(-\infty, x+\varepsilon]} \quad \forall x \in \mathbb{R}, \varepsilon > 0$. En particular,

$$\begin{aligned} \limsup_{n \rightarrow \infty} \mathbb{P}(X_n \leq x) &\leq \limsup_{n \rightarrow \infty} \mathbb{E}(g_{x,\varepsilon}(X_n)) \\ &= \mathbb{E}(g_{x,\varepsilon}(X_\infty)) \\ &\leq \mathbb{P}(X_\infty \leq x + \varepsilon) \\ &= F_{X_\infty}(x + \varepsilon). \end{aligned}$$

En conclusión, $\limsup_{n \rightarrow \infty} F_{X_n}(x) \leq F_{X_\infty}(x + \varepsilon) \quad \forall \varepsilon > 0$.

Tomando $\varepsilon \rightarrow 0^+$, resulta $\limsup_{n \rightarrow \infty} F_{X_n}(x) \leq F_{X_\infty}(x)$. (pues F_{X_∞} es continua a derecha.)

Por otro lado,

$$\liminf_{n \rightarrow \infty} \mathbb{P}(X_n \leq x) \geq \liminf_{n \rightarrow \infty} \mathbb{E}(g_{x-\varepsilon,\varepsilon}(X_n)) = \mathbb{E}(g_{x-\varepsilon,\varepsilon}(X_\infty)).$$

Tomando, $\varepsilon \rightarrow 0^1$, resulta $\liminf_{n \rightarrow \infty} \mathbb{P}(X_n \leq x) \geq \mathbb{P}(X_\infty < x) = F_{X_\infty}(x^-)$. Pero, si x es punto de continuidad de F_{X_∞} , entonces $F_{X_\infty}(x^-) = F_{X_\infty}(x)$ y, por lo tanto, $\lim_{n \rightarrow \infty} \mathbb{P}(X_n \leq x) = \mathbb{P}(X_\infty \leq x)$, lo cual muestra que $X_n \xrightarrow{d} X_\infty$. $\square$

Observación. La demostración anterior muestra que $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X_\infty)) \quad \forall f \in \mathcal{C}$ donde $\mathcal{C}$ es cualquier clase de funciones continuas y acotadas con la siguiente propiedad:

(A) Dado $x \in \mathbb{R}$ y $\varepsilon > 0$, existe $f_{x,\varepsilon} \in \mathcal{C}$ tal que $\mathbb{1}_{(-\infty, x]} \leq f_{x,\varepsilon} \leq \mathbb{1}_{(-\infty, x+\varepsilon]}$.

Definición 3.13. Sea E un espacio métrico. Diremos que:

- i) Una sucesión $(X_n)_{n \in \mathbb{N}}$ de elementos aleatorios a valores en E *converge débilmente o en distribución* a un elemento aleatorio X_∞ , y lo notamos $X_n \Rightarrow X_\infty$ ó $X_n \xrightarrow{d} X_\infty$, si $\mathbb{E}(f(X_n)) \xrightarrow{n \rightarrow \infty} \mathbb{E}(f(X_\infty)) \quad \forall f: E \rightarrow \mathbb{R}$ continua y acotada.
- ii) Una sucesión $(\mu_n)_{n \in \mathbb{N}}$ de medidas sobre el espacio $(E, \beta(E))$ *converge débilmente* a una medida μ_∞ y lo notamos $\mu_n \Rightarrow \mu_\infty$ ó $\mu_n \xrightarrow{\omega} \mu_\infty$, si se cumple que

$$\lim_{n \rightarrow \infty} \int_E f d\mu_n = \int_E f d\mu_\infty \quad \forall f: E \rightarrow \mathbb{R} \text{ continua y acotada.}$$

Observación.

1. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{P}_{X_n} \xrightarrow{\omega} \mathbb{P}_{X_\infty}$.
2. Si R es un espacio métrico compacto y $\mathcal{C}(E) := \{f: E \rightarrow \mathbb{R} \mid f \text{ continua}\}$, entonces

$$(\mathcal{C}(E))^* := \{\varphi: \mathcal{C}(E) \rightarrow \mathbb{R} \mid \varphi \text{ lineal y continua}\} = \mathcal{M}(E),$$

donde

$$\mathcal{M}(E) := \{\mu : \mu \text{ medida con signo finito en } (E, \beta(E))\}.$$

Es decir,

- i. Para todo $\varphi \in (\mathcal{C}(E))^*$ existe una única $\mu_\varphi \in \mathcal{M}(E)$ tal que $\varphi(f) = \int f d\mu_\varphi$ para toda $f \in \mathcal{C}(E)$. (por eso, a veces se nota $\int f d\mu =: \mu(f)$.) Además, $\|\varphi\| = \|\mu_\varphi\|$ ($:= |\mu_\varphi|(E)$).
- ii. Para toda $\mu \in \mathcal{M}(E)$, la aplicación $\varphi_\mu: \mathcal{C}(E) \rightarrow \mathbb{R}$ dada por $\varphi_\mu(f) := \int f d\mu$, cumple que $\varphi_\mu \in (\mathcal{C}(E))^*$ y $\|\varphi_\mu\| = \|\mu\|$.

En particular, si $(\mathbb{P}_n)_{n \in \mathbb{N} \cup \{\infty\}}$ son medidas de probabilidad en $(E, \beta(E))$, entonces

$$\begin{aligned} \mathbb{P}_n \xrightarrow{\omega} \mathbb{P}_\infty &\Leftrightarrow \int f d\mathbb{P}_n \rightarrow \int f d\mathbb{P}_\infty \quad \forall f \in \mathcal{C}(E) \\ &\Leftrightarrow \varphi_{\mathbb{P}_n}(f) \rightarrow \varphi_{\mathbb{P}_\infty}(f) \quad \forall f \in \mathcal{C}(E) \\ &\Leftrightarrow \varphi_{\mathbb{P}_n} \xrightarrow{\omega^*} \varphi_{\mathbb{P}_\infty}. \end{aligned}$$

Es decir, la convergencia es distribución (cuando E es compacto, es un caso particular de la convergencia débil-* de Análisis Funcional).

Teorema 3.14 (de la aplicación medible). Sean $h: \mathbb{R} \rightarrow \mathbb{R}$ medible Borel y $D_h := \{x : h \text{ es discontinua en } x\}$. Entonces, si $X_n \xrightarrow{d} X_\infty$ y $\mathbb{P}(X_\infty \in D_h) = 0$, vale que $h(X_n) \xrightarrow{d} h(X_\infty)$.
Si además h es acotada, entonces $\mathbb{E}(h(X_n)) \rightarrow \mathbb{E}(h(X_\infty))$.

Demostración. Ejercicio de la práctica 5. □

Nota. $\text{Var}(X) = 0 \Leftrightarrow X = \mathbb{E}(X)$ c.s.

Teorema 3.15 (Central del Límite). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de VA's i.i.d, con:

- $\mathbb{E}(X_n) =: \mu \in \mathbb{R}$;
- $\text{Var}(X_n) =: \sigma^2 \in (0, \infty)$.

Entonces, en el límite cuando $n \rightarrow \infty$,

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

Observación.

1. En particular, el TCL dice que para todo $a < b$,

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(a < \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b\right) = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

2. Observar que $n\mu = \mathbb{E}(S_n)$ y $\text{Var}(S_n) = n\sigma^2$, de modo que

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{S_n - \mathbb{E}(S_n)}{\sqrt{\text{Var}(S_n)}}.$$

(i.e, estamos centrando y normalizando para que tenga media 0 y varianza 1.)

3. El TCL nos dice "esencialmente" que, bajo las hipótesis del Teorema,

$$S_n \stackrel{d}{\approx} n\mu + \sigma\sqrt{n} \cdot N(0, 1) \sim N(n\mu, \sigma^2 n)$$

para n grande. Equivalentemente

$$\frac{S_n}{n} \stackrel{d}{\approx} \mu + \frac{\sigma}{\sqrt{n}} \cdot N(0, 1).$$

Por la LGN, ya sabíamos que $\frac{S_n}{n} \rightarrow \mu$. El TCLL va más allá y nos dice cómo son las *fluctuaciones* de $\frac{S_n}{n}$ alrededor de su límite μ : de orden $\frac{1}{\sqrt{n}}$ y distribución asintóticamente normal.

Clase 13

13 de Abril

Nota. En el TCL, podemos reescribir:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \sqrt{n} \left(\frac{\frac{S_n}{n} - \mu}{\sigma} \right).$$

Además, notar que $\frac{S_n}{n} = \overline{X_n}$.

Nota.

- No basta con que las VA's sean independientes de a pares (Ver Durrett, Ejemplo 3.4.9);
- Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d con $\mathbb{E}(X_n) = 0$ y $\sigma^2 := \text{Var}(X_n) \in (0, \infty)$, entonces $\frac{S_n}{\sqrt{n}} \xrightarrow{d} N(0, \sigma^2)$, pero:
 - i) $\limsup_{n \rightarrow \infty} \frac{S_n}{\sqrt{n}} = \infty$ $\mathbb{P}$ -c.s.
 - ii) $(\frac{S_n}{\sqrt{n}})_{n \in \mathbb{N}}$ no converge en probabilidad.
 (i y ii parte del ejercicio 3.4.2 del Durrett.)
- Si $(X_n)_{n \in \mathbb{N}}$ i.i.d y $(S_n/\sqrt{n})_{n \in \mathbb{N}}$ converge en distribución, entonces $\mathbb{E}(X_n^2) < \infty$. (Ejercicio 3.4.3 Durrett.)

En general, si $\mathbb{E}(X_n^2) = \infty$, entonces $S_n - n\mu \neq O(\sqrt{n})$ y, además, puede que la distribución asintótica tampoco sea normal.

3.1.1 Aplicaciones

1. **Aproximación normal a la Binomial.** Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d $\text{Be}(p)$ con $p \in (0, 1)$, entonces

$$\begin{aligned} \text{Bi}(n, p) \sim X_1 + \cdots + X_n = S_n &\stackrel{d}{\approx} n\mu + \sigma\sqrt{n}N(0, 1) \\ &= np + \sqrt{p(1-p)}\sqrt{n}N(0, 1) \\ &\stackrel{d}{=} N(np, np(1-p)) \end{aligned}$$

$$\Rightarrow \text{Bi}(n, p) \stackrel{d}{\approx} N(np, np(1-p)).$$

2. **Aproximación normal a la Poisson.** Si $(X_n)_{n \in \mathbb{N}}$ son i.i.d $\mathcal{P}(1)$, entonces $S_n = X_1 + \cdots + X_n \sim \mathcal{P}(n)$. Luego,

$$\begin{aligned} \mathcal{P}(n) \sim S_n &\stackrel{d}{\approx} n\mu + \sigma\sqrt{n}N(0, 1) \\ &= n \cdot 1 + 1 \cdot \sqrt{n}N(0, 1) \\ &\stackrel{d}{=} N(n, n). \end{aligned}$$

En general, vale que $\mathcal{P}(\lambda) \stackrel{d}{\approx} N(\lambda, \lambda)$ cuando $\lambda \rightarrow \infty$. (Ejercicio Práctica 5.)

Pregunta. ¿Cuál es la velocidad de convergencia?

Teorema 3.16 (Berry-Esseen). Sean $(X_n)_{n \in \mathbb{N}}$ i.i.d con $\mathbb{E}(X_i) = 0$ y $\text{Var}(X_n) =: \sigma^2 \in (0, \infty)$. Entonces, si $\rho := \mathbb{E}(|X_n|^3) < \infty$, entonces

$$\sup_{x \in \mathbb{R}} \left| F_{\frac{S_n}{\sigma\sqrt{n}}}(x) - F_{N(0,1)}(x) \right| \leq \frac{3\rho}{\sigma^3} \cdot \frac{1}{\sqrt{n}}.$$

Además, puede verse que la tasa de convergencia no puede ser más rápida que $\frac{1}{\sqrt{n}}$.

Demostración. En el Durrett (de todas maneras, esto es más curiosidad que algo importante para el curso). $\square$

Para demostrar el TCL, vamos a usar lo siguiente:

Proposición 3.17. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X_\infty)) \quad \forall f \in C_b^\infty(\mathbb{R})$.

La Proposición es un corolario directo de lo que ya hemos visto y el siguiente lema:

Lema 3.18. Dado $x \in \mathbb{R}$ y $\varepsilon > 0$, existe $f_{x,\varepsilon} \in C_b^\infty(\mathbb{R})$ tal que $\mathbb{1}_{(-\infty, x]} \leq f_{x,\varepsilon} \leq \mathbb{1}_{(-\infty, x+\varepsilon]}$.

Demostración (Idea). Sean

$$\varphi(t) := \begin{cases} e^{-1/t} & t > 0 \\ 0 & t \leq 0 \end{cases}$$

y $\rho(x) := k \cdot \varphi(1 - x^2)$, donde $k > 0$ es tal que $\int_{\mathbb{R}} \rho(x) dx = 1$. Observar que $\varphi \in C^\infty$ y, por lo tanto, $\rho \in C^\infty$ también. Además, $\rho \geq 0$ y $\rho(x) > 0$ si y solo si $|x| < 1$. En particular, $\rho \in C_b^\infty$.

Ahora, dado $\varepsilon > 0$, consideramos $\rho_\varepsilon(x) := \frac{1}{\varepsilon} \rho\left(\frac{x}{\varepsilon}\right)$. Observar que $\rho_\varepsilon \in C_b^\infty$, $\int_{\mathbb{R}} \rho_\varepsilon(x) dx = 1$, $\rho_\varepsilon \geq 0$ y $\rho_\varepsilon(x) > 0$ si y solo si $|x| < \varepsilon$.

Con todo esto, definimos

$$f_{x,\varepsilon}(z) := \left(\mathbb{1}_{(-\infty, x+\frac{\varepsilon}{2}]} * \rho_{\frac{\varepsilon}{2}} \right)(z) = \int_{-\infty}^{x+\frac{\varepsilon}{2}} \rho_{\frac{\varepsilon}{2}}(z-y) dy.$$

Resulta que $f_{x,\varepsilon}$ cumple lo pedido. $\square$

Demostración (TCL). Sin pérdida de generalidad, podemos asumir $\mu = 0$ y $\sigma^2 = 1$. En caso contrario, consideramos $X'_n := \frac{X_n - \mu}{\sigma}$, que cumplen $\mathbb{E}(X'_n) = 0$, $\text{Var}(X'_n) = 1$ y son i.i.d. Si probamos el TCL para las $(X'_n)_{n \in \mathbb{N}}$, entonces $\frac{S'_n}{\sqrt{n}} \xrightarrow{d} N(0, 1)$, pero $\frac{S'_n}{\sqrt{n}} = \frac{S_n - n\mu}{\sigma\sqrt{n}}$, de modo que también vale el TCL para las $(X_n)_{n \in \mathbb{N}}$.

Por otro lado, la validez del TCL para las $(X_n)_{n \in \mathbb{N}}$ es una propiedad que

depende sólo de su distribución $\mathbb{P}_{(X_n)_{n \in \mathbb{N}}}$. En particular, bastará con probar el TCL para alguna sucesión $(\tilde{X}_n)_{n \in \mathbb{N}}$ de VA's i.i.d con $\mathbb{P}_{(\tilde{X}_n)_{n \in \mathbb{N}}} = \mathbb{P}_{(X_n)_{n \in \mathbb{N}}}$ para que valga para $(X_n)_{n \in \mathbb{N}}$ también.

Teniendo esto en cuenta, si pérdida de generalidad, podemos asumir, que en el mismo EdP en donde están definidas las $(X_n)_{n \in \mathbb{N}}$, tenemos definida también una sucesión $(Y_n)_{n \in \mathbb{N}}$ de VA's i.i.d con distribución $N(0, 1)$ independiente de $(X_n)_{n \in \mathbb{N}}$.

Con todo esto, definimos las variables

$$S_{n,i} := \frac{X_1 + \cdots + X_{i-1} + 0 + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 0, \dots, n$$

$$Z_{n,i} := \frac{X_1 + \cdots + X_{i-1} + X_i + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 0, \dots, n.$$

Observar que:

$$Z_{n,n} = \frac{S_n}{\sqrt{n}} \text{ y } Z_{n,0} = \frac{Y_1 + \cdots + Y_n}{\sqrt{n}} \sim N(0, 1).$$

Por la proposición, basta con mostrar

$$\mathbb{E}(f(Z_{n,n})) - \mathbb{E}(f(\underbrace{Z_{n,0}}_{\sim N(0,1)})) \xrightarrow{n \rightarrow \infty} 0 \quad \forall f \in C_b^\infty.$$

□

Clase 14

15 de Abril

Demostración. $(X_n)_{n \in \mathbb{N}}$ i.i.d $\mathbb{E}(X_n) = 0$, $\text{Var}(X_n) = 1$. $(Y_n)_{n \in \mathbb{N}}$ i.i.d $N(0, 1)$, indep. de $(X_n)_{n \in \mathbb{N}}$.

$$S_{n,i} := \frac{X_1 + \cdots + X_{i-1} + 0 + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 1, \dots, n$$

$$Z_{n,i} := \frac{X_1 + \cdots + X_i + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 0, \dots, n$$

$$Z_{n,n} = \frac{X_1 + \cdots + X_n}{\sqrt{n}}$$

$$Z_{n,0} = \frac{Y_1 + \cdots + Y_n}{\sqrt{n}} \sim N(0, 1).$$

Ahora, como X_i y $S_{n,i}$ son independientes,

- $\mathbb{E}\left(\frac{f'(S_{n,1}) \cdot X_1}{\sqrt{n}}\right) = \frac{1}{\sqrt{n}} \mathbb{E}(f'(S_{n,1})) \cdot \mathbb{E}(X_1) = 0;$
- $\mathbb{E}\left(\frac{f''(S_{n,i}) \cdot X_i^2}{2n}\right) = \frac{1}{2n} \mathbb{E}(f''(S_{n,i})) \cdot \mathbb{E}(X_i^2) = \frac{1}{2n} \mathbb{E}(f''(S_{n,i}));$

de modo que lo anterior resulta

$$|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(S_{n,i})) - \frac{1}{2n} \mathbb{E}(f''(S_{n,i}))| \leq \frac{\varepsilon}{n}.$$

Como $Z_{n,i-1} - S_{n,i} = Y_i$, el mismo argumento empleado para $Z_{n,i}$ y $S_{n,i}$, obtenemos que, si n es suficientemente grande, para todo $i = 1, \dots, n$,

$$|\mathbb{E}(f(Z_{n,i-1})) - \mathbb{E}(f(S_{n,i})) - \frac{1}{2n} \mathbb{E}(f''(S_{n,i}))| \leq \frac{\varepsilon}{n}.$$

Juntando ambas desigualdades,

$$|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(Z_{n,i-1}))| \leq \frac{2\varepsilon}{n} \quad \forall i = 1, \dots, n.$$

Sumando en i , concluimos que

$$|\mathbb{E}(f(Z_{n,n})) - \mathbb{E}(f(Z_{n,0}))| \leq \sum_{i=1}^n \underbrace{|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(Z_{n,i-1}))|}_{\leq \frac{2\varepsilon}{n}} \leq 2\varepsilon$$

si n es suficientemente grande. □

Chapter 4

Esperanza Condicional

Problema. Dado un vector (X, Y) , buscar la mejor predicción del valor de X basada en el valor de Y .

Más precisamente, buscamos una VA Z tal que

1. $Z = g(Y)$, donde $g(y) =$ "mejor predicción del valor de X cuando $Y = y$ " es medible Borel. Es decir, Z es $\sigma(Y)$ -medible.
2. Z es la "mejor aproximación" de X dentro de las variables $\sigma(Y)$ -medibles.

Trabajamos este problema primero en L^2 .

- $L^2(\Omega, \mathcal{F}, \mathbb{P}) := \{Z: \Omega \rightarrow \overline{\mathbb{R}} \mid Z \text{ es } \mathcal{F}\text{-medible y } \mathbb{E}(Z^2) < \infty\}$,
- L^2 es un espacio de Hilbert con producto interno $\langle Z_1, Z_2 \rangle := \mathbb{E}(Z_1 Z_2)$.
- $\|Z\|_2 := \sqrt{\langle Z, Z \rangle}$, $d(Z_1, Z_2) = \|Z_1 - Z_2\|_2$.

Luego, si pensamos que $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, buscamos $Z \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ que sea $\sigma(Y)$ -medible y tal que

$$d(X, Z) = \min\{d(X, W) : w \in L^2, \sigma(Y)\text{-medible}\}.$$

Defino $\mathcal{G} := \sigma(Y)$ y

$$L^2(\Omega, \mathcal{G}, \mathbb{P}) := \{W \in L^2(\Omega, \mathcal{F}, \mathbb{P}) : W \text{ es } \mathcal{G}\text{-medible}\}.$$

Notar que $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es un subespacio vectorial de $L^2(\Omega, \mathcal{F}, \mathbb{P})$. Luego, nuestra pregunta se reduce a encontrar la proyección ortogonal Z de X sobre $L^2(\Omega, \mathcal{F}, \mathbb{P})$.

Existirá tal proyección (y será única) si $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es un subespacio cerrado de $L^2(\Omega, \mathcal{F}, \mathbb{P})$ (y esto siempre vale pues $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es completo). Luego, existe tal Z y es única.

Notemos que, en la definición de Z ,

- 1) Z es $\mathcal{G}$ -medible;
- 2) $d(X, Z) = \min\{d(X, W) : W \in L^2(\Omega, \mathcal{G}, \mathbb{P})\}$;

Podemos reemplazar 2) por:

$$2') \langle X - Z, W \rangle = 0 \quad \forall W \in L^2(\Omega, \mathcal{G}, \mathbb{P}) \quad (\text{ó } \langle X, W \rangle = \langle Z, W \rangle).$$

O, equivalentemente, por:

$$2'') \langle X, \mathbb{1}_A \rangle = \langle Z, \mathbb{1}_A \rangle \quad \forall A \in \mathcal{G}.$$

Notar que, (1) y (2'') tienen sentido para una σ -álgebra $\mathcal{G} \subset \mathcal{F}$ cualquiera y X no necesariamente en L^2 .

Definición 4.1. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un EdP, $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$ una σ -álgebra. Diremos que $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ es una *esperanza condicional de X dada $\mathcal{G}$* y lo notamos $Y = \mathbb{E}(X|\mathcal{G})$, si satisface:

- i) Y es $\mathcal{G}$ -medible;
- ii) $\int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P} \quad \forall A \in \mathcal{G}.$

Teorema 4.2. Sean $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$ una σ -álgebra. Entonces,

1. **Existencia:** existe $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ esperanza condicional de X dada $\mathcal{G}$;
2. **Unicidad:** si Y, Y' son esperanza condicional de X dada $\mathcal{G}$, $\mathbb{P}(Y = Y') = 1$.

Clase 15

20 de Abril

Propiedad 4.3. Sean $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subseteq \mathcal{F}$ una σ -álgebra. Entonces, valen las siguientes:

1. X es $\mathcal{G}$ -medible $\Rightarrow \mathbb{E}(X|\mathcal{G}) = X$.
2. La aplicación $X \mapsto \mathbb{E}(X|\mathcal{G})$ es un operador lineal en L^1 .
3. $\mathbb{E}(\mathbb{E}(X|\mathcal{G})) = \mathbb{E}(X)$.
4. Si $\Sigma \subseteq \mathcal{G}$ es una σ -álgebra, entonces $\mathbb{E}(\mathbb{E}(X|\mathcal{G})|\Sigma) = \mathbb{E}(X|\Sigma)$.
5. $|\mathbb{E}(X|\mathcal{G})| \leq \mathbb{E}(|X||\mathcal{G})$. En particular,

$$\|\mathbb{E}(X|\mathcal{G})\|_1 = \mathbb{E}(|\mathbb{E}(X|\mathcal{G})|) \leq \mathbb{E}(\mathbb{E}(|X||\mathcal{G})) = \mathbb{E}(|X|) = \|X\|_1.$$

Con lo cual, $X \mapsto \mathbb{E}(X|\mathcal{G})$ es un operador lineal acotado en L^1 .

6. $X \leq Y \Rightarrow \mathbb{E}(X|\mathcal{G}) \leq \mathbb{E}(Y|\mathcal{G})$.

Demostración. Ejercicio!

□

¿Cómo extender la definición cuando X es débilmente integrable?

Caso $X \geq 0$:

- $X_n := X \wedge n = \min\{X, n\} \in L^1 \quad \forall n \in \mathbb{N}.$
- $Z_n := \mathbb{E}(X_n|\mathcal{G}).$

- $(Z_n)_{n \in \mathbb{N}}$ es $\mathbb{P}$ -c.s creciente por propiedad 6, pues $(X_n)_{n \in \mathbb{N}}$ lo son.
- Definimos $Z := \lim_{n \rightarrow \infty} Z_n$.

Notemos que:

- Z es $\mathcal{G}$ -medible.
- Si $A \in \mathcal{G}$,

$$\begin{aligned} \int_A Z \, d\mathbb{P} &= \int_A \lim_{n \rightarrow \infty} Z_n \, d\mathbb{P} \\ (\text{T.C.M}) &= \lim_{n \rightarrow \infty} \int_A Z_n \, d\mathbb{P} \\ &= \lim_{n \rightarrow \infty} \int_A X_n \, d\mathbb{P} \\ (\text{T.C.M}) &= \int_A \lim_{n \rightarrow \infty} X_n \, d\mathbb{P} \\ &= \int_A X \, d\mathbb{P}. \end{aligned}$$

Además, si Y es otra variable que cumple (i) y (ii), resulta

$$\int_A Y \, d\mathbb{P} = \int_A Z \, d\mathbb{P} \quad \forall A \in \mathcal{G}.$$

En particular, tomando $A_{a,b} := \{Z \leq a < b \leq Y\}$ con $a, b \in \mathbb{Q}$. Como $A_{a,b} \in \mathcal{G}$, resulta

$$b\mathbb{P}(A_{a,b}) \leq \int_{A_{a,b}} Y \, d\mathbb{P} = \int_{A_{a,b}} Z \, d\mathbb{P} \leq a\mathbb{P}(A_{a,b}),$$

de donde se deduce que $\mathbb{P}(A_{a,b}) = 0$. Como $a < b \in \mathbb{Q}$ eran arbitrarios, $\mathbb{P}(Z < Y) = 0$ y la otra desigualdad es análoga.

Luego, existe $\mathbb{P}$ -c.s una única VA Z que cumple (i) y (ii) de la definición de $\mathbb{E}(X|\mathcal{G})$.

Caso General: $\mathbb{E}(X) = \pm\infty$.

- Definimos $\mathbb{E}(X|\mathcal{G}) := \mathbb{E}(X^+|\mathcal{G}) - \mathbb{E}(X^-|\mathcal{G})$.
- Bien definido, pues

$$\begin{cases} X^+ \in L^1 \Rightarrow \mathbb{E}(X^+|\mathcal{G}) \in L^1 \\ X^- \in L^1 \Rightarrow \mathbb{E}(X^-|\mathcal{G}) \in L^1 \end{cases}$$

- Puede verificarse que cumple (i) y (ii) y que es casi seguramente única.

Teorema 4.4. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un EdP y $\mathcal{G} \subseteq \mathcal{F}$ una σ -álgebra. Entonces se cumplen:

- **Convergencia Monótona:** Si $(X_n)_{n \in \mathbb{N}}$ es una sucesión creciente de VA's no negativas, entonces

$$0 \leq \mathbb{E}(X_n | \mathcal{G}) \nearrow \mathbb{E}\left(\lim_{n \rightarrow \infty} X_n | \mathcal{G}\right) \quad \text{cuando } n \rightarrow \infty.$$

- **Lema de Fatou:** Si $(X_n)_{n \in \mathbb{N}}$ son VA's no negativas, entonces

$$\mathbb{E}(\liminf_{n \rightarrow \infty} X_n | \mathcal{G}) \leq \liminf_{n \rightarrow \infty} \mathbb{E}(X_n | \mathcal{G}).$$

- **Convergencia Dominada:** Si $(X_n)_{n \in \mathbb{N}}$ son VA's tal que $X_n \xrightarrow{c.s.} X_\infty$ y $\sup_{n \in \mathbb{N}} |X_n| \leq Y$ $\mathbb{P}$ -c.s con $Y \in L^1$, entonces

$$\mathbb{E}(X_n | \mathcal{G}) \xrightarrow{c.s.} \mathbb{E}(X_\infty | \mathcal{G}).$$

- **Desigualdad de Jensen:** Si $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\varphi: \mathbb{R} \rightarrow (-\infty, \infty]$ es convexa tal que $\varphi \geq 0$ ó $\varphi(X) \in L^1$, entonces $\varphi(\mathbb{E}(X | \mathcal{G})) \leq \mathbb{E}(\varphi(X) | \mathcal{G})$.

En particular, para todo $1 \leq p < \infty$ vale que $\|\mathbb{E}(X | \mathcal{G})\|_p \leq \|X\|_p$, con lo cual el operador lineal "esp. cond." $X \mapsto \mathbb{E}(X | \mathcal{G})$ es continuo en $L^p(\Omega, \mathcal{F}, \mathbb{P})$.

Proposición 4.5. Sea X débilmente integrable. Entonces, para cualquier Z $\mathcal{G}$ -medible tal que $X.Z$ sea débilmente integrable, vale que

$$(I) \quad \mathbb{E}(XZ) = \mathbb{E}(Z \cdot \mathbb{E}(X | \mathcal{G})).$$

$$(II) \quad \mathbb{E}(XZ | \mathcal{G}) = Z \mathbb{E}(X | \mathcal{G}).$$

(se puede cambiar $\mathbb{1}_A$ de la definición por Z $\mathcal{G}$ -medible.)

Demostración. (I) Por el argumento estándar, igual que antes.

(II) Verificamos (i) y (ii) de la definición de $\mathbb{E}(XZ | \mathcal{G})$.

i) $Z \mathbb{E}(X | \mathcal{G})$ es $\mathcal{G}$ -medible por ser producto de $\mathcal{G}$ -medibles;

ii) Si $A \in \mathcal{G}$,

$$\begin{aligned} \int_A Z \mathbb{E}(X | \mathcal{G}) \, d\mathbb{P} &= \mathbb{E}\left(\underbrace{Z \cdot \mathbb{1}_A}_{\mathcal{G}\text{-medible}} \cdot \mathbb{E}(X | \mathcal{G})\right) \\ (I) &= \mathbb{E}(Z \cdot \mathbb{1}_A \cdot X) \\ &= \int_A X \cdot Z \, d\mathbb{P}. \end{aligned}$$

Entonces, $Z \mathbb{E}(X | \mathcal{G}) = \mathbb{E}(XZ | \mathcal{G})$. □

Clase 16

22 de Abril

Proposición 4.6. Dado $(\Omega, \mathcal{F}, \mathbb{P})$ EdP y $\mathcal{G}_1, \mathcal{G}_2 \subseteq \mathcal{F}$ σ -álgebra, entonces: $\mathcal{G}_1, \mathcal{G}_2$ independientes si solo si $\forall X$ VA $\mathcal{G}_2$ -medible $\mathbb{P}$ -débil integrable se tiene $\mathbb{E}(X | \mathcal{G}_1) = \mathbb{E}(X)$.

Demostración. $\Rightarrow$ Si $A \in \mathcal{G}_1$, entonces $\mathbb{1}_A$ y X son independientes,

$$\mathbb{E}(\mathbb{1}_A X) = \mathbb{P}(A)\mathbb{E}(X) = \mathbb{E}(\mathbb{1}_A \mathbb{E}(X)).$$

Como $\mathbb{E}(X)$ es $\mathcal{G}_1$ -medible, entonces $\mathbb{E}(X | \mathcal{G}_1) = \mathbb{E}(X)$.

$\Leftarrow$ $A \in \mathcal{G}_1$, $B \in \mathcal{G}_2$ y $X = \mathbb{1}_B$, entonces, como X es $\mathcal{G}_2$ -medible,

$$\mathbb{P}(A \cap B) = \mathbb{E}(\mathbb{1}_A \cdot \mathbb{1}_B) = \mathbb{E}(\mathbb{1}_A \cdot X) = \mathbb{E}(\mathbb{1}_A \cdot \mathbb{E}(X)) = \mathbb{P}(A)\mathbb{P}(B).$$

(donde se ocupa que $\mathbb{E}(X) = \mathbb{E}(X | \mathcal{G}_1)$.) Luego, A y B son independientes. $\square$

4.0.1 Esperanza Condicional dada una variable aleatoria

En el caso particular en que $\mathcal{G} = \sigma(Y)$, donde Y es una VA, notaremos $\mathbb{E}(X | \mathcal{G}) =: \mathbb{E}(X | Y)$. Calcularemos esto en algunos casos.

Lema 4.7. Dada una VA Y , tenemos que Z es $\sigma(Y)$ -medible si y solo si $\exists h: \mathbb{R} \rightarrow \mathbb{R}$ medible Borel tal que $Z = h(Y)$.

Cálculo de $\mathbb{E}(h(X, Y) | Y)$.

1. **Y discreta:** Si $A \in \sigma(Y)$, entonces $A = \{Y \in B\}$ con $B \in \beta(\mathbb{R})$. En particular, $\mathbb{1}_A = \mathbb{1}_{\{Y \in B\}} = \mathbb{1}_B(Y)$. Luego,

$$\begin{aligned} \mathbb{E}(h(X, Y)\mathbb{1}_A) &= \mathbb{E}(h(X, Y)\mathbb{1}_B(Y)) \\ &= \sum_{y \in \mathcal{A}_Y} \mathbb{E}(h(X, Y)\mathbb{1}_B(Y)\mathbb{1}_{\{y\}}(Y)) \\ &= \sum_{y \in \mathcal{A}_Y} \mathbb{E}(h(X, y)\mathbb{1}_B(y)\mathbb{1}_y(Y)) \\ &= \sum_{y \in \mathcal{A}_Y} \mathbb{1}_B(y)\mathbb{E}(h(X, y)\mathbb{1}_y(Y)) \\ &= \sum_{y \in \mathcal{A}_Y} \mathbb{1}_B(y)\mathbb{P}(Y = y)\mathbb{E}(h(X, Y) | Y = y), \end{aligned}$$

donde

$$\mathbb{E}(h(X, Y) | Y = y) = \int h(X, y) d\mathbb{P}(\cdot | Y = y)$$

y

$$\mathbb{P}(A | Y = y) = \frac{\mathbb{P}(A \cap \{Y = y\})}{\mathbb{P}(Y = y)}.$$

Observar que

$$\mathbb{E}(h(X, y) \mid Y = y) = \frac{1}{\mathbb{P}(Y = y)} \int_{\{Y=y\}} h(X, y) d\mathbb{P} = \frac{1}{\mathbb{P}(Y = y)} \mathbb{E}(h(X, y) \mathbb{1}_y(Y)).$$

Luego, tenemos que

$$\begin{aligned} \sum_{y \in \mathcal{A}_Y} \mathbb{1}_B(y) \mathbb{P}(Y = y) \mathbb{E}(h(X, Y) \mid Y = y) &= \sum_{y \in \mathcal{A}_Y} g_h(y) \mathbb{1}_B(y) \mathbb{P}(Y = y) \\ &= \mathbb{E}(g_h(Y) \mathbb{1}_B(Y)) \\ &= \mathbb{E}(g_h(Y) \mathbb{1}_A), \end{aligned}$$

donde $g_h(y) := \mathbb{E}(h(X, y) \mid Y = y)$. Como además, $g_h(Y)$ es $\sigma(Y)$ -medible por el Lema, resulta

$$\mathbb{E}(h(X \mid Y) \mid Y) = g_h(Y).$$

Nota. Lo mismo vale si $\mathcal{G} = \sigma(A_n : n \in \mathbb{N})$ con $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{F}$ partición de Σ . En el caso anterior teníamos $A_y = \{Y = y\}$. En este caso, se obtiene

$$\mathbb{E}(h(X, Y) \mid \mathcal{G}) = \sum_{\substack{n \in \mathbb{N} \\ \mathbb{P}(A_n) > 0}} \mathbb{1}_{A_n} \mathbb{E}(h(X, Y) \mid A_n)$$

2. (X, Y) **vector discreto:** Sea ρ_{XY} la función de probabilidad puntual conjunta de (X, Y) . Recordemos que

$$\rho_Y(y) = \sum_{x \in \mathcal{A}_X} \rho_{XY}(x, y).$$

Entonces,

$$\begin{aligned} g_h(y) &= \mathbb{E}(h(X, y) \mid Y = y) \\ &= \sum_{x \in \mathcal{A}_X} h(x, y) \mathbb{P}(X = x \mid Y = y) \\ &= \sum_{x \in \mathcal{A}_X} h(x, y) \frac{\rho_{XY}(x, y)}{\rho_Y(y)}. \end{aligned}$$

La función

$$\rho_{X \mid Y=y}(x) := \frac{\rho_{XY}(x, y)}{\rho_Y(y)}$$

se llama la función de probabilidad puntual condicional de X dado $Y = y$ ($y \in \mathcal{A}_Y$).

3. (X, Y) **absolutamente continuo:** Por analogía con lo anterior, esperamos que

$$\mathbb{E}(h(X, Y) \mid Y) = g_h(Y)$$

donde

$$g_h(y) = \mathbb{E}(h(X, y) \mid Y = y) = \int h(X, y) d\mathbb{P}(\cdot \mid Y = y),$$

donde debemos darle sentido a $\mathbb{P}(\cdot | Y = y)$. Para ello, recordemos que

$$\mathbb{P}((X, Y) \in B) = \int_B d\mathbb{P}_{XY}(x, y) = \int_B f_{XY}(x, y) \, dx dy,$$

donde f_{XY} es la densidad. Formalmente, decimos que

$$d\mathbb{P}_{XY}(x, y) = f_{XY}(x, y) \, dx dy = \mathbb{P}_{XY}(dx, dy).$$

Por otro lado, Y tiene densidad

$$f_Y(y) = \int_{\mathbb{R}} f_{XY}(x, y) \, dx$$

($\int_B d\mathbb{P}_Y(y) = \mathbb{P}(Y \in B) = \int_B f_Y(y) \, dy$). Formalmente,

$$d\mathbb{P}_Y(y) = f_Y(y) \, dy = \mathbb{P}_Y(dy).$$

Con esto, podemos argumentar que

$$\begin{aligned} d\mathbb{P}_X(x | Y = y) &= \mathbb{P}_X(dx | Y = y) \approx \mathbb{P}_X(dx | Y \in dy) = \frac{\mathbb{P}(X \in dx, Y \in dy)}{\mathbb{P}(Y \in dy)} \\ &= \frac{\mathbb{P}_{XY}(dx, dy)}{\mathbb{P}_Y(dy)} = \frac{f_{XY}(x, y) \, dx dy}{f_Y(y) \, dy} = \frac{f_{XY}(x, y)}{f_Y(y)} \, dx. \end{aligned}$$

Por lo tanto, si definimos

$$\phi_y(x) := \begin{cases} \frac{f_{XY}(x, y)}{f_Y(y)} & \text{si } f_Y(y) > 0 \\ 0 & \text{si } f_Y(y) = 0 \end{cases}$$

y

$$g_h(y) := \int h(x, y) \phi_y(x) \, dx,$$

$g_h(Y)$ es un candidato para $\mathbb{E}(h(X, Y) | Y)$. Puede verificarse que, en efecto,

$$\mathbb{E}(h(X, Y) | Y) = g_h(Y).$$

La función

$$f_{X | Y=y} = \frac{f_{XY}(x, y)}{f_Y(y)} \quad (\text{con } f_Y(y) > 0),$$

se dice la densidad condicional de X dado $Y = y$.

4. **Caso general:** Si (X, Y) es un vector aleatorio cualquiera, puede mostrarse que

$$\mathbb{E}(h(X, Y) | Y) = g_h(Y),$$

donde $g_h(y) := \int h(x, y) \, dQ_y(x)$ (*), para una cierta medida Q_y que juega el rol de $\mathbb{P}_X(\cdot | Y = y)$.

Como queremos que g_h sea medible en y , para que (*) funcione. Necesitaremos que $y \mapsto Q_y$ sea medible (en algún sentido apropiado).

Las familias $(Q_y)_{y \in \mathbb{R}}$ que cumplen estas condiciones de medibilidad junto con (*) se llaman probabilidades condicionales regulares.

Ejemplo. 1. X, Y discretas, $Q_y = \mathbb{P}_X |_{Y=y}$.

2. (X, Y) absolutamente continuo, $dQ_y(x) = f_{X | Y=y} \, dx$.

e

3. X, Y independientes, $Q_y = \mathbb{P}_X \quad \forall y$.

Clase 17

27 de Abril

4.1 Probabilidad Condicional Regular

$\mathbb{E}(h(X, Y) \mid Y) = g_h(Y)$, donde

$$\begin{aligned} g_h(y) &:= \int_{\mathbb{R}} h(x, y) dQ_y(x), \\ Q_y &= \mathbb{P}_X(\cdot \mid Y = y), \\ g_h(y) &= \mathbb{E}(h(X, Y) \mid Y = y). \end{aligned}$$

Observación. 1. Esto generaliza la fórmula de *Probabilidad Total* cuando Y es discreta:

$$\mathbb{E}(h(X, Y)) = \sum_{y \in \mathcal{A}_Y} \mathbb{E}(h(X, Y) \mid Y = y) \mathbb{P}(Y = y).$$

se convierte en

$$\mathbb{E}(h(X, Y)) = \mathbb{E}(g_h(Y)) = \int_{\mathbb{R}} \underbrace{\mathbb{E}(h(X, Y) \mid Y = y)}_{g_h(y)} \mathbb{P}_Y(dy).$$

2. Esto generaliza el Teorema de Fubini al caso de medidas que no son producto:

$$\begin{aligned} \int_{\mathbb{R}^2} h d\mathbb{P}_{XY} &= \mathbb{E}(h(X, Y)) = \int_{\mathbb{R}} g_h(y) d\mathbb{P}_Y(y) \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} h(x, y) dQ_y(x) \mathbb{P}_Y(y). \end{aligned}$$

Chapter 5

Martingalas

Definición 5.1. Sea $(\Omega, \mathcal{F})$ un espacio medible. Una familia $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ de sub- σ -álgebras de $\mathcal{F}$ se llamará una *filtración* de $(\Omega, \mathcal{F})$ si

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots \subseteq \mathcal{F}_\infty := \sigma\left(\bigcup_{n \in \mathbb{N}} \mathcal{F}_n\right) \subseteq \mathcal{F}.$$

La terna $(\Omega, \mathcal{F}, (\mathcal{F}_n)_{n \in \mathbb{N}_0})$ se dice un *espacio (medible) filtrado*.

Definición 5.2. 1. Sea $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ una filtración de $(\Omega, \mathcal{F})$. Un proceso estocástico $(X_n)_{n \in \mathbb{N}_0}$ se dirá *adaptado* a $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ si X_n es $\mathcal{F}_n$ -medible para cada $n \in \mathbb{N}_0$.

2. Sea $X = (X_n)_{n \in \mathbb{N}_0}$ un proceso estocástico en $(\Omega, \mathcal{F}, \mathbb{P})$. Definimos la *filtración natural* $(\mathcal{G}_n)_{n \in \mathbb{N}_0}$ asociada a X como la menor filtración con respecto a la cual X es adaptado, i.e.

$$\mathcal{G}_n := \sigma(X_n, X_{n-1}, \dots, X_0).$$

Definición 5.3. Un proceso estocástico $X = (X_n)_{n \in \mathbb{N}_0}$ sobre un espacio filtrado $(\Omega, \mathcal{F}, (\mathcal{F}_n)_{n \in \mathbb{N}_0}, \mathbb{P})$ se dirá una *martingala* si

1. X es adaptado a $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$;
2. $\mathbb{E}(|X_n|) < \infty \quad \forall n \in \mathbb{N}_0$;
3. $\mathbb{E}(X_{n+1} \mid \mathcal{F}_n) = X_n \quad \forall n \in \mathbb{N}_0$.

Si reemplazamos a (3) por

- 3⁺. $\mathbb{E}(X_{n+1} \mid \mathcal{F}_n) \leq X_n$, X se dice una *supermartingala*.
- 3⁻. $\mathbb{E}(X_{n+1} \mid \mathcal{F}_n) \geq X_n$, X se dice *submartingala*.

Ejemplo. Sean

- $(\xi_i)_{i \in \mathbb{N}}$ VA's i.i.d. con $\mu := \mathbb{E}(\xi_i) \in \mathbb{R}$.

- $(S_n)_{n \in \mathbb{N}_0}$, $S_n := S_0 + \xi_1 + \dots + \xi_n$, $S_0 := \text{cte.}$
- $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ dada por $\mathcal{F}_n := \sigma(\xi_1, \dots, \xi_n)$, $\mathcal{F}_n := \{\emptyset, \Omega\}$.

Luego,

1. **Martingala Lineal** (o caminata aleatoria):

- Si $\mu = 0$, $(S_n)_{n \in \mathbb{N}_0}$ es una martingala:

$$\begin{aligned} \mathbb{E}(S_{n+1} \mid \mathcal{F}_n) &= \mathbb{E}(\xi_{n+1} + S_n \mid \mathcal{F}_n) = \mathbb{E}(\xi_{n+1} \mid \mathcal{F}_n) + S_n \\ &= \mathbb{E}(\xi_{n+1}) + S_n = S_n. \end{aligned}$$

(notar que en la segunda igualdad se usa que S_n es $\mathcal{F}_n$ -medible)

- Si $\mu \leq 0$, (S_n) es supermartingala.
 - Si $\mu \geq 0$, (S_n) es submartingala.
 - $(S_n - n\mu)_{n \in \mathbb{N}_0}$ es martingala $\forall \mu \in \mathbb{R}$.
2. **Martingala Cuadrática:** Si $\mu = 0$ y $\sigma^2 := \text{Var}(\xi_i) = \mathbb{E}(\xi_i^2)$, entonces $(S_n^2 - n\sigma^2)_{n \in \mathbb{N}_0}$ es martingala.
3. **Martingala Multiplicativa:** Si $(Y_n)_{n \in \mathbb{N}_0}$ son variables i.i.d. con $\mathbb{E}(Y_i) = 1$, entonces $(\prod_{i=0}^n Y_i)_{n \in \mathbb{N}_0}$ es una martingala (con respecto a su filtración natural).
4. **Martingalas Exponenciales:** Si $\phi(\theta) := \mathbb{E}(e^{\theta \xi_i}) < \infty$ e $Y_i := \frac{e^{\theta \xi_i}}{\phi(\theta)}$, entonces

$$M_n := \prod_{i=1}^n Y_i = \frac{e^{\theta S_n}}{(\phi(\theta))^n}$$

define una martingala.

5. **Proceso de Galton-Watson:** Si $(Z_n)_{n \in \mathbb{N}_0}$ es un proceso de Galton-Watson, i.e. $Z_n := \#$ individuos en la generación n (en un proceso de G-W con variable de reproducción X) y $\mu := \mathbb{E}(X)$, entonces $(\frac{Z_n}{\mu^n})_{n \in \mathbb{N}_0}$ es una martingala.
6. **Martingalas Cerradas:** Si $Z \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ filtración, entonces $(\mathbb{E}(Z \mid \mathcal{F}_n))_{n \in \mathbb{N}_0}$ es martingala.

Propiedad 5.4.

- Si $(X_n)_{n \in \mathbb{N}_0}$ es supermartingala, $\mathbb{E}(X_{n+k} \mid \mathcal{F}_n) \leq X_n \quad \forall k \in \mathbb{N}$.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es submartingala, $\mathbb{E}(X_{n+k} \mid \mathcal{F}_n) \geq X_n \quad \forall k \in \mathbb{N}$.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es martingala, $\mathbb{E}(X_{n+k} \mid \mathcal{F}_n) = X_n \quad \forall k \in \mathbb{N}$. En particular, toda martingala tiene esperanza constante.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es martingala y $\varphi: \mathbb{R} \rightarrow (-\infty, \infty]$ es convexa y tal que $\mathbb{E}(|\varphi(X_n)|) < \infty \quad \forall n \in \mathbb{N}$, entonces $(\varphi(X_n))_{n \in \mathbb{N}_0}$ es submartingala. En particular, si $(X_n)_{n \in \mathbb{N}_0}$ es martingala y $X_n \in L^p \quad \forall n$, entonces $(|X_n|^p)_{n \in \mathbb{N}}$ es submartingala si $p \geq 1$.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es submartingala y $\varphi: \mathbb{R} \rightarrow (-\infty, \infty]$ es convexa, creciente y tal que $\mathbb{E}(|\varphi(X_n)|) < \infty \quad \forall n \in \mathbb{N}$, entonces $(\varphi(X_n))_{n \in \mathbb{N}_0}$ es submartingala.

En particular,

- $(X_n)_{n \in \mathbb{N}_0}$ submartingala $\Rightarrow ((X_n - a)^+)_{n \in \mathbb{N}_0}$ submartingala $\forall a \in \mathbb{R}$.
- $(X_n)_{n \in \mathbb{N}_0}$ supermartingala $\Rightarrow ((X_n - a)^-)_{n \in \mathbb{N}_0}$ supermartingala $\forall a \in \mathbb{R}$.

Definición 5.5. Dada una filtración $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$, un proceso $(H_n)_{n \in \mathbb{N}}$ se dice *predecible* si H_n es $\mathcal{F}_{n-1}$ -medible $\forall n \in \mathbb{N}$.

En lo que sigue, pensaremos que H_n es el monto que un jugador apuesta a tiempo n : en este caso, tiene sentido que H_n sea decidido en base a los resultados de las jugadas a tiempo $1, 2, \dots, n-1$, pero NO a tiempo n .

Pregunta. Si pensamos a $(H_n)_{n \in \mathbb{N}}$ como estrategia de apuestas, ¿Cuánto dinero podemos ganar?

Sea $X_n :=$ cantidad neta de \$ ganada hasta tiempo n , si en cada jugada hubiéramos apostado \$1. Si apostamos de acuerdo a $(H_n)_{n \in \mathbb{N}}$, las ganancias a tiempo n serían

$$(H \cdot X)_n := \sum_{i=1}^n H_i(X_i - X_{i-1}) \text{ y } (H \cdot X)_0 := 0.$$

Alternativamente, X_i puede pensarse como el precio de una acción (a tiempo i) y H_i la cantidad de acciones que uno tiene en $[i-1, i]$. El proceso $\{(H \cdot X)_n\}_{n \in \mathbb{N}_0}$ se conoce como "*martingale transform*" de X por H o *integral estocástica discreta* de H con respecto a X .

Clase 18

29 de Abril

$H_i :=$ cuantos \$ apostamos en jugada i .
 $X_i :=$ ganancia neta acumulada hasta la jugada i si apostamos \$1 en cada jugada.
 $(H \cdot X)_n :=$ ganancia acumulada hasta tiempo N con estrategia $(H_i)_{i \in \mathbb{N}}$

$$= \sum_{i=1}^n H_i(X_i - X_{i-1}), \quad (H \cdot X)_0 := 0.$$

Teorema 5.6. Si $(X_n)_{n \in \mathbb{N}}$ es una super/sub/martingala y $(H_n)_{n \in \mathbb{N}}$ es predecible no negativo y acotado, entonces $(H \cdot X)$ es una super/sub/martingala.

Demostración. Vemos sólo el caso de $(X_n)_{n \in \mathbb{N}}$ martingala.

1. $\mathbb{E}(|(H \cdot X)_n|) < \infty$ para todo n pues $X_n \in L^1 \quad \forall n \in \mathbb{N}$ y $(H_i)_{i \in \mathbb{N}}$ es acotada.
2. $(H \cdot X)_n$ es $\mathcal{F}_n$ -medible por ser suma y producto de $\mathcal{F}_n$ -medibles.
3. $\mathbb{E}((H \cdot X)_{n+1} \mid \mathcal{F}_{n+1}) = (H \cdot X)_n + \mathbb{E}(H_{n+1}(X_{n+1} - X_n) \mid \mathcal{F}_n) = (H \cdot X)_n + H_{n+1}(\underbrace{\mathbb{E}(X_{n+1} \mid \mathcal{F}_n) - X_n}_0) = (H \cdot X)_n. \quad \square$

Observación. La condición $(H_n)_{n \in \mathbb{N}}$ acotado sólo se usa para ver que $H_n(X_n - X_{n-1}) \in L^1$. En particular, si $H_{n+1}, X_n \in L^2 \quad \forall n \in \mathbb{N}_0$, entonces el resultado vale.

Definición 5.7. Una variable aleatoria T a valores en $\mathbb{N}_0 \cup \{\infty\}$ se dice un *tiempo de parada* (o "stopping time") si $\{T \leq n\} \in \mathcal{F}_n \quad \forall n \in \mathbb{N}_0$.

Ejemplo.

- $T := \inf\{n \in \mathbb{N} : (H \cdot X)_n > \$1000\}$ es un tiempo de parada.
- $T := \sup\{n \in \mathbb{N} : (H \cdot X)_n > \$1000\}$ NO es un tiempo de parada.

Propiedad 5.8.

- T tiempo de parada $\Leftrightarrow \{T = n\} \in \mathcal{F}_n \quad \forall n \in \mathbb{N}_0$.
- $T \equiv m$ es tiempo de parada $\forall m \in \mathbb{N}_0$.
- S, T tiempos de parada $\Rightarrow T \wedge S, T \vee S, S + T$ tiempos de parada.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es un proceso estocástico y T es finito, entonces $X_T(\omega) := X_{T(\omega)}(\omega)$ es una variable aleatoria.

Definición 5.9. Dado un tiempo de parada T , definimos la σ -álgebra $\mathcal{F}_T$ de eventos ocurridos hasta tiempo T como

$$\mathcal{F}_T := \{B \in \mathcal{F} : B \cap \{T \leq n\} \in \mathcal{F}_n \quad \forall n \in \mathbb{N}_0\}.$$

Propiedad 5.10. Sean S, T tiempos de parada.

1. T es $\mathcal{F}_T$ -medible;
2. $A \in \mathcal{F}_T \Leftrightarrow A \cap \{T = n\} \in \mathcal{F}_n \quad \forall n \in \mathbb{N}_0$;
3. Si $(X_n)_{n \in \mathbb{N}_0}$ es un proceso estocástico y T es finito, entonces X_T es $\mathcal{F}_T$ -medible;
4. $\mathcal{F}_{T \wedge S} = \mathcal{F}_T \cap \mathcal{F}_S$ y $\mathcal{F}_{T \vee S} = \mathcal{F}_T \vee \mathcal{F}_S := \sigma(\mathcal{F}_T \cup \mathcal{F}_S)$.

Teorema 5.11 (Parada Opcional). Si $(X_n)_{n \in \mathbb{N}_0}$ es una super/sub/martingala y T es un tiempo de parada, entonces:

- i) El proceso parado $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ es una super/sub/martingala.
- ii) Si $S \leq T$ son tiempos de parada acotados, $\mathbb{E}(X_T \mid \mathcal{F}_S) = X_S$, donde la igualdad se reemplaza con $\leq$ en el caso de super y por $\geq$ en el caso de submartingala.

En particular, $\mathbb{E}(X_T) = \mathbb{E}(X_S)$ y, tomando $S = 0$, $\mathbb{E}(X_T) = \mathbb{E}(X_0)$ (esto último vale $\forall$ tiempo de Parada acotado T .) (la igualdad se reemplaza según la misma regla anterior.)

Demostración. i) Si $H_n := \mathbb{1}_{\{n \leq T\}}$, entonces:

- $(H_n)_{n \in \mathbb{N}}$ es predecible:

$$\{n \leq T\} = \{T \leq n-1\}^c \in \mathcal{F}_{n-1} \quad \forall n \in \mathbb{N};$$

- $(H_n)_{n \in \mathbb{N}}$ acotado y no negativo;
- se tiene que:

$$(H \cdot X)_n = \sum_{i=1}^{T \wedge n} 1 \cdot (X_i - X_{i-1}) = X_{T \wedge n} - X_0.$$

Por resultado anterior, $(H \cdot X)$ es super/sub/martingala y $Y_n := X_0$ también lo es. Como $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ resulta suma de 2 super/sub/martingalas, vale (i).

- ii) Ya sabemos que X_S es $\mathcal{F}_S$ -medible. Sólo debemos ver que

$$\mathbb{E}(X_T \mathbb{1}_A) = \mathbb{E}(X_S \mathbb{1}_A) \quad \forall A \in \mathcal{F}_S.$$

(con la igualdad reemplazada respectivamente.)

Dado $A \in \mathcal{F}_S$, definimos $H_n := \mathbb{1}_A \cdot \mathbb{1}_{\{S < n \leq T\}} = \mathbb{1}_{A \cap \{S \leq n-1\}} \cdot \mathbb{1}_{\{n \leq T\}}$.
Tenemos que:

- $(H_n)_{n \in \mathbb{N}_0}$ es acotado, no negativo y predecible;
- $X_T, X_S \in L^1$ ($|X_T| \leq \sum_{i=1}^K |X_i|$ con $T \leq K$);
- $(H \cdot X)_K = \mathbb{1}_A(X_T - X_S)$ si $S, T \leq K$.

Ahora, si $(X_n)_{n \in \mathbb{N}_0}$ es supermartingala, $(H \cdot X)$ también, y luego $\mathbb{E}((H \cdot X)_K) \leq \mathbb{E}((H \cdot X)_0) = 0$. Es decir, $\mathbb{E}(\mathbb{1}_A X_T) \leq \mathbb{E}(\mathbb{1}_A X_S)$ $X_S, X_T \in L^1$. Esto implica que

$$\mathbb{E}(\mathbb{1}_A \mathbb{E}(X_T | \mathcal{F}_S)) \leq \mathbb{E}(\mathbb{1}_A X_S) \quad \forall A \in \mathcal{F}_S;$$

ó, equivalentemente,

$$\mathbb{E}(\mathbb{1}_A (X_S - \mathbb{E}(X_T | \mathcal{F}_S))) \geq 0 \quad \forall S \in \mathcal{F}_S.$$

Como $X_S - \mathbb{E}(X_T | \mathcal{F}_S)$ es $\mathcal{F}_S$ -medible, esto implica que $\mathbb{P}(X_S < \mathbb{E}(X_T | \mathcal{F}_S)) = 0$. Multiplicando por (-1) obtenemos el resultado para submartingalas y, combinando ambas, para martingalas. $\square$

Observación. Si $(X_n)_{n \in \mathbb{N}_0}$ es una super/sub/martingala, NO es necesariamente cierto que $\mathbb{E}(X_T) = \mathbb{E}(X_S)$ (con la igualdad reemplazada respectivamente con la misma regla anterior) si T no es acotado.

En efecto, sea $S_n := -1 + \xi_1 + \dots + \xi_n$ una caminata aleatoria con $(\xi_i)_{i \in \mathbb{N}}$ i.i.d., $\mathbb{P}(\xi_i = \pm 1)$ y $T := \inf\{n : S_n = 0\}$. Entonces, $\mathbb{E}(S_n) = -1 \quad \forall n \in \mathbb{N}$, pero $\mathbb{E}(S_T) = \mathbb{E}(0) = 0 > \mathbb{E}(S_0)!!!$ (donde la primera igualdad está dada porque T es finito.)

Clase 19

6 de Mayo

Supongamos que $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala, que representa la evolución del precio de una acción de una empresa. Queremos implementar la estrategia de "comprar barato y vender caro" para intentar sacar rédito.

Más precisamente, dados $a < b \in \mathbb{R}$, queremos definir la estrategia $(H_n)_{n \in \mathbb{N}}$ en la que compramos una acción cada vez que su precio caiga de "a" y la vendemos apenas su valor supere "b". Para esto, usamos tiempos de parada.

Definimos $(T_k)_{k \in \mathbb{N}_0}$ como:

- $T_0 \equiv -1$;
- $T_{2k-1} := \inf\{n > T_{2k-2} : X_n \leq a\} \quad (k \in \mathbb{N})$;
- $T_{2k} := \inf\{n > T_{2k-1} : X_n \geq b\} \quad (k \in \mathbb{N})$.

Puede verificarse que $(T_k)_{k \in \mathbb{N}_0}$ son tiempos de parada.

La estrategia que buscamos es

$$H_n := \begin{cases} 1 & \text{si } T_{2k-1} < n \leq T_{2k} \quad (k \in \mathbb{N}_0) \\ 0 & \text{en caso contrario.} \end{cases}$$

Observar que:

1. Cada vez que el precio "cruza" desde " $\leq a$ " a " $\geq b$ ", la ganancia acumulada es $\geq b - a$.
2. Si a tiempo n tengo una acción y decido venderla (posiblemente antes de tiempo!), voy a perder dinero si $X_n \leq$ precio de la última compra ($\leq a$). En cualquier caso, lo máximo que puedo perder es $(X_n - a)^-$.

En particular, la ganancia neta a tiempo n es

$$(H \cdot X)_n \geq (b - a)U_n^{a,b} - (X_n - a)^-$$

donde $U_n^{a,b} := \sup\{k : T_{2k} \leq n\}$.

Teorema 5.12 (Lema de Upcrossings de Doob). Si $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala y $a < b \in \mathbb{R}$, entonces

$$(b - a)\mathbb{E}(U_n^{a,b}) \leq \mathbb{E}((X_n - a)^-).$$

Teorema 5.13 (de convergencia de supermartingalas). Si $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala tal que $\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^-) < \infty$, entonces $X_n \xrightarrow{c.s.} X_\infty$, donde el límite X_∞ cumple $\mathbb{E}(|X_\infty|) < \infty$.

Demostración. Como $(X_n - a)^- \leq X_n^- + |a|$, el resultado anterior implica que

$$\mathbb{E}(U_n^{a,b}) \leq \frac{|a| + \mathbb{E}(X_n^-)}{b - a}.$$

Como $U_n^{a,b} \nearrow U^{a,b} := \#$ cruces de a hasta b , por TCM

$$\mathbb{E}(U_n^{a,b}) \leq \frac{|a| + \sup_n \mathbb{E}(X_n^-)}{b - a} < \infty.$$

En particular, $U^{a,b} < \infty$ casi seguramente.

Pero entonces,

$$\begin{aligned} \Lambda &:= \{\omega \in \Omega : (X_n(\omega))_{n \in \mathbb{N}} \text{ no converge en } \overline{\mathbb{R}}\} \\ &= \{\omega : \liminf_{n \rightarrow \infty} X_n(\omega) < \limsup_{n \rightarrow \infty} X_n(\omega)\} \\ &= \bigcup_{\substack{a, b \in \mathbb{Q} \\ a < b}} \{\omega : \liminf_{n \rightarrow \infty} X_n(\omega) < a < b < \limsup_{n \rightarrow \infty} X_n(\omega)\} \\ &\subseteq \bigcup_{a < b \in \mathbb{Q}} \{\omega : U^{a,b}(\omega) = \infty\} \end{aligned}$$

Luego, $\mathbb{P}(\Lambda) = 0$ y, por lo tanto, $X_\infty := \liminf_{n \rightarrow \infty} X_n$ cumple $X_n \xrightarrow{c.s.} X_\infty$.

Falta ver que $X_\infty \in L^1$.

$$\begin{aligned}\mathbb{E}(X_\infty^-) &\leq \liminf_{n \rightarrow \infty} \mathbb{E}(X_n^-) \\ \mathbb{E}(X_\infty^+) &\leq \liminf_{n \rightarrow \infty} \mathbb{E}(X_n^+) \quad (\leq C)\end{aligned}\tag{*}$$

por el lema de Fatou, pues $X_n^\pm \xrightarrow{c.s.} X_\infty^\pm$.

Por un lado,

$$\liminf_{n \rightarrow \infty} \mathbb{E}(X_n^-) \leq \sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^-) < \infty.$$

Por otro lado,

$$\begin{aligned}\mathbb{E}(X_n^+) &= \mathbb{E}(X_n) + \mathbb{E}(X_n^-) \\ &\leq \mathbb{E}(X_0) + \sup_{k \in \mathbb{N}_0} \mathbb{E}(X_k^-) =: C < \infty,\end{aligned}$$

con lo cual

$$\liminf_{n \rightarrow \infty} \mathbb{E}(X_n^+) \leq C < \infty$$

y así $X_\infty \in L^1$. □

Corolario 5.14. Si $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala no negativa, entonces $X_n \xrightarrow{c.s.} X_\infty$ y $\mathbb{E}(X_\infty) \leq \mathbb{E}(X_0)$.

Demostración. Basta notar que $X_n^- = 0$ c.s. con lo cual $\mathbb{E}(X_n^-) = 0$ y así podemos usar el Teorema anterior. Que $\mathbb{E}(X_\infty) \leq \mathbb{E}(X_0)$ se deduce de (*), pues en este caso $X_\infty^+ = X_\infty$ c.s. y $C = \mathbb{E}(X_0)$. □

Corolario 5.15. Si $(X_n)_{n \in \mathbb{N}_0}$ es una maringala acotada en L^1 (i.e. $\sup_{n \in \mathbb{N}} \|X_n\|_1 < \infty$), entonces $X_n \xrightarrow{c.s.} X_\infty \in L^1$. (En general, no es cierto que $X_n \xrightarrow{L^1} X_\infty$.)

Demostración. $(X_n)_{n \in \mathbb{N}}$ martingala. Como $(X_n)_{n \in \mathbb{N}}$ es submartingala $\Rightarrow (X_n^+)_{n \in \mathbb{N}}$ supermartingala. Dado que $\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^+) < \infty \Rightarrow X_n^+ \xrightarrow{c.s.} X_\infty^+ \in L^1$.

$(X_n)_{n \in \mathbb{N}}$ martingala. Como $(X_n)_{n \in \mathbb{N}}$ es supermartingala $\Rightarrow (X_n^-)_{n \in \mathbb{N}}$ submartingala. Dado que $\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^-) < \infty \Rightarrow X_n^- \xrightarrow{c.s.} X_\infty^- \in L^1$. □

5.0.1 Contraejemplo para la convergencia en L^1

Sea $S_n := 1 + \xi_1 + \dots + \xi_n$ con $(\xi_n)_{n \in \mathbb{N}}$ i.i.d. $\mathbb{P}(\xi_n = \pm 1) = \frac{1}{2}$. Definimos

$$\begin{aligned}T &:= \inf\{n : S_n = 0\} \\ X_n &:= S_{T \wedge n}.\end{aligned}$$

Por el Teorema de P.O., $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala. Como $X_n \geq 0 \quad \forall n \in \mathbb{N}$, por el Teorema de reci n, $X_n \xrightarrow{c.s.} X_\infty \in L^1$. Como $X_n \in \mathbb{Z} \quad \forall n \in \mathbb{N}$, $X_\infty \in \mathbb{Z}$ tambi n. De hecho, $X_\infty \equiv 0$ c.s. Pero, como $\mathbb{E}(X_n) = \mathbb{E}(S_{T \wedge n}) = \mathbb{E}(S_0) = 1$ (donde la segunda igualdad est  dada por P.O. con tiempo $T \wedge n$ acotado.), esto implica que $\mathbb{E}(X_n) \longrightarrow \underbrace{\mathbb{E}(X_\infty)}_{=0} = 0$ y, por lo tanto, $X_n \not\xrightarrow{L^1} X_\infty$.

Clase 20

8 de Mayo

Teorema 5.16 (Convergencia de super/submartingalas).

- Si $(X_n)_{n \in \mathbb{N}_0}$ es una supermartingala con $\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^-) < \infty$ entonces $X_n \xrightarrow{c.s.} X_\infty \in L^1$.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es una submartingala con $\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^+) < \infty$ entonces $X_n \xrightarrow{c.s.} X_\infty \in L^1$.

Corolario 5.17.

- Si $(X_n)_{n \in \mathbb{N}_0}$ es supermartingala no negativa, entonces $X_n \xrightarrow{c.s.} X_\infty \in L^1$, con $\mathbb{E}(X_\infty) \leq \mathbb{E}(X_0)$.
- Si $(X_n)_{n \in \mathbb{N}_0}$ es una martingala con $\sup_{n \in \mathbb{N}_0} \mathbb{E}(|X_n|) < \infty$ entonces $X_n \xrightarrow{c.s.} X_\infty \in L^1$.

5.0.2 Contraejemplo $(X_n \not\xrightarrow{L^1} X_\infty)$

$X_n := S_{T \wedge n}$, donde

$$S_n := 1 + \xi_1 + \cdots + \xi_n$$

$$T = \inf\{n \in \mathbb{N}_0 : S_n = 0\},$$

con $(\xi_i)_{i \in \mathbb{N}}$ i.i.d. $\mathbb{P}(\xi_i = \pm 1) = \frac{1}{2}$.

Vimos que $(X_n)_{n \in \mathbb{N}_0}$ es martingala no negativa, por lo tanto $X_n \xrightarrow{c.s.} X_\infty \in L^1$. Adem s, $X_\infty \in \mathbb{Z}$ casi seguramente.

En realidad, $X_\infty = 0$ $\mathbb{P}$ -c.s. En efecto, si $X_n(\omega) \longrightarrow X_\infty(\omega)$, $(X_n(\omega))$ es eventualmente constante. En particular, $X_{n+1}(\omega) - X_n(\omega) = 0 \quad \forall n \geq n_0(\omega)$. Pero, como $X_{n+1}(\omega) - X_n(\omega) = \pm 1$ si $n < T(\omega)$, esto implica que $T(\omega) \leq n_0(\omega)$ y, por lo tanto, que $X_\infty(\omega) = X_{T(\omega)}(\omega) = S_{T(\omega)} = 0$. Pero, como $\mathbb{E}(X_n) = \mathbb{E}(S_{T \wedge n}) = \mathbb{E}(S_0) = 1 \quad \forall n \in \mathbb{N}$ (donde la segunda igualdad est  dada por P.O. con $T \wedge n$ acotado), vemos que $\mathbb{E}(X_n) \not\longrightarrow \mathbb{E}(X_\infty) = 0$ y, por ende $X_n \not\xrightarrow{L^1} X_\infty$.

Observaci n. En particular, esto muestra que $\mathbb{P}(T = \infty) = 0$.

Comentarios.

1. Si $(X_n)_{n \in \mathbb{N}_0}$ es una (super/sub)martingala tal que $X_n \xrightarrow{c.s.} X_\infty$, podemos definir ahora X_T para tiempos de parada T que no sean finitos.

$$X_T(\omega) := \begin{cases} X_n(\omega) & \text{si } T(\omega) = n \\ X_\infty(\omega) & \text{si } T(\omega) = \infty. \end{cases}$$

2. Vimos que si $(X_n)_{n \in \mathbb{N}_0}$ es supermartingala, no es cierto en general que $\mathbb{E}(X_T) \leq \mathbb{E}(X_0)$, a menos que T sea acotado. Sin embargo, tenemos lo siguiente.

Proposición 5.18. Si $(X_n)_{n \in \mathbb{N}_0}$ es supermartingala no negativa y $T \in N_0 \cup \{\infty\}$ es un tiempo de parada, entonces $\mathbb{E}(X_T) \leq \mathbb{E}(X_0)$.

Demostración. Se cumple que

$$\begin{aligned} \mathbb{E}(X_T) &= \mathbb{E}\left(\lim_{n \rightarrow \infty} \underbrace{X_{T \wedge n}}_{\geq 0}\right) \\ (\text{Fatou}) &\leq \liminf_{n \rightarrow \infty} \mathbb{E}(X_{T \wedge n}) \\ &\leq \mathbb{E}(X_0). \end{aligned}$$

(Notar que la última desigualdad está dada por: P.O. con $T \wedge n$ t.d.p. acotado) $\square$

Observación. Si $(X_n)_{n \in \mathbb{N}_0}$ es martingala no negativa, no valdrá que $\mathbb{E}(X_T) = \mathbb{E}(X_0)$ (pero si $\mathbb{E}(X_T) \leq \mathbb{E}(X_0)$).

5.1 Convergencia de Martingalas en L^p ($p > 1$)

Proposición 5.19 (Desigualdad maximal de Doob). Sea $(X_n)_{n \in \mathbb{N}_0}$ una submartingala y definamos $X_n^* := \max_{0 \leq k \leq n} X_k^+$. Entonces, dado $\lambda > 0$,

$$\lambda \mathbb{P}(X_n^* \geq \lambda) \leq \mathbb{E}(X_n^+ \mathbf{1}_{\{X_n^* \geq \lambda\}}) \leq \mathbb{E}(X_n^+).$$

Demostración. Sean

$$\begin{aligned} T &:= \inf\{k : X_k^+ \geq \lambda\} \wedge n \\ A &:= \{X_n^+ \geq \lambda\}. \end{aligned}$$

Como T es tiempo de parada acotado y $X_T^+ \geq \lambda$ en A ,

$$\lambda \mathbb{P}(A) \leq \lambda \mathbb{P}(\{X_T^+ \geq \lambda\} \cap A) \leq \mathbb{E}(X_T^+ \mathbf{1}_A). \quad (*)$$

Por otro lado, como $\mathbb{E}(X_T^+) \leq \mathbb{E}(X_n^+)$ por el Teorema de P.O. para $(X_n^+)_{n \in \mathbb{N}_0}$, vale que

$$\mathbb{E}(X_T^+ \mathbf{1}_A) + \mathbb{E}(X_T^+ \mathbf{1}_{A^c}) = \mathbb{E}(X_T^+) \leq \mathbb{E}(X_n^+) = \mathbb{E}(X_n^+ \mathbf{1}_A) + \mathbb{E}(X_n^+ \mathbf{1}_{A^c}).$$

Pero, como en A^c tenemos que $X_T^+ = X_n^+$, concluimos que

$$\mathbb{E}(X_T^+ \mathbf{1}_A) \leq \mathbb{E}(X_n^+ \mathbf{1}_A).$$

Juntando con (*), esto prueba la desigualdad izquierda de la proposición. La otra es inmediata. $\square$

Teorema 5.20 (Desigualdad maximal en L^p , $p > 1$). Si $(X_n)_{n \in \mathbb{N}_0}$ es una submartingala y $p \in (1, \infty)$ entonces

$$\|X_n^*\|_p \leq \frac{p}{p-1} \|X_n^+\|_p.$$

En particular, si $(Y_n)_{n \in \mathbb{N}_0}$ es martingala, entonces

$$\left\| \max_{0 \leq k \leq n} |Y_k| \right\|_p \leq \frac{p}{p-1} \|Y_n\|_p.$$

Demostración. Se cumple que

$$\begin{aligned} \mathbb{E}((X_n^*)^p) &\stackrel{\text{F-T}}{=} \int_0^\infty p\lambda^{p-1} \mathbb{P}(X_n^* \geq \lambda) d\lambda \\ (\text{D.M. de Doob}) &\leq \int_0^\infty p\lambda^{p-1} \frac{1}{\lambda} \mathbb{E}(X_n^+ \mathbf{1}_{\{X_n^* \geq \lambda\}}) d\lambda \\ (\text{F-T}) &= \mathbb{E}\left(X_n^+ \int_0^{X_n^*} p\lambda^{p-2} d\lambda\right) \\ &= \frac{p}{p-1} \mathbb{E}(X_n^+ (X_n^*)^{p-1}) \\ (\text{Hölder}) &\leq \frac{p}{p-1} \|X_n^+\|_p \|X_n^*\|_p^{p-1}. \end{aligned}$$

En conclusión,

$$(\|X_n^*\|_p)^p \leq \frac{p}{p-1} \|X_n^+\|_p (\|X_n^*\|_p)^{p-1}.$$

- Si $\|X_n^*\|_p < \infty$, pasamos dividiendo y listo.
- Si $\|X_n^*\|_p = \infty$, probamos el resultado primero para $X_n^* \wedge M$, y luego, tomamos el límite con $M \rightarrow \infty$ para obtener la desigualdad.

La afirmación para $(Y_n)_{n \in \mathbb{N}_0}$ se obtiene aplicando lo anterior a $X_n := |Y_n|$. $\square$

Observación. La desigualdad no vale si $p = 1$.

Teorema 5.21. Si $(X_n)_{n \in \mathbb{N}_0}$ es una martingala y $p \in (1, \infty)$, son equivalentes:

1. $(X_n)_{n \in \mathbb{N}_0}$ es acotado en L^p ; i.e., $\sup_{n \in \mathbb{N}_0} \|X_n\|_p < \infty$.
2. $X_n \xrightarrow[L^p]{c.s.} X_\infty$.
3. $\exists Z \in L^p$ tal que $X_n = \mathbb{E}(Z \mid \mathcal{F}_n)$.

Demostración. $i) \Rightarrow ii)$ Como $\sup_{n \in \mathbb{N}_0} \|X_n\|_1 \leq \sup_{n \in \mathbb{N}_0} \|X_n\|_p < \infty$, sabemos que $X_n \xrightarrow{c.s.} X_\infty \in L^1$.

Por Fatou,

$$\|X_\infty\|_p \leq \liminf_{n \rightarrow \infty} \|X_n\|_p \leq \sup_{n \in \mathbb{N}_0} \|X_n\|_p < \infty$$

y luego $X_\infty \in L^p$.

Por otro lado, por la desigualdad maximal en L^p ,

$$\mathbb{E}\left(\left(\sup_{0 \leq k \leq n} |X_k|^p\right)\right) \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}(|X_n|^p) \leq \left(\frac{p}{p-1}\right)^p \left(\sup_{k \in \mathbb{N}_0} \|X_k\|_p\right)^p,$$

de modo que, tomando $n \rightarrow \infty$ en esta desigualdad,

$$\mathbb{E}\left(\left(\sup_{n \in \mathbb{N}_0} |X_n|^p\right)\right) \leq \left(\frac{p}{p-1}\right)^p \sup_{k \in \mathbb{N}_0} \|X_k\|_p^p < \infty.$$

Entonces, como

$$|X_n - X_\infty|^p \leq \left(2 \sup_{k \in \mathbb{N}_0} |X_k|\right)^p,$$

por T.C.D. $\mathbb{E}(|X_n - X_\infty|^p) \xrightarrow{n \rightarrow \infty} 0$ y así, $X_n \xrightarrow{L^p} X_\infty$. $\square$

Clase 21

11 de Mayo

Continuamos con la demostración que quedó pendiente la clase pasada:

Demostración. $ii) \Rightarrow ii)$ Recordamos $\|\mathbb{E}(Y | \mathcal{G})\|_p \leq \|Y\|_p$ (esperanza condicional es continua en L^p). Luego, si $X_n \xrightarrow{L^p} X_\infty$, entonces

$$\mathbb{E}(X_n | \mathcal{F}) \xrightarrow{L^p} \mathbb{E}(X_\infty | \mathcal{G}) \quad \forall \mathcal{G} \subseteq \mathcal{F} \text{ } \sigma\text{-álgebra.}$$

En particular, si fijamos $n \in \mathbb{N}_0$ y tomamos $\mathcal{G} = \mathcal{F}_n$, para $m \geq n$,

$$X_n = \mathbb{E}(X_m | \mathcal{F}_n) \xrightarrow{m \rightarrow \infty} \mathbb{E}(X_\infty | \mathcal{F}_n).$$

Por lo tanto, $X_n = \mathbb{E}(X_\infty | \mathcal{F}_n)$ ($Z = X_\infty$).

$iii) \Rightarrow i)$ Notar que por Jensen condicional,

$$\|X_n\|_p = \|\mathbb{E}(Z | \mathcal{F}_n)\|_p \leq \|Z\|_p.$$

Con lo cual,

$$\sup_{n \in \mathbb{N}} \|X_n\|_p \leq \|Z\|_p < \infty.$$

$\square$

Comentarios. Una martingala que cumple (3) (que es la esperanza condicional de una única variable) se dice *cerrada* (en L^p). A cualquier variable Z que cumple (3) se la llama una "última variable" para $(X_n)_{n \in \mathbb{N}_0}$ (porque si $m \geq n$ entonces $\mathbb{E}(X_n | \mathcal{F}_n) = X_n$ y, visto así, Z vendría "después" que toda X_n).

Observar que, en tal caso, vale que $X_\infty = \mathbb{E}(Z \mid \mathcal{F}_\infty)$ pues:

- $X_\infty := \limsup_{n \rightarrow \infty} X_n$ es $\mathcal{F}_\infty$ -medible pues cada X_n lo es,
- Si $A \in \mathcal{F}_n$,

$$\begin{aligned} \mathbb{E}(X_\infty \mathbb{1}_A) &= \lim_{m \rightarrow \infty} \mathbb{E}(X_m \mathbb{1}_A) && \text{(pues } X_m \xrightarrow{L^1} X_\infty) \\ &= \mathbb{E}(X_n \mathbb{1}_A) && \text{(pues } \mathbb{E}(X_m \mid \mathcal{F}_n) = X_n \text{ si } m \geq n) \\ &= \mathbb{E}(Z \mathbb{1}_A). && (X_n = \mathbb{E}(Z \mid \mathcal{F}_n)) \end{aligned}$$

Es decir,

$$\mathbb{E}(X_\infty \mathbb{1}_A) = \mathbb{E}(Z \mathbb{1}_A) \quad \forall A \in \bigcup_{n \in \mathbb{N}_0} \mathcal{F}_n.$$

Como $\bigcup_{n \in \mathbb{N}_0} \mathcal{F}_n$ es un π -sistema que genera $\mathcal{F}_\infty$ y además contiene a Ω ,

$$\mathbb{E}(X_\infty \mathbb{1}_A) = \mathbb{E}(Z \mathbb{1}_A) \quad \forall A \in \mathcal{F}_\infty,$$

y luego, $X_\infty = \mathbb{E}(Z \mid \mathcal{F}_\infty)$.

Observación. La demostración prueba que, en particular, dado $p \geq 1$, si $(X_n)_{n \in \mathbb{N}_0}$ es una martingala acotada en L^p que satisface la desigualdad maximal en L^p entonces $(X_n)_{n \in \mathbb{N}_0}$ converge en L^p .

Esto nos dice que la desigualdad maximal no puede valer en $p = 1$, ya que vimos un ejemplo de martingala acotada en L^1 que no converge.

Definición 5.22. Una colección de VA's $(X_i)_{i \in I}$ se dice *uniformemente integrable (UI)* si

$$\lim_{M \rightarrow \infty} \left(\sup_{i \in I} \int_{\{|X_i| > M\}} |X_i| d\mathbb{P} \right) = 0.$$

Observación. 1. $(X_i)_{i \in I}$ UI $\Rightarrow (X_i)_{i \in I}$ acotada en L^1 .

$$\begin{aligned} \sup_{i \in I} \mathbb{E}(|X_i|) &\leq M + \sup_{i \in I} \mathbb{E}(|X_i| \mathbb{1}_{\{|X_i| > M\}}) \\ &\leq M + 1 < \infty. \end{aligned}$$

2. $(X_i)_{i \in I}$ acotada en $L^1 \not\Rightarrow (X_i)_{i \in I}$ UI. Por ejemplo: $U \sim \mathcal{U}([0, 1])$, $X_n := n \cdot \mathbb{1}_{\{U \in [0, 1/n]\}}$.

- $(X_n)_{n \in \mathbb{N}}$ acotada en L^1 :

$$\mathbb{E}(|X_n|) = \mathbb{E}(X_n) = n \cdot \mathbb{P}(U \in [0, \frac{1}{n}]) = 1.$$

- $(X_n)_{n \in \mathbb{N}}$ no es UI, pues, si $n > M$,

$$\mathbb{E}(|X_n| \mathbb{1}_{\{|X_n| > M\}}) = \mathbb{E}(X_n \mathbb{1}_{X_n \neq 0}) = \mathbb{E}(X_n) = 1 \not\rightarrow 0.$$

Ejemplo. 1. Si $(X_i)_{i \in I}$ está acotada en L^p con $p \in (1, \infty]$, entonces es UI.

2. Si I es finito y $X_i \in L^1 \quad \forall i \in I$, entonces $(X_i)_{i \in I}$ es UI.

3. Si $X_n \xrightarrow{L^1} X_\infty$, entonces $(X_n)_{n \in \mathbb{N}}$ es UI.
4. **Convergencia Dominada:** si existe $Y \in L^1$ tal que $\sup_{i \in I} |X_i| \leq Y$, entonces $(X_i)_{i \in I}$ es UI.
5. Si $X \in L^1$, entonces

$$\mathcal{C} := \{\mathbb{E}(X \mid \mathcal{G}) : \mathcal{G} \subseteq \mathcal{F} \text{ } \sigma\text{-álgebra}\}$$

es UI.

Teorema 5.23. Sea $(X_n)_{n \in \mathbb{N}} \subseteq L^1$ tal que $X_n \xrightarrow{\mathbb{P}} X$. Son equivalentes:

- i) $(X_n)_{n \in \mathbb{N}}$ es UI.
- ii) $X_n \xrightarrow{L^1} X$.
- iii) $\mathbb{E}(|X_n|) \rightarrow \mathbb{E}(|X|) < \infty$.

Teorema 5.24. Si $(X_n)_{n \in \mathbb{N}_0}$ es una super/sub/maringala, entonces, son equivalentes:

- i) $(X_n)_{n \in \mathbb{N}_0}$ es UI.
- ii) $X_n \xrightarrow[L^1]{c.s.} X_\infty \in L^1$.
- iii) $X_n \xrightarrow{L^1} X_\infty \in L^1$.

Además, en tal caso, vale que $\mathbb{E}(X_\infty \mid \mathcal{F}_n) = X_n \quad \forall n \in \mathbb{N}$ (reemplazando la igualdad con $\leq$ para supermartingala y con $\geq$ para submartingala).

Demostración. Supongamos $(X_n)_{n \in \mathbb{N}_0}$ supermartingala.

i) $\Rightarrow$ ii) Como

$$\sup_{n \in \mathbb{N}_0} \mathbb{E}(X_n^-) \leq \sup_{n \in \mathbb{N}_0} \|X_n\|_1 < \infty,$$

pues $(X_n)_{n \in \mathbb{N}_0}$ es UI, por el Teo. de Conv. de supermartingalas

$$X_n \xrightarrow{c.s.} X_\infty \in L^1.$$

Además, como $(X_n)_{n \in \mathbb{N}_0}$ es UI, $X_n \xrightarrow{L^1} X_\infty$.

ii) $\Rightarrow$ iii) Es inmediato.

iii) $\Rightarrow$ i) Por el Teorema anterior, pues $X_n \xrightarrow{\mathbb{P}} X_\infty$.

Por último, por la contiunidad en L^1 de $X \mapsto \mathbb{E}(X \mid \mathcal{F}_n)$, tenemos que

$$\mathbb{E}(X_\infty \mid \mathcal{F}_n) = \lim_{m \rightarrow \infty} \mathbb{E}(X_m \mid \mathcal{F}_n) \leq X_n \quad \text{si } m \geq n,$$

por ser $(X_n)_{n \in \mathbb{N}_0}$ supermartingala. $\square$

Teorema 5.25. Si $(X_n)_{n \in \mathbb{N}_0}$ es una martingala, son equivalentes:

- i) $(X_n)_{n \in \mathbb{N}_0}$ es UI.
- ii) $X_n \xrightarrow[L^1]{c.s.} X_\infty \in L^1$.
- iii) $X_n \xrightarrow{L^1} X_\infty \in L^1$.
- iv) $\exists Z \in L^1$ tal que $X_n = \mathbb{E}(Z \mid \mathcal{F}_n)$.

Demostración. (i) $\Leftrightarrow$ (ii) $\Leftrightarrow$ (iii) ya lo vimos.

iii) $\Rightarrow$ iv) El Teo anterior prueba que $X_n = \mathbb{E}(X_\infty \mid \mathcal{F}_n) \quad \forall n \in \mathbb{N}$.

iv) $\Rightarrow$ i) Por el ejemplo 5. $\square$

Teorema 5.26. Si $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ es una filtración y $\mathcal{F}_\infty := \sigma(\mathcal{F}_n : n \in \mathbb{N}_0)$, entonces, dado $p \geq 1$, para toda $Z \in L^p$, el proceso $(X_n)_{n \in \mathbb{N}_0}$ dado por

$$X_n := \mathbb{E}(Z \mid \mathcal{F}_n),$$

es una martingala UI acotada en L^p que cumple

$$X_n = \mathbb{E}(Z \mid \mathcal{F}_n) \xrightarrow[L^p]{c.s.} \mathbb{E}(Z \mid \mathcal{F}_\infty) = X_\infty.$$

Teorema 5.27 (Parada Opcional de Doob). Sean $(X_n)_{n \in \mathbb{N}_0}$ una super/sub/martingala y $S \leq T$ tiempos de parada. Si $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ es UI, entonces:

1. Si $T < \infty$, entonces $X_S, X_T \in L^1$ y $\mathbb{E}(X_T \mid \mathcal{F}_S) = X_S$ (reemplazando la igualdad por $\leq$ para supermartingala y con $\geq$ para submartingala). En particular, $\mathbb{E}(X_T) = \mathbb{E}(X_S)$ (reemplazando la igualdad por la misma regla anterior).
2. Si T no es necesariamente finito, pero $X_n \xrightarrow{c.s.} X_\infty$, entonces $X_S, X_T \in L^1$ y $\mathbb{E}(X_T \mid \mathcal{F}_S) = X_S$. En particular, $\mathbb{E}(X_T) = \mathbb{E}(X_S)$. (nuevamente, ambas igualdades las reemplazamos según la regla anterior.)

Clase 22

13 de Mayo

Lema 5.28. Si $(Y_n)_{n \in \mathbb{N}_0}$ es una super/sub/martingala UI entonces $(Y_{S \wedge n})_{n \in \mathbb{N}}$ es UI para cualquier tiempo de parada S .

Demostración. Supongamos que $(Y_n)_{n \in \mathbb{N}_0}$ es supermartingala. Entonces, $Y_n^- := (-Y_n)^+$ es submartingala. Como $S \wedge n$ es tiempo de parada acotado,

$\mathbb{E}(Y_{S \wedge n}^-) \leq \mathbb{E}(Y_n^-)$. Luego, como $(Y_n)_{n \in \mathbb{N}_0}$ es UI,

$$\sup_{n \in \mathbb{N}_0} \mathbb{E}(Y_{S \wedge n}^-) \leq \sup_{n \in \mathbb{N}_0} \mathbb{E}(Y_n^-) \leq \sup_{n \in \mathbb{N}_0} \|Y_n\|_1 < \infty$$

y, luego, por el Teo. de Conv. de Supermartingala (para $(Y_{S \wedge n})_{n \in \mathbb{N}_0}$ y $(Y_n)_{n \in \mathbb{N}_0}$),

$$Y_{S \wedge n} \xrightarrow{c.s.} Y_S \in L^1.$$

Con esto, tenemos que

$$\begin{aligned} \int_{|Y_{S \wedge n}| > M} |Y_{S \wedge n}| d\mathbb{P} &= \int_{\{|Y_{S \wedge n}| > M, S < n\}} + \int_{\{|Y_{S \wedge n}| > M, S \geq n\}} \\ &= \int_{\{|Y_S| > M, S < n\}} |Y_S| d\mathbb{P} + \int_{\{|Y_n| > M, S \geq n\}} |Y_n| d\mathbb{P} \\ &\leq \int_{\{|Y_S| > M\}} |Y_S| d\mathbb{P} + \int_{\{|Y_n| > M\}} |Y_n| d\mathbb{P} \xrightarrow{M \rightarrow 0} 0 \end{aligned}$$

unif. en $n \in \mathbb{N}_0$. □

Demostración (Parada Opcional). Tanto en (1) como (2), tenemos que $X_{T \wedge n} \xrightarrow{c.s.} X_T$. Como $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ es UI, de hecho vale que $X_{T \wedge n} \xrightarrow{L^1} X_T$. En particular, $X_T \in L^1$ y

$$\mathbb{E}(X_T \mid \mathcal{F}_n) = \lim_{m \rightarrow \infty} \mathbb{E}(X_{T \wedge m} \mid \mathcal{F}_n) = \mathbb{E}(X_{T \wedge n})$$

(la última igualdad es $\leq$ si es supermartingala).

Ahora, si definimos $Y_n := X_{T \wedge n}$, entonces, como $S \leq T$, tenemos que:

- $X_{S \wedge n} = Y_{S \wedge n}$, con lo cual, por el Lema previo, $(X_{S \wedge n})_{n \in \mathbb{N}_0}$ es UI y repitiendo lo anterior, resulta que $X_S \in L^1$.

- Si $A \in \mathcal{F}_S$,

$$\begin{aligned}
 \int_A \mathbb{E}(X_T \mid \mathcal{F}_S) &= \int_A X_T \, d\mathbb{P} \\
 (X_T \in L^1) &= \sum_{n=0}^{\infty} \int_{A \cap \{S=n\}} X_T \, d\mathbb{P} + \underbrace{\int_{A \cap \{S=\infty\}} X_{\infty} \, d\mathbb{P}}_{\text{sólo en (2)}} \\
 &= \sum_{n=0}^{\infty} \int_{A \cap \{S=n\}} \mathbb{E}(X_T \mid \mathcal{F}_n) + \int_{A \cap \{S=\infty\}} X_S \, d\mathbb{P} \\
 (*) &= \sum_{n=0}^{\infty} \int_{A \cap \{S=n\}} X_{T \wedge n} \, d\mathbb{P} + \int_{A \cap \{S=\infty\}} X_S \, d\mathbb{P} \\
 &= \sum_{n=0}^{\infty} \int_{A \cap \{S=n\}} X_S \, d\mathbb{P} + \int_{A \cap \{S=\infty\}} X_S \, d\mathbb{P} \\
 &= \int_A X_S \, d\mathbb{P}.
 \end{aligned}$$

(desde $(*)$ las igualdades se reemplazan $\leq$ si es super o $\geq$ si es sub.)

Finalmente, como $\mathbb{E}(X_T \mid \mathcal{F}_S)$ y X_S son $\mathcal{F}_S$ -medibles, lo anterior implica que

$$\mathbb{E}(X_T \mid \mathcal{F}_S) = X_S \text{ casi seguramente.}$$

(similarmente, la igualdad se reemplaza por $\leq$ o $\geq$ en los respectivos casos.) $\square$

Pregunta. ¿Cuándo es $(X_{T \wedge n})_{n \in \mathbb{N}}$ UI?

Teorema 5.29. Si $(X_n)_{n \in \mathbb{N}_0}$ es una super/sub/martingala y T es tiempo de parada, entonces $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ es una super/sub/martingala UI en cada uno de los siguientes casos:

1. $(X_n)_{n \in \mathbb{N}_0}$ es UI,
2. T es acotado, i.e. $T \leq M$ para $M \in \mathbb{N}$,
3. $\mathbb{E}(T) < \infty$ y $\exists k > 0$ tal que $\mathbb{E}(|X_{n+1} - X_n| \mid \mathcal{F}_n) \leq k$.

Demostración. 1. Por el Lema previo.

2. Si $T \leq M$ entonces

$$|X_{T \wedge n}| \leq \sum_{i=0}^M |X_i| \quad \forall n \in \mathbb{N}.$$

Como $\sum_{i=0}^M |X_i| \in L^1$, $(X_{T \wedge n})_{n \in \mathbb{N}_0}$ es UI por ejemplo 4 de la clase pasada.

3. Como

$$|X_{T \wedge n}| \leq |X_0| + \sum_{i=0}^{\infty} |X_{i+1} - X_i| \mathbb{1}_{T > i} \quad \forall n \in \mathbb{N}$$

y

$$\begin{aligned} \mathbb{E} \left(\sum_{i=0}^{\infty} |X_{i+1} - X_i| \mathbb{1}_{T > i} \right) &= \sum_{i=0}^{\infty} \mathbb{E}(\mathbb{1}_{T > i} \underbrace{\mathbb{E}(|X_{i+1} - X_i| \mid \mathcal{F}_i)}_{\leq k}) \\ &\leq k \sum_{i=0}^{\infty} \mathbb{P}(T > i) \\ &= k \mathbb{E}(T) < \infty, \end{aligned}$$

resulta $(X_n)_{n \in \mathbb{N}_0}$ es UI por el ejemplo 4. □

5.1.1 Martingalas reversas

$\mathcal{W}_n := \sigma(X_k : k \geq n)$.

Definición 5.30. Sea $\mathcal{G}_0 \supseteq \mathcal{G}_{-1} \supseteq \mathcal{G}_{-2} \supseteq \dots$ una filtración *reversa*. Diremos que un proces $(X_n)_{n \in \mathbb{Z}_0^-}$ es una *martingala reversa* si:

1. $X_n \in L^1 \quad \forall n \in \mathbb{Z}_0^-$,
2. X_n es $\mathcal{G}_n$ -medible $\forall n \in \mathbb{Z}_0^-$,
3. $\mathbb{E}(X_{n+1} \mid \mathcal{G}_n) = X_n \quad \forall n \in \mathbb{Z}_0^-$.

Si queremos reindexar la filtración reversa para que sea una filtración usual, i.e. $\mathcal{W}_n := \mathcal{G}_n$ ($n \in \mathbb{N}_0$), entonces (3) se convierte en

- 3'. $\mathbb{E}(\bar{X}_n \mid \mathcal{W}_{n+1}) = \bar{X}_{n+1}$ ($n \in \mathbb{N}_0$), donde $\bar{X}_n := X_n$ es el proceso "invertido".

Teorema 5.31. Si $(X_n)_{n \in \mathbb{Z}_0^-}$ es una martingala reversa, entonces

$$X_n \xrightarrow[L^1]{c.s.} X_{-\infty} := \mathbb{E}(X_0 \mid \mathcal{G}_{-\infty}),$$

donde $\mathcal{G}_{-\infty} := \bigcap_{n \in \mathbb{Z}_0^-} \mathcal{G}_n$. Además, si $X_0 \in L^p$ entonces $X_n \xrightarrow{L^p} X_{-\infty}$.

Idea. • $(X_n)_{n \in \mathbb{Z}_0^-}$ es UI pues $X_n = \mathbb{E}(X_0 \mid \mathcal{G}_n)$. Además, si $X_0 \in L^p$ entonces $(X_n)_{n \in \mathbb{Z}_0^-}$ acot. en L^p .

- $(X_{-m+k} : k = 0, \dots, m)$ es una martingala usual. Por lema de Doob,

$$(b-a)\mathbb{E}(\bar{U}_n^{a,b}) \leq \mathbb{E}((X_0 - a)^-).$$

Usando estos $\bar{U}^{a,b} < \infty$ c.s. y, por ende, $X_n \xrightarrow{c.s.} X_{-\infty}$.

Chapter 6

Cadenas de Markov

Clase 23

25 de Mayo

Notación. Si $\mathcal{G} \subseteq \mathcal{F}$ es una sub- σ -álgebra de $\mathcal{F}$ y $A \in \mathcal{F}$, definimos $\mathbb{P}(A \mid \mathcal{G}) := \mathbb{E}(\mathbf{1}_A \mid \mathcal{G})$.

Definición 6.1. Sean $(\Omega, \mathcal{F}, \mathbb{P}, (\mathcal{F}_n)_{n \in \mathbb{N}_0})$ es un espacio de probabilidad filtrado, y $X = (X_n)_{n \in \mathbb{N}_0}$ un proceso estocástico a valores en un espacio métrico S (def. en $(\Omega, \mathcal{F}, \mathbb{P})$). Diremos que X es una *cadena de Markov* con respecto a $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ (o $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ -cadena de Markov) si:

- (i) X es adaptado a $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$,
- (ii) para todo $n \in \mathbb{N}_0$, $B \in \beta(S)$, $\mathbb{P}(X_{n+1} \in B \mid \mathcal{F}_n) = \mathbb{P}(X_{n+1} \in B \mid X_n)$.

Comentarios. 1. S se dirá el *espacio de estados* de X .

2. Si X es una $(\mathcal{F}_n)_{n \in \mathbb{N}}$ -CdM entonces también es una $(\mathcal{F}_n^X)_{n \in \mathbb{N}_0}$ -CdM, donde $\mathcal{F}_n^X := \sigma(X_0, \dots, X_n)$ es la filtración natural asociada a X . En efecto:

$$\begin{aligned} \mathbb{P}(X_{n+1} \in B \mid \mathcal{F}_n^X) &= \mathbb{E}(\mathbb{P}(X_{n+1} \in B \mid \mathcal{F}_n) \mid \mathcal{F}_n^X) && (\mathcal{F}_n^X \subseteq \mathcal{F}_n) \\ &= \mathbb{E}(\mathbb{P}(X_{n+1} \in B \mid X_n) \mid \mathcal{F}_n^X) && (\mathcal{F}_n\text{-Markov}) \\ &= \mathbb{P}(X_{n+1} \in B \mid X_n). \end{aligned}$$

Ejemplo. Si $(Z_n)_{n \in \mathbb{N}}$ son i.i.d., entonces la caminata aleatoria $S = (S_n)_{n \in \mathbb{N}_0}$, dada por

$$\begin{cases} S_0 := 0 \\ S_n := Z_1 + \dots + Z_n \quad (n \in \mathbb{N}) \end{cases}$$

es una cadena de Markov.

En efecto, $\mathcal{F}_n^S = \sigma(S_0, S_1, \dots, S_n) = \sigma(0, Z_1, \dots, Z_n)$

$$\begin{aligned} \mathbb{P}(S_{n+1} \in B \mid \mathcal{F}_n^S) &= \mathbb{P}(S_n + Z_{n+1} \in B \mid \sigma(S_n) \vee \mathcal{F}_{n-1}^S) \\ &= \mathbb{P}(S_n + Z_{n+1} \in B \mid S_n) \quad (S_n + Z_{n+1} \text{ indep. de } \mathcal{F}_{n-1}^S) \\ &= \mathbb{P}(S_{n+1} \in B \mid S_n). \quad \checkmark \end{aligned}$$

$$\left(\mathbb{E}(h(S_n + Z_{n+1})\mathbb{1}_A \mid S_n) = \mathbb{E}(h(S_n + Z_{n+1}) \mid S_n) \mathbb{P}(A \mid S_n) \quad \forall A \in \mathcal{F}_{n-1}^S \right)$$

(la igualdad es por la condicionalidad a $\sigma(S_n)$.)

Ejemplo. Si $(Z_n)_{n \in \mathbb{N}_0}$ es un proceso de Galton-Watson, es una cadena de Markov, pues

$$Z_{n+1} = \sum_{i=1}^{Z_n} X_i^{(n)}$$

con $(X_i^{(n)})_{i,n \in \mathbb{N}}$ i.i.d.

Teorema 6.2. Sea $X = (X_n)_{n \in \mathbb{N}_0}$ una $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ -CdM. Entonces:

1. $\mathbb{E}(f(X_{n+1}) \mid \mathcal{F}_n) = \mathbb{E}(f(X_{n+1}) \mid X_n) \quad \forall n \in \mathbb{N}_0, f: S \rightarrow \mathbb{R} \text{ } \beta(S)\text{-medible y acotada.}$
2. $\mathbb{E}(f(X_{n+k}) \mid \mathcal{F}_n) = \mathbb{E}(f(X_{n+k}) \mid X_n) \quad \forall n \in \mathbb{N}_0, k \in \mathbb{N}, f: S \rightarrow \mathbb{R} \text{ medible y acotada.}$
3. $\mathbb{E}(f(X_{n+1}, \dots, X_{n+k}) \mid \mathcal{F}_n) = \mathbb{E}(f(X_{n+1}, \dots, X_{n+k}) \mid X_n) \quad \forall n \in \mathbb{N}_0, k \in \mathbb{N}, f: S^k \rightarrow \mathbb{R} \text{ medible y acotada.}$
4. $\mathbb{E}(Z \mid \mathcal{F}_n) = \mathbb{E}(Z \mid X_n) = \mathbb{E}(Z \mid \sigma(X_n) \vee \mathcal{F}_{n-1}) \quad \forall Z \text{ VA } \sigma(X_{n+k} : k \in \mathbb{N}_0)\text{-medible.}$

En particular, condicional a X_n , $\sigma(X_{n+k} : k \in \mathbb{N})$ y $\mathcal{F}_{n-1}$ son independientes.

Demostración. 1. Por un argumento estándar.

2. Vale por def. si $k = 1$ y, si vale para k ,

$$\begin{aligned} \mathbb{E}(f(X_{n+(k+1)}) \mid \mathcal{F}_n) &= \mathbb{E}(\underbrace{\mathbb{E}(f(X_{n+k+1}) \mid \mathcal{F}_{n+k})}_{=\mathbb{E}(f(X_{n+k+1}) \mid X_{n+k})=g(n+k)} \mid \mathcal{F}_n) \\ &= \mathbb{E}(g(X_{n+k}) \mid \mathcal{F}_n) \\ &= \mathbb{E}(g(X_{n+k}) \mid X_n) \quad (\text{H.I.}) \\ &= \mathbb{E}(\mathbb{E}(f(X_{n+k+1}) \mid \mathcal{F}_{n+k}) \mid X_n) \\ &\quad (\text{caso } k = 1) \\ &= \mathbb{E}(f(X_{n+k+1}) \mid X_n). \end{aligned}$$

(con g medible y acotada.) Luego, por inducción, obtenemos (2).

3. Si $k = 1$, el resultado vale por el ítem (1). Ahora, si vale para $k \in \mathbb{N}$,

entonces dados $B_1, \dots, B_{k+1} \in \beta(S)$, se tiene que

$$\begin{aligned}
& \mathbb{P}(X_{n+k+1} \in B_{k+1}, \dots, X_{n+1} \in B_1 \mid \mathcal{F}_n) \\
&= \mathbb{E} \left(\mathbb{E} \left(\prod_{i=1}^{k+1} \mathbb{1}_{\{X_{n+i} \in B_i\}} \mid \mathcal{F}_{n+k} \right) \mid \mathcal{F}_n \right) \\
&= \mathbb{E} \left(\prod_{i=1}^k \mathbb{1}_{\{X_{n+i} \in B_i\}} \underbrace{\mathbb{P}(X_{n+k+1} \in B_{k+1} \mid \mathcal{F}_{n+k})}_{g(X_{n+k})} \mid \mathcal{F}_n \right) \\
&= \mathbb{E} \left(\prod_{i=1}^k \mathbb{1}_{\{X_{n+i} \in B_i\}} g(X_{n+k}) \mid X_n \right) \\
&= \mathbb{E} \left(\prod_{i=1}^k \mathbb{1}_{\{X_{n+i} \in B_i\}} \mathbb{E}(\mathbb{1}_{\{X_{n+k+1} \in B_{k+1}\}} \mid \mathcal{F}_{n+k}) \mid X_n \right) \\
&= \mathbb{E} \left(\mathbb{E} \left(\prod_{i=1}^{k+1} \mathbb{1}_{\{X_{n+i} \in B_i\}} \mid \mathcal{F}_{n+k} \right) \mid X_n \right) \\
&= \mathbb{E} \left(\prod_{i=1}^{k+1} \mathbb{1}_{\{X_{n+i} \in B_i\}} \mid X_n \right) \\
&= \mathbb{P}(X_{n+k+1} \in B_{k+1}, \dots, X_{n+1} \in B_1 \mid X_n).
\end{aligned}$$

Luego, hemos probado (3) para toda f de la forma $f = \mathbb{1}_R$ con R un rectángulo medible en S^k .

Por un argumento de topo $\pi - \lambda$, (3) vale para toda $f = \mathbb{1}_B$ con $B \in \beta(S)$.

Por un argument estándar, vale (3) tal y cómo lo enunciamos.

4. Por el ítem (3), (4) vale si $Z = \mathbb{1}_A$ con A un *cilindro especial*, i.e.,

$$A = \{X^{(n)} \in C(\{0, \dots, k\}, B)\},$$

donde

$$\begin{cases} X^{(n)} := (X_{n+j})_{j \in \mathbb{N}_0} \\ B = B_0 \times \dots \times B_k \text{ con } B_i \in \beta(S), i = 0, \dots, k. \end{cases}$$

Por un argumento $\pi - \lambda$ valdrá (4a) para toda $Z = \mathbb{1}_A$ con $A = (X^{(n)})^{-1}(B)$ y $B \in \prod_{j \in \mathbb{N}} \beta(S)$. Pero, toda $A \in \sigma(X_{n+k} : k \in \mathbb{N}_0)$ es exactamente de esta forma. Luego, vale (4a) para indicadoras. Por un argumento estándar, vale (4a) como lo enunciamos.

En particular,

$$\begin{aligned}
 \mathbb{E}(Z \mid \sigma(X_n) \vee \mathcal{F}_{n-1}) \\
 &= \mathbb{E}(\mathbb{E}(Z \mid \mathcal{F}_n) \mid \sigma(X_n) \vee \mathcal{F}_{n-1}) \quad (\sigma(X_n) \vee \mathcal{F}_{n-1} \subseteq \mathcal{F}_n) \\
 &= \mathbb{E}(\mathbb{E}(Z \mid X_n) \mid \sigma(X_n) \vee \mathcal{F}_{n-1}) \quad (4a) \\
 &= \mathbb{E}(Z \mid X_n).
 \end{aligned}$$

□

Clase 24

27 de Mayo

Aclaración. A partir de ahora, S será a lo sumo numerable. En este caso,

$$\mathcal{F}_n^X = \sigma(\{X_0 = i_0, \dots, X_n = i_n\} : i_0, \dots, i_n \in S)$$

será generada por una partición numerable de Σ y lo mismo ocurre con $\sigma(X_n)$.

En tal caso, vimos que, dado $B \subseteq S$,

$$\begin{aligned}
 \mathbb{P}(X_{n+1} \in B \mid \mathcal{F}_n^X) &= \sum_{\substack{i_0, \dots, i_n \in S \\ \mathbb{P}(X_0=i_0, \dots, X_n=i_n) > 0}} \mathbb{P}(X_{n+1} \in B \mid X_n = i_n, \dots, X_0 = i_0) \mathbb{1}_{\{X_0=i_0, \dots, X_n=i_n\}} \\
 &= \sum_{\substack{i_0, \dots, i_n \in S \\ \mathbb{P}(X_0=i_0, \dots, X_n=i_n) > 0}} \sum_{j \in B} \mathbb{P}(X_{n+1} = j \mid X_n = i_n) \mathbb{1}_{\{X_n=i_n\}}.
 \end{aligned}$$

De manera similar,

$$\mathbb{P}(X_{n+1} \in B \mid X_n) = \sum_{\substack{i_n \in S \\ \mathbb{P}(X_n=i_n) > 0}} \sum_{j \in B} \mathbb{P}(X_{n+1} = j \mid X_n = i_n) \mathbb{1}_{\{X_n=i_n\}}.$$

Teorema 6.3. $X = (X_n)_{n \in \mathbb{N}_0}$ es una CdM si y solo si

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i_n)$$

$\forall j \in S, i_0, \dots, i_n \in S$ tal que $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) > 0$.

Definición 6.4. Diremos que una CdM $X = (X_n)_{n \in \mathbb{N}_0}$ es *homogénea* si para cada $i, j \in S$, la cantidad $\mathbb{P}(X_{n+1} = j \mid X_n = i)$ no depende de $n \in \mathbb{N}_0$.

En este caso, la aplicación $P: S \times S \rightarrow [0, 1]$ donde $(i, j) \mapsto \mathbb{P}(X_{n+1} = j \mid X_n = i)$ se llama *matriz de transición* de X . Pensaremos a P como una matriz (posiblemente infinita) y, por tal motivo, la denotaremos por $P = (p_{ij})_{i, j \in S}$, donde $p_{ij} := P(i, j)$ es la *probabilidad de transición de i a j* .

En lo que sigue, estudiaremos *exclusivamente* CdM homogéneas.

Definición 6.5. Una matriz $P = (p_{ij})_{i,j \in S}$ (posiblemente infinita) se dice una *matriz estocástica* si

- (i) $p_{ij} \geq 0 \quad \forall i, j \in S$;
- (ii) $\sum_{j \in S} p_{ij} = 1 \quad \forall i \in S$ (i.e., para cada $i \in S$, la i -ésima fila $(p_{ij})_{j \in S}$ es un *vector de probabilidad*.)

Observación. Toda matriz de transición es estocástica, puesto que $j \mapsto p_{ij} := \mathbb{P}(X_{n+1} = j \mid X_n = i)$ es un vector de probabilidad $\forall i \in S$.

Definición 6.6. Dada una CdM $X = (X_n)_{n \in \mathbb{N}_0}$, definimos su *distribución inicial* como el vector de probabilidad $\mu = (\mu_i)_{i \in S}$ dado por $\mu_i := \mathbb{P}(X_0 = i)$ (i.e. $\mu = \mathbb{P}_{X_0}$).

Proposición 6.7. Si X es una CdM (homogénea) con distancia inicial μ y matriz de transición P , entonces $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) = \mu_{i_0} \prod_{k=1}^n p_{i_{k-1} i_k}$ para cualquier $i_0, \dots, i_n \in S$ y $n \in \mathbb{N}_0$.

En particular, 2 CdM con igual distribución inicial y MdT tienen igual distribución en $S^{\mathbb{N}_0}$.

Demostración. El caso $n = 0$ vale por def. de μ . Si vale para $n \in \mathbb{N}_0$, entonces

$$\begin{aligned}
 & \mathbb{P}(X_{n+1} = i_{n+1}, X_n = i_n, \dots, X_0 = i_0) \\
 &= \mathbb{P}(X_{n+1} = i_{n+1} \mid X_n = i_n, \dots, X_0 = i_0) \cdot \mathbb{P}(X_n = i_n, \dots, X_0 = i_0) \\
 &= \mathbb{P}(X_{n+1} = i_{n+1} \mid X_n = i_n) \left(\prod_{k=1}^n p_{i_{k-1} i_k} \right) \mu_{i_0} \\
 &= p_{i_n i_{n+1}} \left(\prod_{k=1}^n p_{i_{k-1} i_k} \right) \mu_{i_0}. \quad \checkmark
 \end{aligned}$$

□

La proposición anterior nos dice que la aplicación

$$\theta: \{\mathbb{P}_X : \text{CdM sobre } S\} \rightarrow \left\{ \begin{array}{c} \text{distribuciones} \\ \text{en } S \end{array} \right\} \times \left\{ \begin{array}{c} \text{matrices} \\ \text{estocásticas} \\ \text{en } S \times S \end{array} \right\}$$

dada por $\theta(\mathbb{P}_X) = (\mathbb{P}_{X_0}, \frac{\mathbb{P}_{X_0 X_1}}{\mathbb{P}_{X_0}}) = (\mu, P)$ es *inyectiva*.

Teorema 6.8. Dada una distribución μ en S y una matriz estocástica P , existe una única distribución $\mathbb{P}$ en $S^{\mathbb{N}_0}$ tal que

$$\mathbb{P}(\{i_0\} \times \cdots \times \{i_n\} \times S^{\mathbb{N}_0}) = \mu_{i_0} \prod_{k=1}^n p_{i_{k-1}i_k} \quad \forall i_0, \dots, i_n \in S, \quad n \in \mathbb{N}_0$$

(Es decir, tal que, bajo $\mathbb{P}$, el proceso canónico $(\pi_n)_{n \in \mathbb{N}_0}$ es una CdM homogénea con distribución inicial μ y MdT P .) En particular, $\mathbb{P}$ es la distribución de la (única) CdM con distribución inicial μ y MdT P . Por lo tanto, θ es una biyección.

Demostración. Práctica 8. □

Notación. Sea X una CdM con MdT P . Definimos:

- i) $\mathbb{P}_i = \mathbb{P}_X(\cdot \mid X_0 = i)$ (la dist. de X si $\mu = \delta_i$), $\mathbb{E}_i = \mathbb{E}(\cdot \mid X_0 = i)$.
- ii) Dada una dist. μ en S ,

$$\mathbb{P}_\mu := \sum_{i \in S} \mu_i \mathbb{P}_i$$

$$\mathbb{E}_\mu := \sum_{i \in S} \mu_i \mathbb{E}_i.$$

- iii) Si $f: S \rightarrow \mathbb{R}$ es acotada, $P(f): S \rightarrow \mathbb{R}$ tal que $i \mapsto \sum_{j \in S} p_{ij} f(j)$.
Es decir, si vemos a f como v. columna, entonces $P(f)$ es el v. columna que se obtiene al multiplicar $P \cdot f$ como matrices.
- iv) Dada μ dist. en S , definimos $\mu P: S \rightarrow [0, 1]$ tal que $j \mapsto \sum_{i \in S} \mu_i p_{ij}$.
Es decir, si vemos a μ como v. fila, μP es el v. fila que se obtiene del producto $\mu \cdot P$ como matrices.
- v) Dada otra matriz estocástica Q , definimos $PQ: S \times S \rightarrow [0, 1]$ tal que $(i, j) \mapsto \sum_{k \in S} p_{ik} q_{kj}$.
Observar que PQ es también matriz estocástica y que corresponde al producto $P \cdot Q$ como matrices.
- vi) $P^{(n)} := (p_{ij}^{(n)})_{i,j \in S}$, donde $p_{i,j}^{(n)} := \mathbb{P}(X_n = j \mid X_0 = i)$.

Clase 25

1 de Junio

Proposición 6.9. En el marco anterior,

- i) $\mathbb{P}_\mu$ es la distribución de la CdM con MdT P y distribución inicial μ .
- ii) $P(f)(i) = \mathbb{E}_i(f(X_1))$.
- iii) $\mu P(j) = \mathbb{P}_\mu(X_1 = j)$.
- iv) $P_{ij}^{(n+m)} := \mathbb{P}_i(X_{n+m} = j) = \sum_{k \in S} P_{ik}^{(m)} P_{kj}^{(n)} = (P^{(m)} \cdot P^{(n)})_{ij}$ (Chapman-Kolmogorov).

Demostración. i) Si X tiene DI μ y MdT P ,

$$\begin{aligned}\mathbb{P}_X(A) &:= \mathbb{P}(X \in A) = \sum_{i \in S} \mathbb{P}(X \in A \mid X_0 = i) \cdot \mathbb{P}(X_0 = i) \\ &= \sum_{i \in S} \mathbb{P}_i(A) \mu(i) \\ &= \mathbb{P}_\mu(A).\end{aligned}$$

ii) Se tiene que:

$$\begin{aligned}\mathbb{E}(f(X_1)) &= \sum_{j \in S} f(j) \mathbb{P}_i(X_1 = j) \\ &= \sum_{j \in S} f(j) \mathbb{P}(X_1 = j \mid X_0 = i) \\ &= \sum_{j \in S} f(j) P_{ij} \\ &= P(f)(i).\end{aligned}$$

iii) Se tiene que:

$$\begin{aligned}\mathbb{P}_\mu(X_1 = j) &= \sum_{i \in S} \mathbb{P}_\mu(X_1 = j \mid X_0 = i) \mathbb{P}_\mu(X_0 = i) \\ &= \mu P(j).\end{aligned}$$

iv) Se tiene que:

$$\begin{aligned}\mathbb{P}(X_{n+m} = j \mid X_0 = i) &= \mathbb{P}(X_{n+m} = j, X_0 = i) \cdot \frac{1}{\mathbb{P}(X_0 = i)} \\ &= \sum_{k \in S} \mathbb{P}(X_{n+m} = j, X_m = k, X_0 = i) \cdot \frac{1}{\mathbb{P}(X_0 = i)} \\ &= \sum_{k \in S} \mathbb{P}(X_{n+m} = j \mid X_m = k) \cdot \mathbb{P}(X_m = k \mid X_0 = i) \\ &= \sum_{k \in S} P_{ik}^{(m)} \cdot P_{kj}^{(n)}.\end{aligned}$$

□

6.0.1 Propiedad Fuerte de Markov

Recordemos que si $(X_n)_{n \in \mathbb{N}_0}$ es una $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ -CdM entonces

$$\mathbb{E}(f(X^{(n)}) \mid \mathcal{F}_n) = \mathbb{E}(f(X^{(n)}) \mid X_n)$$

para toda $f: S^{\mathbb{N}_0} \rightarrow \mathbb{R}$ medible y acotada, donde $X^{(n)} := (X_{n+k})_{k \in \mathbb{N}_0}$.

Como S ahora es numerable, podemos escribir

$$\mathbb{E}(f(X^{(n)}) \mid X_n) = \sum_{i \in S} \mathbb{E}(f(X^{(n)}) \mid X_n = i) \mathbb{1}_{\{X_n = i\}}.$$

Además, si X es homogénea, entonces resulta

$$\mathbb{E}(f(X^{(n)}) \mid X_n = i) = \mathbb{E}(f(X^{(0)}) \mid X_0 = i) = \mathbb{E}(f(X) \mid X_0 = i) = \mathbb{E}_i(f(X))$$

de modo que

$$\sum_{i \in S} \mathbb{E}(f(X^{(n)}) \mid X_n = i) \mathbb{1}_{\{X_n = i\}} = \sum_{i \in S} \mathbb{E}_i(f(X)) \mathbb{1}_{\{X_n = i\}} = \mathbb{E}_{X_n}(f(X)).$$

Entonces,

$$\mathbb{E}(f(X^{(n)}) \mid \mathcal{F}_n) = \mathbb{E}_{X_n}(f(X)) \quad \forall f: S^{\mathbb{N}_0} \rightarrow \mathbb{R} \text{ medible y acotada.}$$

Teorema 6.10. Sean $X = (X_n)_{n \in \mathbb{N}_0}$ una $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ -CdM homogénea y τ un $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$ -tiempo de parada. Entonces

$$\mathbb{E}(f(X^{(\tau)}) \mathbb{1}_{\{\tau = \infty\}} \mid \mathcal{F}_\tau) = \mathbb{E}_{X_\tau}(f(X)) \mathbb{1}_{\tau < \infty}$$

$\forall f: S^{\mathbb{N}_0} \rightarrow \mathbb{R}$ medible y acotada, donde $(X^{(\tau)}) = (X_{\tau+k})_{k \in \mathbb{N}_0}$.

Demostración. Basta con ver que

$$\mathbb{E}(f(X^{(\tau)}) \mathbb{1}_{\{\tau = n\}} \mid \mathcal{F}_n) = \underbrace{\mathbb{E}_{X_\tau}}_{X_n}(f(X)) \mathbb{1}_{\{\tau = n\}} \quad \forall n \in \mathbb{N}_0.$$

Por definición,

1. Si $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ es medible y acotada y $Z := \varphi(X_n) \mathbb{1}_{\{\tau = n\}}$, entonces Z es $\mathcal{F}_\tau$ -medible, pues si $B \in \beta(\mathbb{R})$ entonces

$$\{Z \in B\} \cap \{\tau = k\} = \begin{cases} \emptyset & \text{si } 0 \notin B, k \neq n, \\ \{\tau = k\} & \text{si } 0 \in B, k \neq n, \\ \{X_n \in \varphi^{-1}(B)\} \cap \{\tau = k\} & \text{si } k = n \end{cases} \in \mathcal{F}_k.$$

2. Si $A \in \mathcal{F}_\tau$,

$$\begin{aligned} \mathbb{E}(f(X^{(\tau)}) \mathbb{1}_{\{\tau = n\}} \mathbb{1}_A) &= \mathbb{E}(f(X^{(n)}) \mathbb{1}_{\{\tau = n\} \cap A}) \\ &= \mathbb{E}(\mathbb{E}_{X_n}(f(X)) \mathbb{1}_{\{\tau = n\} \cap A}) \quad (\text{Prop. de Markov}) \\ &= \mathbb{E}((\mathbb{E}_{X_n}(f(X)) \mathbb{1}_{\{\tau = n\}}) \mathbb{1}_A) \end{aligned}$$

Entonces,

$$\mathbb{E}(f(X^{(n)}) \mathbb{1}_{\{\tau = n\}} \mid \mathcal{F}_\tau) = \mathbb{E}_{X_n}(f(X)) \mathbb{1}_{\{\tau = n\}}.$$

□

6.1 Estructura de Clases

Definición 6.11. Sean X una CdM, $i, j \in S$. Diremos que i conduce a j ($i \rightarrow j$) si $\mathbb{P}_i(\exists n \in \mathbb{N}_0 : X_n = j) > 0$. Decimos que i y j se comunican ($i \leftrightarrow j$) si $i \rightarrow j$ y $j \rightarrow i$.

Proposición 6.12. Si $i \neq j \in S$, son equivalentes:

- i) $i \rightarrow j$,
- ii) $\exists n \in \mathbb{N}$, $i_1, \dots, i_{n-1} \in S$ tal que $p_{i,i_1} \cdot p_{i_1,i_2} \cdots p_{i_{n-1},j} > 0$,
- iii) $\exists n \in \mathbb{N}$ tal que $\mathbb{P}_i(X_n = j) > 0$.

Clase 26

3 de Junio

Demostración (Proposición). $(i) \Leftrightarrow (iii)$ Se cumple, pues:

$$\mathbb{P}_i(X_{n_0} = j) \stackrel{i \neq j}{\leq} \mathbb{P}_i\left(\bigcup_{n \in \mathbb{N}} \{X_n = j\}\right) \leq \sum_{n \in \mathbb{N}} \mathbb{P}_i(X_n = j).$$

$(iii) \Leftrightarrow (ii)$ Sean $i_0 = i$ e $i_{n_0} = j$. Entonces,

$$\begin{aligned} \mathbb{P}_i(X_{n_0} = j) &= \sum_{\substack{i_0, \dots, i_{n_0} \in S : \\ i_0 = i, i_{n_0} = j}} \mathbb{P}_i(X_0 = i_0, \dots, X_{n_0} = i_{n_0}) \\ &= \sum_{\substack{i_0, \dots, i_{n_0} \in S : \\ i_0 = i, i_{n_0} = j}} \prod_{k=1}^{n_0} p_{i_{k-1}} p_{i_{k-1}, i_k}. \end{aligned} \quad \square$$

Proposición 6.13.

- La relación $\rightarrow$ es reflexiva y transitiva.
- La relación $\leftrightarrow$ es de equivalencia.

Demostración. Solo queda por ver la transitividad. Si $i \rightarrow k$ y $k \rightarrow j$, por la Prop. anterior existen $m, n \in \mathbb{N}$ tal que $p_{ik}^{(m)} \cdot p_{kj}^{(n)} > 0$. Luego, por Chapman-Kolmogorov,


$$p_{ij}^{m+n} = \sum_{r \in S} p_{ir}^{(m)} p_{rj}^{(n)} \geq p_{ik}^{(m)} p_{kj}^{(n)} > 0$$

y luego $i \rightarrow j$ por la Proposición. $\square$

Definición 6.14. Dado $i \in S$, la *clase* $C(i)$ de i , es la clase de equivalencia de i bajo $\leftrightarrow$. Decimos que una clase es cerrada si

$$i \in C, i \rightarrow j \Rightarrow j \in C \text{ (} j \rightarrow i \text{)}.$$

Ejemplo.



Las clases son: $\{1, 2, 3\}$, $\{4\}$, $\{5, 6\}$ y $\{4\}$, $\{5, 6\}$ son las únicas cerradas.

Definición 6.15 (Irreducibilidad). Decimos que una CdM X es *irreducible* (o que su matriz de transición lo es) si X tiene una única clase (que es necesariamente cerrada.)

6.1.1 Aperiodicidad

Pregunta. ¿Existe $\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j)$?

$S = \mathbb{Z}$, $i = 0$, $j = 1$, X = caminata aleatoria de saltos ± 1 .

Definición 6.16. El *periodo* de un estado $i \in S$ se define como

$$d(i) := \text{mcd}\{n \in \mathbb{N} : p_{ii}^{(n)} > 0\}.$$

Un estado $i \in S$ se dice *aperiódico* si $d(i) = 1$.

Proposición 6.17.

1. Un estado i es aperiódico si y solo si existe $N_i \in \mathbb{N}$ tal que $p_{ii}^{(n)} > 0 \quad \forall n \geq N_i$.
2. Si $i \leftrightarrow j$, con i aperiódico, entonces j también lo es.

Demostración. 2) Por (1), existe $N_i \in \mathbb{N}$ tal que $p_{ii}^{(n)} > 0 \quad \forall n \geq N_i$. Como $i \leftrightarrow j$, existen $k_1, k_2 \in \mathbb{N}_0$ tal que $p_{ji}^{(k_1)} p_{ij}^{(k_2)} > 0$. Entonces,

$$p_{jj}^{(k_1+n+k_2)} \geq p_{ji}^{(k_1)} p_{ii}^{(n)} p_{ij}^{(k_2)} > 0 \quad \forall n \geq N_i.$$

Luego, $p_{ij}^{(m)} > 0 \quad \forall m \geq k_1 + k_2 + N_i$ y, por (1), resulta $d(j) = 1$.

1) Definamos $I_i = \{n \in \mathbb{N} : p_{ii}^{(n)} > 0\}$. (notar que $p_{ii}^{(2k)} \geq p_{ii}^{(k)} p_{ii}^{(k)} > 0$.) Basta demostrar que I_i tiene dos enteros consecutivos: k y $k+1$. Pues, en

este caso, va a contener a $2k, 2k+1, 2k+2, 3k, 3k+1, 3k+2, 3k+3$ y con esto obtenemos a todos los demás:

$$k + (k-1)k, k + (k-1)k + 1, \dots, k + (k-1)k + k - 1 = 2k + (k-1)k - 1 \\ 2k + (k-1)k, 2k + (k-1)k + 1, \dots, 2k + (k-1)k + k - 1 = 3k + (k-1)k - 1.$$

Para mostrar que existe tal k , usamos lo siguiente: si $\text{mcd } I_i = 1$, entonces existen enteros $r_1, \dots, r_m \in I_i$ y coeficientes enteros $c_1, \dots, c_m$ tal que $c_1 r_1 + \dots + c_m r_m = 1$. Sean $a_r := c_r^+$, $b_r := c_r^-$. Entonces la eq. anterior nos dice que

$$a_1 r_1 + \dots + a_m r_m = b_1 r_1 + \dots + b_m r_m + 1.$$

Luego, $k = b_1 r_1 + \dots + b_m r_m$ y $k+1 = a_1 r_1 + \dots + a_m r_m$ son los buscados. $\square$

Clase 27

8 de Junio

Definición 6.18. Dada una CdM $X = (X_n)_{n \in \mathbb{N}_0}$, definimos para $i \in S$,

- el *tiempo de retorno a i* $\tau_i = \tau_i(X) := \inf\{n \in \mathbb{N}_{\geq 1} : X_n = i\}$;
- el *número de visitas a i* $N_i := \sum_{n=0}^{\infty} \mathbb{1}_{\{X_n = i\}}$.

Para $A \subseteq S$, definimos análogamente, el *tiempo de retorno a A* como $\tau_A := \inf\{n \geq 1 : X_n \in A\}$. Vamos a decir que $i \in S$ es *recurrente* si $\mathbb{P}(\tau_i < \infty) = 1$, en otro caso decimos que es *transiente*.

Análogamente, podemos definir el *tiempo del k-ésimo retorno a i* (o a $A \subseteq S$), con $k \in \mathbb{N}$, como el tiempo de parada $\tau_i^{(k)}$ (ó $\tau_A^{(k)}$) dada por

$$\tau_i^{(k)} := \begin{cases} \tau_i & \text{si } k = 1 \\ \inf\{n > \tau_i^{(k-1)} : X_n = i\} = \tau_i(X^{(\tau_i^{(k-1)})}) & \text{si } k \geq 2 \end{cases}$$

ó

$$\tau_A^{(k)} := \begin{cases} \tau_A & k = 1 \\ \tau_A(X^{(\tau_A^{(k-1)})}) & k \geq 2, \end{cases}$$

respectivamente. Aquí utilizamos la convención $\inf \emptyset = \infty$.

Proposición 6.19. Sean $i \in S$ y $\theta_i := \mathbb{P}_i(\tau_i < \infty)$. Entonces, $N_i \sim G(1 - \theta_i)$ bajo $\mathbb{P}_i$,

$$\text{Ge}(p) \stackrel{c.s.}{=} \begin{cases} 1 & \text{si } p = 1 \\ \infty & \text{si } p = 0. \end{cases}$$

Demostración. Vamos a probar que $\mathbb{P}_i(N_i = k) = \theta_i^{k-1}(1 - \theta_i) \quad \forall k \in \mathbb{N}$. Lo hacemos por inducción.

$$\underline{k=1}: \mathbb{P}_i(N_i = 1) = \mathbb{P}_i(\tau_i = \infty) = 1 - \theta_i. \quad \checkmark$$

$k \Rightarrow k+1$: Tenemos que

$$\begin{aligned}\mathbb{P}_i(N_i = k+1) &= \mathbb{P}_i(\tau_i^{(k)} < \infty = \tau_i^{(k+1)}) \\ &= \mathbb{P}_i(\tau_i^{(k+1)} = \infty) - \mathbb{P}_i(\tau_i^{(k)} = \infty) \\ &= \mathbb{P}_i(\tau_i^{(k)} < \infty) - \mathbb{P}_i(\tau_i^{(k+1)} < \infty) \\ &= \theta_i^k - \theta_i^{k+1} = \theta_i^k(1 - \theta_i).\end{aligned}$$

Luego, basta con mostrar que $\mathbb{P}_i(\tau_i^{(k)} < \infty) = \theta_i^k \quad \forall k \in \mathbb{N}$:

$k=1$: $\mathbb{P}_i(\tau_i^{(1)} < \infty) = \mathbb{P}_i(\tau_i < \infty) = \theta_i$. ✓

$k \Rightarrow k+1$: Tenemos que

$$\begin{aligned}\mathbb{P}_i(\tau_i^{(k+1)} < \infty) &= \mathbb{P}_i(\tau_i^{(k)} < \infty, \tau_i^{(k+1)} < \infty) \\ &= \mathbb{E}_i(\mathbb{E}_i(\mathbb{1}_{\{\tau_i^{(k)} < \infty\}} \mathbb{1}_{\{\tau_i^{(k+1)} < \infty\}} \mid \mathcal{F}_{\tau_i^{(k)}})) \\ (\text{Markov fuerte en } \tau_i^{(k)}) &= \mathbb{E}_i(\mathbb{E}_i(\mathbb{1}_{\{\tau_i^{(k)} < \infty\}} \mathbb{1}_{\{\tau_1(X^{(\tau_i^{(k)})}) < \infty\}} \mid \mathcal{F}_{\tau_i^{(k)}})) \\ &= \mathbb{E}_i(\mathbb{1}_{\{\tau_i^{(k)} < \infty\}} \underbrace{\mathbb{E}_{X_{\tau_i^{(k)}}}(\mathbb{1}_{\{\tau_1 < \infty\}})}_i) \\ &= \mathbb{E}_i(\mathbb{1}_{\{\tau_i^{(k)} < \infty\}} \mathbb{P}_i(\tau_1 < \infty)) \\ &= \theta_i \mathbb{P}_i(\tau_i^{(k)} < \infty) = \theta_i^{k+1}.\end{aligned}$$

□

Teorema 6.20. Sea $i \in I$. Son equivalentes:

(R1) i es recurrente.

(R2) $N_i = \infty$ $\mathbb{P}_i$ -c.s.

(R3) $\mathbb{E}_i(N_i) = \infty$.

(T1) i es transiente.

(T2) $\mathbb{P}_i(N_i = \infty) = 0$.

(T3) $\mathbb{E}_i(N_i) < \infty$.

Demostración. Vemos sólo las (R1)-(R2)-(R3).

R1 $\Rightarrow$ R2: i es recurrente $\Rightarrow \theta_i = 1 \Rightarrow N_i \sim \text{Ge}(1 - \theta_i) = \text{Ge}(0) \Rightarrow N_i = \infty$ $\mathbb{P}_i$ -c.s.

R2 $\Rightarrow$ R3: ✓

R3 $\Rightarrow$ R1: $\infty = \mathbb{E}_i(N_i) = \frac{1}{1-\theta_i}$ si convenimos que $\frac{1}{0} = \infty$. Esto es equivalente a $\theta_i = 1$. Lo que es equivalente a i recurrente. □

Corolario 6.21 (Criterio de Recurrencia). i es recurrente si y solo si

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \sum_{n=0}^{\infty} \mathbb{P}_i(X_n = i) = \infty.$$

Demostración. i es recurrente si y solo si (por el Teo.)

$$\infty = \mathbb{E}_i(N_i) = \mathbb{E}_i \left(\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n = i\}} \right) = \sum_{n=0}^{\infty} \mathbb{P}_i(X_n = i).$$

□

Proposición 6.22. Si $i \leftrightarrow j$, entonces i recurrente $\Leftrightarrow j$ recurrente.

Demostración. Como $i \leftrightarrow j$, existen $m, n \in \mathbb{N}_0$ tales que $p_{ij}^{(m)} \cdot p_{ji}^{(n)} > 0$. Luego, por Chapman-Kolmogorov, para todo $r \geq 0$,

$$p_{ii}^{(m+n+r)} \geq p_{ij}^{(m)} p_{jj}^{(r)} p_{ji}^{(n)}.$$

Despenjando en $p_{jj}^{(r)}$ y sumando en r , obtenemos que

$$\begin{aligned} \mathbb{E}_j(N_j) &= \sum_{r=0}^{\infty} p_{jj}^{(r)} \\ &\leq \frac{1}{p_{ij}^{(m)} p_{ji}^{(n)}} \sum_{r=0}^{\infty} p_{ii}^{(m+n+r)} \\ &\leq \frac{1}{p_{ij}^{(m)} p_{ji}^{(n)}} \mathbb{E}_i(N_i), \end{aligned}$$

con lo cual, si j es recurrente, resulta $\mathbb{E}_i(N_i) = \infty$ y así, i es recurrente también. Por simetría tenemos la otra implicación. □

Proposición 6.23. Vale lo siguiente:

1. Si $i \neq j \in S$, $i \rightarrow j$, $\mathbb{P}_i(\tau_j < \infty) > 0$.
2. $\mathbb{P}_i(N_j = \infty) = \mathbb{P}_i(\tau_j < \infty) \mathbb{P}_j(N_j = \infty)$.
3. Si $i \rightarrow j$ e i es recurrente, $\mathbb{P}_i(\tau_j < \infty) = 1$.

Demostración. [1.] Tenemos que

$$\mathbb{P}_i(\tau_j < \infty) = \mathbb{P}_i(\exists n \in \mathbb{N}_0 : X_n = j)$$

e

$$i \rightarrow j \Leftrightarrow \mathbb{P}_i(\exists n \in \mathbb{N}_0 : X_n = j) > 0.$$

2. Tenemos que

$$\begin{aligned} \mathbb{P}_i(N_j = \infty) &= \mathbb{P}_i(\tau_j < \infty, N_j = \infty) \\ &= \mathbb{E}_i(\mathbb{E}_i(\mathbf{1}_{\{\tau_i < \infty\}} \mathbf{1}_{\{N_j = \infty\}} \mid \mathcal{F}_{\tau_j})) \\ (\text{Markov fuerte}) &= \mathbb{P}_i(\tau_j < \infty) \mathbb{P}_j(N_j = \infty). \end{aligned}$$

□

Clase 28

10 de Junio

Demostración. 3. Supongamos que $X_0 = i$. Sea V_j^i el número de visitas al estado i antes de visitar j (bien definido, pues i es recurrente).

Por le mismo argumento que la clase pasada (el que mostraba $N_i \sim \text{Ge}(\mathbb{P}_i(\tau_i = \infty))$), vale que

$$V_j^i \sim \text{Ge}(\mathbb{P}_i(\tau_j < \infty)).$$

Pero, como $\mathbb{P}_i(\tau_j < \infty) > 0$ por (1), $V_j^i < \infty$ c.s.

□

Corolario 6.24. Si X es irreducible y recurrente (todo $i \in S$ es irreducible y recurrente), entonces $\mathbb{P}_i(N_j = \infty \forall j \in S) = 1 \quad \forall i \in S$. (lo mismo vale para cualquier μ inicial.)

Demostración. Por la proposición anterior, fijado $i \in S$,

$$\mathbb{P}_i(N_j = \infty) = \underbrace{\mathbb{P}_i(\tau_j < \infty)}_{=1 \text{ por (3)}} \overbrace{\mathbb{P}_j(N_j = \infty)}^{=1 \text{ (} j \text{ recurrente)}} = 1 \quad \forall j \in S.$$

(y la primera igualdad está dada por (2).)

□

Proposición 6.25. Toda clase comunicante recurrente es cerrada ($i \rightarrow j + i$ recurrente $\Rightarrow j \rightarrow i$).

Demostración. Sea C una clase recurrente, $i \in C$ y $j \in S$ tal que $i \rightarrow j$. Queremos ver que $j \rightarrow i$. Supongamos que no. Entonces, como $i \rightarrow j$, existe $n \in \mathbb{N}$ con $p_{ij}^{(n)} > 0$. Si $j \not\rightarrow i$, estando en j a tiempo n , la cadena no puede regresar a i . Luego,

$$\mathbb{P}_i(X_n = j, N_j < \infty) = \mathbb{P}_i(X_n = j) = p_{ij}^{(n)} > 0.$$

Pero entonces,

$$\mathbb{P}_i(N_i < \infty) \geq \mathbb{P}_i(X_n = j, N_j < \infty) = p_{ij}^{(n)} > 0,$$

lo cual no puede pasar, pues i es recurrente. Luego, $j \rightarrow i$. $\square$

Proposición 6.26. Si j es transiente, entonces $\mathbb{E}_i(N_j) < \infty \quad \forall i$.

Demostración. Notar que

$$\begin{aligned} \mathbb{E}_i(N_j) &= \mathbb{E}_i(N_j \mathbf{1}_{\{\tau_j < \infty\}}) \\ &= \underbrace{\mathbb{P}_i(\tau_j < \infty)}_{\leq 1} \underbrace{\mathbb{E}_j(N_j)}_{< \infty} < \infty. \end{aligned} \quad (\text{Markov fuerte})$$

$\square$

Corolario 6.27. Si S es finito, existe un estado recurrente. En particular,

$$S \text{ finito} + X \text{ irreducible} \Rightarrow X \text{ recurrente.}$$

Demostración. Como S es finito,

$$\sum_{j \in S} \lim_{n \rightarrow \infty} p_{ij}^{(n)} = \lim_{n \rightarrow \infty} \sum_{j \in S} p_{ij}^{(n)} = 1. \quad (*)$$

Si todo $j \in S$ fuese transiente, entonces, como

$$p_{ij}^{(n)} \xrightarrow{n \rightarrow \infty} 0,$$

pues

$$\sum_{n=0}^{\infty} p_{ij}^{(n)} = \mathbb{E}_i(N_j) < \infty,$$

la suma de la izquierda en $(*)$ daría 0, no 1. Entonces, existe al menos un estado recurrente. $\square$

Comentarios. Si S es infinito, esto NO es cierto.

Ejemplo. Caminata aleatoria en $\mathbb{Z}$ con saltos X_n de media $\neq 0$ (esto es irreducible y transiente). (recordar la animación de la clase pasada.)

Definición 6.28. Sean P una matriz estocástica y μ una medida sobre S . Decimos que μ es una *medida invariante* para P (o *P -invariante*) si $\mu P = \mu$. Si además μ es medida de probabilidad, decimos que μ es *distribución invariante*.

Observación. Si μ es medida invariante, $\lambda \cdot \mu$ es medida invariante $\forall \lambda \geq 0$.

Comentarios. Se llama distribución invariante pues

$$\mathbb{P}_\mu(X_n = j) = (\mu P^n)_j = \mu(j) \quad \forall n \in \mathbb{N}_0.$$

A veces, estas reciben el nombre de *distribuciones estacionarias o de equilibrio*.

Observación. Si S es finito y existe $i_0 \in S$ tal que los límites

$$\pi_j := \lim_{n \rightarrow \infty} p_{i_0 j}^{(n)}$$

existen para todo $j \in S$, entonces $\pi = (\pi_j)_{j \in S}$ es una distribución invariante. (esto da una motivación de por qué también las llamamos estacionarias.)

Observación. Como P es matriz estocástica, P tiene autovalor (a derecha) 1 con autovector $\mathbf{1} = (1, 1, \dots, 1)$, pues $(P \cdot \mathbf{1})_i = \sum_{j \in S} p_{ij} = 1 \quad \forall i \in S$.

Luego, P^T tiene autovalor (a derecha) 1 con un cierto autovector v ; i.e., $P^T \cdot v = v \Leftrightarrow v^T P = v^T$. O sea, que siempre existen autovectores a izquierda de P de autovalor 1 ("medida con signo invariante").

Luego, una medida P -invariante es un autovector a izquierda de P de autovalor 1 (esto siempre existe) de **entradas no negativas**. Que exista una distribución invariante requiere además que dicho v esté en $l_1(S)$.

Ejemplo.

1. $S = \mathbb{Z}$ y $\mu(n) \equiv 1$ es medida invariante para la caminata aleatoria simétrica en $\mathbb{Z}$.

$$(\mu P)_n = \sum_{j \in \mathbb{Z}} p_{jn} = p_{n-1,n} + p_{n+1,n} = 1 = \mu(n).$$

Pero μ es **infinita**.

2. **Urna de Ehrenfest:** $S = \{0, 1, \dots, r\}$ y $p_{k,k+1} = \frac{r-k}{r}$, $p_{k,k-1} = \frac{k}{r}$. Con

$$\mu(k) = \frac{1}{2^r} \binom{r}{k},$$

$$\mu \sim \text{Bi}(r, \frac{1}{2}).$$