Teoría de Integración

Basado en las clases impartidas por Santiago Saglietti en el primer semestre del 2026

Contents

1 1 **3**

1.1 Espacios de medida . . . 3

1.1.1 Ejemplos de medidas . . . 4

1.1.2 Propiedades de una medida . . . 4

1.2 Espacios de probabilidad . . . 4

1.2.1 Notación para espacios de probabilidad . . . 5

1.2.2 Ejemplos de espacios de probabilidad . . . 5

1.2.3 Propiedades adicionales de una probabilidad . . . 5

1.3 Análisis vs Probabilidad . . . 5

1.4 Funciones medibles y variables aleatorias . . . 6

1.4.1 En Análisis . . . 6

1.4.2 En Probabilidad . . . 6

1.5 σ-álgebra de Borel . . . 6

1.6 Distribución de una variable aleatoria . . . 7

1.6.1 Diferencia de enfoques . . . 7

1.7 Función de distribución . . . 7

1.7.1 Propiedades . . . 7

1.7.2 Demostración del Teorema (esquema) . . . 8

1.8 Tipos de variables aleatorias . . . 9

1.9 Teorema de Radon-Nikodym . . . 9

1.10 Teorema de existencia y unicidad de variable aleatoria con distribución dada . . . 10

1.10.1 Forma canónica: Teorema de extensión de Carathéodory . 10

1.10.2 Forma constructiva: inversa generalizada . . . 12

1.11 Teorema π-λ de Dynkin . . . 13

1.12 Independencia . . . 14

1.12.1 Aplicación . . . 18

1.13 Ley 0-1 de Kolmogorov . . . 21

1.14 Lemas de Borel-Cantelli . . . 22

1.15 Existencia de sucesiones independientes . . . 22

2 Procesos Estocásticos (Notas de Anton Bovier) **24**

2.1 Perspectiva Trayectorial . . . 24

2.1.1 Construcción de medidas en S^I . . . 27

3 Leyes de los grandes números **32**

3.1 Convergencia en distribución. . . . 35

3.1.1 Aplicaciones . . . 41

4 Esperanza Condicional **45**

Chapter 1

1

Clase 1

4 de Marzo

1.1 Espacios de medida

- Un espacio E será cualquier conjunto no vacío.
- Cualquier colección de subconjuntos de un espacio E será denominada una **clase** (de subconjuntos de E).

Definición 1.1 (σ-álgebra)**.** Una clase Σ de subconjuntos de un espacio E se dirá una **σ-álgebra** si cumple que:

i) $\emptyset \in \Sigma$ (en particular, Σ es no vacía).

ii) $A \in \Sigma \Rightarrow A^c \in \Sigma$.

iii) $(A_n)_{n\in\mathbb{N}} \subset \Sigma \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \Sigma$.

Definición 1.2 (Espacio medible)**.** Un **espacio medible** es cualquier par (E, Σ) donde E es un espacio y Σ es una σ-álgebra (de subconjuntos de E).

Definición 1.3 (Medida)**.** Dado un espacio medible (E, Σ), una aplicación $\mu : \Sigma \to [0, \infty]$ se dirá una **medida (no negativa)** sobre (E, Σ) si cumple que:

i) $\mu(\emptyset) = 0$,

ii) si $(A_n)_{n\in\mathbb{N}} \subset \Sigma$ son conjuntos disjuntos entonces $\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n)$.

Si μ cumple (ii) decimos que μ es **σ-aditiva**.

Definición 1.4 (Espacio de medida)**.** Un **espacio de medida** será cualquier terna (E, Σ, μ) donde (E, Σ) es un espacio medible y μ es una medida sobre (E, Σ).

1.1.1 Ejemplos de medidas

Ejemplo (Medida de Lebesgue)**.**

- $E = \mathbb{R}^d$
- $\Sigma = \{\text{conjuntos medibles Lebesgue}\}$
- $\mu =$ medida de Lebesgue en $\mathbb{R}^d$

Ejemplo (Medida de contar)**.**

- E un espacio arbitrario
- $\Sigma = 2^E$ (partes de E)
- $\mu =$ medida de contar ($\mu(A) = \#A$)

Ejemplo (Medidas de Hausdorff)**.**

- $E = \mathbb{R}^d$
- $\Sigma = \{\text{Borelianos de } \mathbb{R}^d\}$
- Fijado $s \in [0, \infty)$, $\quad \mu = \mathcal{H}^s =$ medida de Hausdorff s-dimensional

1.1.2 Propiedades de una medida

Si μ es una medida sobre (E, Σ), entonces:

Propiedad 1.5 (Monotonía)**.** $A \subseteq B \Rightarrow \mu(A) \leq \mu(B)$.

Propiedad 1.6 (Subaditividad)**.** $A \subseteq \bigcup_{n=1}^{\infty} A_n \Rightarrow \mu(A) \leq \sum_{n=1}^{\infty} \mu(A_n)$.

Propiedad 1.7 (Continuidad inferior)**.** $A_n \nearrow A \Rightarrow \mu(A_n) \nearrow \mu(A)$.

Propiedad 1.8 (Continuidad superior)**.** $A_n \searrow A$ y $\mu(A_n) < \infty$ para algún n (o $\mu(A_1) < \infty$) $\Rightarrow \mu(A_n) \searrow \mu(A)$. Puede ser falso sin esta condición.

1.2 Espacios de probabilidad

Definición 1.9. Un espacio de medida (E, Σ, μ) se llamará un **espacio de probabilidad** si $\mu(E) = 1$. En este caso, μ recibe el nombre de **medida de probabilidad** (o probabilidad a secas).

1.2.1 Notación para espacios de probabilidad

- El espacio E se denota Ω, y lo llamamos **espacio muestral**.
- Los elementos de Ω se denotan ω (y a veces se llaman **realizaciones**).
- La σ-álgebra Σ se suele denotar por $\mathcal{F}$.
- Los elementos de la σ-álgebra $\mathcal{F}$ se llaman **eventos**.
- La medida μ se denota $\mathbb{P}$ o P.

1.2.2 Ejemplos de espacios de probabilidad

Ejemplo (Espacios equiprobables)**.** Se llaman así porque todas las realizaciones tienen la misma probabilidad.

- Ω un conjunto finito.
- $\mathcal{F} = 2^{\Omega}$ (partes de Ω).
- $\mathbb{P}(A) = \dfrac{\#A}{\#\Omega}$.

Ejemplo (Espacios discretos)**.**

- Ω un conjunto finito o numerable.
- $\mathcal{F} = 2^{\Omega}$.
- $\mathbb{P}(A) = \sum_{\omega \in A} p(\omega)$, donde $(p(\omega))_{\omega \in \Omega}$ es algún vector fijo que satisface $p(\omega) \geq 0 \; \forall \omega \in \Omega$ y $\sum_{\omega \in \Omega} p(\omega) = 1$.

Ejemplo (Un ejemplo no discreto)**.** $\Omega = [0, 1]$, $\mathcal{F} = \{\text{Borelianos de } [0, 1]\}$, $\mathbb{P}(A) = |A|$ (medida de Lebesgue).

1.2.3 Propiedades adicionales de una probabilidad

Si $\mathbb{P}$ es una probabilidad sobre $(\Omega, \mathcal{F})$, entonces a las propiedades anteriores se suman:

Propiedad 1.10 (Continuidad superior sin hipótesis adicional)**.** $A_n \searrow A \Rightarrow \mathbb{P}(A_n) \searrow \mathbb{P}(A)$.

Propiedad 1.11 (Complemento)**.** $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.

1.3 Análisis vs Probabilidad

Aunque tanto en Análisis (Teoría de la medida) como en Probabilidad se trabaja con espacios de medida, la interpretación en cada área es muy diferente:

- **En Análisis:**
  - E suele ser un espacio topológico (i.e. con alguna noción de geometría dentro), típicamente $\mathbb{R}^d$.

  - Σ representa la clase de "conjuntos medibles", i.e. conjuntos suficientemente buenos geométricamente como para poder "medirles".
  - **Ejemplo:** la clase de conjuntos medibles Lebesgue en $\mathbb{R}^d$.
  - $\mu(A)$ representa la "medida" del conjunto A. Fijado el espacio E bajo estudio, típicamente Σ queda fija y μ cambia.

- **En Probabilidad:**
  - Ω es el conjunto de posibles resultados de un experimento bajo estudio. No tiene por qué haber geometría subyacente.
  - $\mathcal{F}$ representa el conjunto de "información observable" sobre el experimento en cuestión.
  - $\mathbb{P}(A)$ representa la probabilidad de que ocurra el evento A. Fijado el experimento bajo estudio, típicamente $\mathbb{P}$ queda fija y $\mathcal{F}$ cambia.

Clase 2

6 de Marzo

1.4 Funciones medibles y variables aleatorias

1.4.1 En Análisis

Sean $(\Omega, \mathcal{F})$ y (E, Σ) dos espacios medibles. Una aplicación $f : \Omega \to E$ se dirá **medible** de $(\Omega, \mathcal{F})$ a (E, Σ) (o (Ω, Σ)-medible o medible a secas) si $f^{-1}(B) \in \mathcal{F}$ para todo $B \in \Sigma$.

Si $(\Omega, \mathcal{F}, \mu)$ es un espacio de medida y $f : \Omega \to E$ es (Ω, Σ)-medible, la medida μ_f sobre (E, Σ) dada por la fórmula

$$\mu_f(B) := \mu \circ f^{-1}(B) = \mu(f^{-1}(B)) \in \mathcal{F} \quad \text{(pues } f \text{ es medible)}$$

se denomina la **medida inducida** o **push-forward** de μ por f.

1.4.2 En Probabilidad

Una **variable aleatoria** es una aplicación $X : \Omega \to \mathbb{R}$ medible de $(\Omega, \mathcal{F})$ a $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, donde:

- $(\Omega, \mathcal{F})$ es algún espacio medible,
- $\mathcal{B}(\mathbb{R})$ es la clase de los **borelianos** en $\mathbb{R}$.

Es decir, una variable aleatoria es cualquier aplicación medible a valores en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Notación: Las variables aleatorias se denotan por X en lugar de f.

Observación. A veces se reemplaza $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ por $(\overline{\mathbb{R}}, \mathcal{B}(\overline{\mathbb{R}}))$ en la definición.

1.5 σ-álgebra de Borel

Definición 1.12. Dado un espacio topológico $(E, \mathcal{T})$, definimos su **σ-álgebra de Borel**, y la notamos $\mathcal{B}(E)$, como aquella generada por $\mathcal{T}$, i.e.

$$\mathcal{B}(E) := \sigma(\mathcal{T}).$$

Luego, un **elemento aleatorio** sobre un espacio topológico E es una aplicación medible $X : \Omega \to E$ desde un espacio medible $(\Omega, \mathcal{F})$ al espacio medible $(E, \mathcal{B}(E))$.

1.6 Distribución de una variable aleatoria

Si $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad y $X : \Omega \to E$ es $(\mathcal{F}, \mathcal{B}(E))$-medible, entonces la medida $\mathbb{P}_X$ inducida sobre $(E, \mathcal{B}(E))$ recibe el nombre de **distribución de** X (sobre $(E, \mathcal{B}(E))$), i.e.

$$\mathbb{P}_X(B) := \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{B}(E).$$

A los eventos $X^{-1}(B)$ se los suele notar (en probabilidad) como $\{X \in B\}$, i.e.

$$\{X \in B\} := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{F}.$$

Se suprime el rol de ω en la notación.

1.6.1 Diferencia de enfoques

- **En Análisis**: interesan propiedades de las funciones medibles f que dependen de su dominio (continuidad, derivabilidad, convexidad, gráfico, etc.).
- **En Probabilidad**: no interesa el dominio de una variable aleatoria X, sino su distribución en el codominio.

1.7 Función de distribución

La distribución de una variable aleatoria X (a valores en $\mathbb{R}$) se suele describir mediante su **función de distribución (acumulada)** $F_X : \mathbb{R} \to [0, 1]$ dada por la fórmula

$$F_X(x) := \mathbb{P}(X \leq x).$$

1.7.1 Propiedades

La función de distribución F_X satisface:

Propiedad 1.13 (Monotonía)**.** F_X es monótona creciente.

Propiedad 1.14 (Límites)**.**

$$F_X(-\infty) := \lim_{x \to -\infty} F_X(x) = 0 \quad \text{y} \quad F_X(+\infty) := \lim_{x \to +\infty} F_X(x) = 1.$$

Propiedad 1.15 (Continuidad por la derecha)**.** F_X es continua a derecha, i.e.

$$\lim_{y \to x^+} F_X(y) = F_X(x).$$

Propiedad 1.16 (Saltos)**.**

$$\Delta F_X(x) := F_X(x) - F_X(x^-) = \mathbb{P}(X = x).$$

Si una función $F : \mathbb{R} \to [0,1]$ satisface (i), (ii) y (iii) arriba, diremos que se trata de una **función de distribución** (no necesariamente asociada a alguna variable aleatoria X).

El siguiente resultado nos dice por qué es suficiente F_X para describir $\mathbb{P}_X$.

Teorema 1.17. Sea F una función de distribución. Entonces:

1. Existe una variable aleatoria X (definida en algún espacio de probabilidad) tal que $F = F_X$.
2. La distribución de dicha variable es única, i.e.

$$F_{X_1} = F_{X_2} \Rightarrow \mathbb{P}_{X_1} = \mathbb{P}_{X_2} \quad (\text{si } \mathbb{P}_{X_1} = \mathbb{P}_{X_2} \text{ lo notamos } X_1 \overset{\mathcal{L}}{=} X_2).$$

Corolario 1.18.

1. Dada una probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, la función $F : \mathbb{R} \to [0,1]$ definida por $F(x) := \mathbb{P}((-\infty, x])$ es una función de distribución.
2. Dada una función de distribución F, existe una única probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que $\mathbb{P}((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$. De hecho, $\mathbb{P} = \mathbb{P}_X$ donde X es la variable del teorema.

En particular, existe una correspondencia biunívoca entre

$$\mathcal{U} := \{\mathbb{P} : \mathbb{P} \text{ medida de probabilidad en } (\mathbb{R}, \mathcal{B}(\mathbb{R}))\}$$

y

$$\mathcal{B} := \{F : F \text{ función de distribución}\}$$

dada por:

$$\begin{aligned} \alpha : \mathcal{U} &\to \mathcal{B}, & \beta : \mathcal{B} &\to \mathcal{U}, \\ \mathbb{P} &\mapsto F(x) := \mathbb{P}((-\infty, x]), & F &\mapsto \mathbb{P}_X \text{ donde } F_X = F \text{ (existe y es única)}. \end{aligned}$$

Como consecuencia del teorema, α y β son inversas una de la otra.

1.7.2 Demostración del Teorema (esquema)

Demostraremos únicamente el teorema; la deducción del corolario a partir de éste es sencilla. Además, lo haremos de dos formas:

1. **Forma canónica**: tomamos $(\Omega, \mathcal{F}) := (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ y $X := \mathrm{id}_\Omega$ $(X(\omega) = \omega)$ y definimos $\mathbb{P}$ sobre $(\Omega, \mathcal{F})$ de manera tal que en $(\Omega, \mathcal{F}, \mathbb{P})$ la variable

$X := \mathrm{id}_\Omega$ cumpla lo buscado.

2. **Forma constructiva**: tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ((0,1), \mathcal{B}((0,1)), \mathrm{leb}(0,1))$ y definimos allí una variable X que cumpla lo buscado.

1.8 Tipos de variables aleatorias

Trabajaremos frecuentemente con dos tipos de variables aleatorias.

Definición 1.19 (Variable aleatoria discreta)**.** Una variable aleatoria X se dice **discreta** si existe $S \subseteq \mathbb{R}$ a lo sumo numerable tal que $\mathbb{P}_X(S) = 1$. Equivalentemente, X es discreta si toma a lo sumo numerables valores (salvo medida nula). El conjunto

$$\mathcal{A}_X = \{x \in \mathbb{R} : \mathbb{P}(X = x) > 0\}$$

es el conjunto de **átomos** de X.

Si X es discreta, definimos su **función de probabilidad puntual** como la función $p_X : \mathcal{A}_X \to [0,1]$ dada por

$$p_X(x) := \mathbb{P}(X = x).$$

Definición 1.20 (Variable aleatoria absolutamente continua)**.** Una variable aleatoria X se dice **absolutamente continua** si existe una función $f : \mathbb{R} \to \mathbb{R}_{\geq 0}$ medible Borel tal que

$$F_X(x) = \int_{-\infty}^{x} f(t)\, dt \quad \text{para todo } x \in \mathbb{R}.$$

En tal caso, la función f se llama la **densidad** de X.

Puede verificarse que X es absolutamente continua $\Leftrightarrow$ F_X es absolutamente continua, i.e. F_X es derivable en casi todo punto, $F_X' \in L^1(\mathbb{R})$ y se verifica que

$$F_X(x) = \int_{-\infty}^{x} F_X'(t)\, dt \quad \text{para todo } x \in \mathbb{R}.$$

Además, en tal caso vale que $f_X = F_X'$ en casi todo punto.

Observación. Existen variables aleatorias que no son ni discretas ni absolutamente continuas, ni una "mezcla" de ambas (ver Práctica).

Clase 3

9 de Marzo

1.9 Teorema de Radon-Nikodym

Teorema 1.21 (Radon-Nikodym)**.** Sean μ y ν dos medidas σ-finitas sobre (E, Σ). Entonces las siguientes afirmaciones son equivalentes:

1. $\nu \ll \mu$ (es decir, ν es absolutamente continua con respecto a μ).
2. Existe una función $f : E \to \mathbb{R}_{\geq 0}$ $(\Sigma, \mathcal{B}(\mathbb{R}))$-medible tal que

$$\nu(A) = \int_A f \, d\mu \quad \text{para todo } A \in \Sigma.$$

La función f es única salvo conjuntos de μ-medida nula y se denomina **derivada de Radon-Nikodym** de ν respecto de μ, denotada por $f = \frac{d\nu}{d\mu}$.

1.10 Teorema de existencia y unicidad de variable aleatoria con distribución dada

Volvamos al teorema de la clase pasada para demostrarlo:

Teorema 1.22. Sea F una función de distribución. Entonces:

1. Existe una variable aleatoria X (definida en algún espacio de probabilidad) tal que $F = F_X$.
2. La distribución de dicha variable es única, i.e.

$$F_{X_1} = F_{X_2} \Rightarrow \mathbb{P}_{X_1} = \mathbb{P}_{X_2} \quad (\text{si } \mathbb{P}_{X_1} = \mathbb{P}_{X_2} \text{ lo notamos } X_1 \overset{\mathcal{L}}{=} X_2).$$

Corolario 1.23.

1. Dada una probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, la función $F : \mathbb{R} \to [0, 1]$ definida por $F(x) := \mathbb{P}((-\infty, x])$ es una función de distribución.
2. Dada una función de distribución F, existe una única probabilidad $\mathbb{P}$ sobre $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que $\mathbb{P}((-\infty, x]) = F(x)$ para todo $x \in \mathbb{R}$. De hecho, $\mathbb{P} = \mathbb{P}_X$ donde X es la variable del teorema.

Demostraremos únicamente el teorema; la deducción del corolario a partir de éste es sencilla. Además, lo haremos de dos formas:

1. **Forma canónica**: tomamos $(\Omega, \mathcal{F}) := (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ y $X := \mathrm{id}_\Omega$ $(X(\omega) = \omega)$ y definimos $\mathbb{P}$ sobre $(\Omega, \mathcal{F})$ de manera tal que en $(\Omega, \mathcal{F}, \mathbb{P})$ la variable $X := \mathrm{id}_\Omega$ cumpla lo buscado.
2. **Forma constructiva**: tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ((0, 1), \mathcal{B}((0, 1)), \mathrm{leb}_{(0,1)})$ y definimos allí una variable X que cumpla lo buscado.

1.10.1 Forma canónica: Teorema de extensión de Carathéodory

Definición 1.24 (Semialgebra)**.** Una clase $\mathcal{J}$ de subconjuntos de un espacio E se dice una **semialgebra** si satisface las siguientes propiedades:

i) $\mathcal{J}$ es no vacía.

ii) $S, T \in \mathcal{J} \Rightarrow S \cap T \in \mathcal{J}$ (es cerrada por intersecciones).

iii) $S \in \mathcal{J} \Rightarrow \exists T_1, \ldots, T_n \in \mathcal{J}$ disjuntos tales que $S = \bigcup_{i=1}^n T_i$.

(Observar que $\emptyset \in \mathcal{J}$: si $S \in \mathcal{J}$ y $S = \bigcup_{i=1}^n T_i$ con T_i disjuntos, $\emptyset = S \cap \emptyset \in \mathcal{J}$ por (ii).)

Teorema 1.25 (Extensión de Carathéodory)**.** Sean $\mathcal{J}$ una semialgebra de subconjuntos de un espacio E y $\mu_0 : \mathcal{J} \to [0,1]$ una aplicación que satisface:

a) $\mu_0(\emptyset) = 0$.

b) μ_0 es finitamente aditiva en $\mathcal{J}$:

$$(A_n)_{n=1,\ldots,N} \subseteq \mathcal{J} \text{ disjuntos, } \bigcup_{n=1}^N A_n \in \mathcal{J} \Rightarrow \mu_0\left(\bigcup_{n=1}^N A_n\right) = \sum_{n=1}^N \mu_0(A_n).$$

c) μ_0 es σ-subaditiva en $\mathcal{J}$:

$$(A_n)_{n\in\mathbb{N}} \subseteq \mathcal{J} \text{ disjuntos, } A \in \mathcal{J}, A \subseteq \bigcup_{n\in\mathbb{N}} A_n \Rightarrow \mu_0(A) \leq \sum_{n\in\mathbb{N}} \mu_0(A_n).$$

Entonces existe una medida μ sobre $(E, \sigma(\mathcal{J}))$ tal que $\mu|_{\mathcal{J}} = \mu_0$.
Además, si μ_0 es σ-finita (existen $(E_n)_{n\in\mathbb{N}} \subseteq \mathcal{J}$ tales que $E = \bigcup_n E_n$ y $\mu_0(E_n) < \infty$ para todo n), entonces la extensión μ es única.

Idea de demostración del teorema (forma canónica)

- Consideramos la semialgebra $\mathcal{J} = \{(a,b] : -\infty \leq a \leq b \leq \infty\}$ con la convención $(a,a] = \emptyset$ y $(a,\infty]$ si $b = \infty$.
- Definimos $\mu_0 : \mathcal{J} \to [0,1]$ como $\mu_0((a,b]) = F(b) - F(a)$.
- Probamos que μ_0 satisface (s0), (s1), (s2). (La demostración de (s2) requiere trabajo.)
- Por el teorema de Carathéodory, existe extensión μ a todo $\sigma(\mathcal{J}) = \mathcal{B}(\mathbb{R})$.
- Tomamos $\mathbb{P} := \mu$ y vemos que en el espacio de probabilidad $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$ la variable aleatoria $X := \mathrm{id}_{\mathbb{R}}$ cumple

$$F_X(x) = \mathbb{P}(\{\omega : X(\omega) \leq x\}) = \mathbb{P}((-\infty, x]) = F(x) - F(-\infty) = F(x).$$

- Si $F_1 = F_2 = F$, entonces $\mathbb{P}_1$ y $\mathbb{P}_2$ son extensiones de μ_0 a $\sigma(\mathcal{J})$. Como $\mu_0(\mathbb{R}) = F(\infty) - F(-\infty) = 1$, por la unicidad en el teorema de Carathéodory, $\mathbb{P}_1 = \mathbb{P}_2$.

Observación. La forma canónica lleva bastante trabajo (que no hicimos), que es el mismo que se suele hacer al construir la medida de Lebesgue. La forma constructiva es más rápida (y útil), pero asume que ya tenemos construida la medida de Lebesgue de antemano.

1.10.2 Forma constructiva: inversa generalizada

Para la demostración de forma constructiva, introducimos la inversa generalizada.

Definición 1.26 (Inversa generalizada)**.** Sea $F : \mathbb{R} \to [0,1]$ una función. Definimos su **inversa generalizada** $F^{-1} : [0,1] \to \overline{\mathbb{R}}$ mediante la fórmula

$$F^{-1}(y) := \sup\{x \in \mathbb{R} : F(x) < y\},$$

donde convenimos que $\sup \emptyset = -\infty$ y $\sup A = \infty$ si A no está acotado superiormente.

Lema 1.27. Sea $F : \mathbb{R} \to [0,1]$ una función de distribución. Entonces, si U es una variable aleatoria tal que $\mathbb{P}_U = \mathrm{leb}_{[0,1]}$, i.e. $\mathbb{P}(U \in B) = |B \cap [0,1]|$ para todo Borel B, resulta que $X := F^{-1}(U)$ es una variable aleatoria y satisface $F_X = F$.

Demostración.

1. En primer lugar, observemos que F^{-1} es medible Borel por ser monótona creciente por definición.
2. En particular, $X := F^{-1}(U)$ es variable aleatoria (pues $X^{-1}(B) = U^{-1}((F^{-1})^{-1}(B)) \in \mathcal{F}$ para todo $B \in \mathcal{B}(\mathbb{R})$).
3. Además, vale que

$$\{X \leq x\} = \{U \leq F(x)\} \quad \text{para todo } x \in \mathbb{R}, \tag{1}$$

de manera tal que

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = |(-\infty, F(x)] \cap [0,1]| = F(x).$$

En efecto, para ver (1) notemos:

($\subseteq$) Si $\omega \in \Omega$ es tal que $X(\omega) \leq x$ entonces debe valer que $U(\omega) \leq F(x)$. En caso contrario, si $F(x) < U(\omega)$, como F es continua a derecha, existiría $\varepsilon > 0$ tal que $F(x+\varepsilon) < U(\omega)$. En particular, $x + \varepsilon \in \{t \in \mathbb{R} : F(t) < U(\omega)\}$ y, por lo tanto, $x + \varepsilon \leq \sup\{t : F(t) < U(\omega)\} = F^{-1}(U(\omega)) = X(\omega)$, lo que implica $X(\omega) > x$, contradicción.

($\supseteq$) Si ω cumple que $U(\omega) \leq F(x)$, entonces x es una cota superior de $\{t \in \mathbb{R} : F(t) < U(\omega)\}$. En efecto, si t pertenece a ese conjunto, entonces $F(t) < U(\omega) \leq F(x)$; por monotonía de F, $t \leq x$. Luego $X(\omega) = \sup\{t : F(t) < U(\omega)\} \leq x$.

Así queda demostrada la igualdad (1).

□

Observación. F^{-1} se llama inversa generalizada de F puesto que satisface la igualdad $\{y : F^{-1}(y) \leq x\} = \{y : y \leq F(x)\}$ dada en (1) y, si en vez de $\leq$ tuviésemos $<$ en (1), entonces sería la inversa tradicional.

Ahora estamos listos para dar la demostración de forma constructiva.

Demostración. Tomamos $(\Omega, \mathcal{F}, \mathbb{P}) := ([0,1], \mathcal{B}([0,1]), \mathrm{leb}_{[0,1]})$ y $U := \mathrm{id}_{[0,1]}$. Como $\mathbb{P}_U = \mathrm{leb}_{[0,1]}$ por definición, por el lema previo, $X := F^{-1}(U)$ es la variable aleatoria buscada. □

Para demostrar la unicidad (teorema, parte 2) necesitamos otro resultado.

1.11 Teorema π-λ de Dynkin

Definición 1.28 (π-sistema)**.** Una clase $\mathcal{P}$ de subconjuntos de un espacio E se dice un **π-sistema** si es cerrada por intersecciones finitas, i.e., si $A, B \in \mathcal{P}$ entonces $A \cap B \in \mathcal{P}$.

Definición 1.29 (λ-sistema)**.** Una clase $\mathcal{D}$ de subconjuntos de un espacio E se dice un **λ-sistema** si verifica las siguientes condiciones:

I) $E \in \mathcal{D}$.

II) $A \in \mathcal{D} \Rightarrow A^c \in \mathcal{D}$.

III) $(A_n)_{n\in\mathbb{N}} \subseteq \mathcal{D}$ disjuntos $\Rightarrow \bigcup_{n\in\mathbb{N}} A_n \in \mathcal{D}$.

Teorema 1.30 (π-λ de Dynkin)**.** Si $\mathcal{P}$ es un π-sistema y $\mathcal{D}$ es un λ-sistema tales que $\mathcal{P} \subseteq \mathcal{D}$, entonces $\sigma(\mathcal{P}) \subseteq \mathcal{D}$.

Demostración. Ver Apéndice I o [Teorema 3.2] de Billingsley (PAM). □

Como consecuencia, tenemos el siguiente corolario.

Corolario 1.31. Supongamos que $\mathbb{P}_1$ y $\mathbb{P}_2$ son probabilidades en $\sigma(\mathcal{P})$, donde $\mathcal{P}$ es un π-sistema. Si $\mathbb{P}_1$ y $\mathbb{P}_2$ coinciden en $\mathcal{P}$ entonces también coinciden en todo $\sigma(\mathcal{P})$.

Demostración. Sea $\mathcal{D} = \{A \in \sigma(\mathcal{P}) : \mathbb{P}_1(A) = \mathbb{P}_2(A)\}$.

- Por hipótesis, $\mathcal{P} \subseteq \mathcal{D}$.
- Si vemos que $\mathcal{D}$ es un λ-sistema, entonces por el teorema de Dynkin tendremos que $\sigma(\mathcal{P}) \subseteq \mathcal{D}$ y, por lo tanto, $\mathbb{P}_1 \equiv \mathbb{P}_2$ en $\sigma(\mathcal{P})$.

Veamos que $\mathcal{D}$ es un λ-sistema:

i) $\mathbb{P}_1(\Omega) = 1 = \mathbb{P}_2(\Omega)$ por ser probabilidades. Luego $\Omega \in \mathcal{D}$.

ii) $A \in \mathcal{D} \Rightarrow \mathbb{P}_1(A) = \mathbb{P}_2(A) \Rightarrow 1 - \mathbb{P}_1(A) = 1 - \mathbb{P}_2(A) \Rightarrow \mathbb{P}_1(A^c) = \mathbb{P}_2(A^c) \Rightarrow A^c \in \mathcal{D}$.

iii) Si $(A_n)_{n\in\mathbb{N}} \subseteq \mathcal{D}$ son disjuntos, entonces

$$\mathbb{P}_1\left(\bigcup_n A_n\right) = \sum_n \mathbb{P}_1(A_n) = \sum_n \mathbb{P}_2(A_n) = \mathbb{P}_2\left(\bigcup_n A_n\right),$$

por la σ-aditividad de las probabilidades. Luego $\bigcup_n A_n \in \mathcal{D}$.

Luego $\mathcal{D}$ es un λ-sistema y esto concluye la demostración. $\square$

Finalmente, notamos que $\sigma(\mathcal{P})$ contiene a todos los intervalos de la forma $(a, b] = (-\infty, b] \cap (-\infty, a]^c$ y, por lo tanto, a todos los intervalos abiertos $(a, b) = \bigcup_{n\in\mathbb{N}}(a, b - \frac{1}{n}]$. Como cualquier abierto en $\mathbb{R}$ es unión numerable de intervalos (a, b) (por ser $\mathbb{R}$ separable), $\sigma(\mathcal{P})$ contiene a cualquier abierto en $\mathbb{R}$. Por minimalidad de $\mathcal{B}(\mathbb{R})$, resulta que $\mathcal{B}(\mathbb{R}) \subseteq \sigma(\mathcal{P})$. Así, la unicidad de la probabilidad que coincide en los intervalos de la forma $(-\infty, x]$ queda garantizada por el corolario anterior, completando la demostración del teorema.

Clase 4

11 de Marzo

1.12 Independencia

Definición 1.32 (a). Sea Ω un conjunto y $(E, \mathcal{F})$ un espacio medible. Sea $f\colon \Omega \to E$. Definimos $\sigma(f)$ como la σ-álgebra más pequeña de Ω que hace que f sea medible. Es facil ver que

$$\sigma(f) = \{f^{-1}(B) \mid B \in \mathcal{F}\}.$$

Sea $(f_i)_{i\in I}$ una familia de funciones $f_i \to E_i$ donde $(E_i, \mathcal{F}_i)$ es espacio medible para cada i. Entonces, defino $\sigma(f_i;\ i \in I)$ como la σ-álgebra más pequeña que hace que todas las f_i sean medibles. Se puede demostrar que

$$\sigma(f_i;\ i \in I) = \sigma\left(\bigcup_{i\in I} \sigma(f_i)\right).$$

Definición 1.33 (Espacio Producto)**.** Sea $(E_1, \mathcal{F}_1, \mu_1)$, $(E_2, \mathcal{F}_2, \mu_2)$ espacios σ-finitos. Definimos $\mathcal{F}_1 \times \mathcal{F}_2$ como $\sigma(\pi_i \ : \ i \in \{1, 2\})$, donde

$$\pi_1 \colon E_1 \times E_2 \to E_1$$
$$\pi_1(x, y) = x,$$

$$\pi_2 \colon E_1 \times E_2 \to E_2$$
$$\pi_2(x, y) = y,$$

definimos $\mu_1 \times \mu_2$ como la única medida en $(E_1 \times E_2, \mathcal{F}_1 \times \mathcal{F}_2)$ tal que

$$\mu_1 \times \mu_2(A \times B) = \mu_1(A) \cdot \mu_2(B) \quad \forall A \in \mathcal{F}_1, \ B \in \mathcal{F}_2.$$

Teorema 1.34. $\mu_1 \times \mu_2$ existe y es única.

Observar. Los conjuntos de la forma $A \times B$ con $A \in \mathcal{F}_1$ y $B \in \mathcal{F}_2$ sse denomina rectángulo.

Nota. La demostración del teorema es una aplicación del teorema de Caratheodory, una vez que sabemos que $\mathcal{F}_1 \times \mathcal{F}_2 = \sigma(\text{rectángulos})$.

Ejemplo. $\mathscr{L}(\mathbb{R}^2) = \mathscr{L}(\mathbb{R}) \times \mathscr{L}(\mathbb{R})$. Por inducción, podemos extender la definición de producto a familias finitas de espacios de medida.

Definición 1.35 (Probabilidad Condicional)**.** Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Se define

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

siempre que $\mathbb{P}(B) > 0$. Si $\mathbb{P}(A) = \mathbb{P}(A|B)$, entonces $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$.

Definición 1.36 (Independencia)**.**

i) Decimos que 2 eventos son independientes si
$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

ii) Dadas 2 variables aleatorias X e Y, decimos que son independientes si $\forall B_1, B_2 \in \mathcal{B}(\mathbb{R})$,
$$\mathbb{P}(X \in B_1, Y \in B_2) = \mathbb{P}(X \in B_1) \cdot \mathbb{P}(Y \in B_2).$$

iii) Dadas 2 sub-σ-álgebras $\mathcal{F}_1$ y $\mathcal{F}_2$, decimos que son independientes si $\forall A \in \mathcal{F}_1$ y $B \in \mathcal{F}_2$, A y B son independientes de acuerdo a i).

Proposición 1.37. 1. A y B son independientes $\Leftrightarrow$ $\mathbb{1}_A$ y $\mathbb{1}_B$ son independientes.

2. X e Y son independientes $\Leftrightarrow$ $\sigma(X)$ y $\sigma(Y)$ son independientes.

3. $\mathcal{F}_1$ y $\mathcal{F}_2$ son independientes $\Leftrightarrow$ $\forall X \in \mathcal{F}_1,\ Y \in \mathcal{F}_2$ se tiene que X e Y son independientes.

Demostración. i) $\boxed{\Leftarrow}$ Basta tomar $B_1 = B_2 = \{1\}$ puesto que $\mathbb{1}_A^{-1}\{1\} = A,\ \mathbb{1}_B^{-1}\{1\} = B$ y por lo tanto $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$.

$\boxed{\Rightarrow}$ Se tiene que

$$\sigma(\mathbb{1}_A) = \{A, A^c, \varnothing, \Omega\} \quad \text{y} \quad \sigma(\mathbb{1}_B) = \{B, B^c, \varnothing, \Omega\}.$$

Por demostrar: $\mathbb{P}(\Omega \cap A) = \mathbb{P}(\Omega) \cdot \mathbb{P}(A)$.

En el caso con A y B^c, se tiene

$$\begin{aligned}
\mathbb{P}(A \cap B^c) &= \mathbb{P}(A \setminus A \cap B) \\
&= \mathbb{P}(A) - \mathbb{P}(A \cap B) \\
&= \mathbb{P}(A) - \mathbb{P}(A) \cdot \mathbb{P}(B) \\
&= \mathbb{P}(A) \cdot (1 - \mathbb{P}(B)) \\
&= \mathbb{P}(A) \cdot \mathbb{P}(B^c).
\end{aligned}$$

El caso con A^c y B, junto con el otro caso son iguales.

ii) $\boxed{\Leftarrow}$ (usar que $\sigma(f) = \{f^{-1}(B) \mid B \in \mathcal{B}(\mathbb{R})\}$).

iii) $\boxed{\Leftarrow}$ Sean $A \in \mathcal{F}_1, B \in \mathcal{F}_2$, entonces $\mathbb{1}_A \in \mathcal{F}_1, \mathbb{1}_B \in \mathcal{F}_2$.

$\square$

Definición 1.38. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

i) Dados $\mathcal{F}_1, \ldots, \mathcal{F}_n \subset \mathcal{F}$ sub-familias arbitrarias de eventos. Decimos que son independientes si $\forall J \subset \{1, \ldots, n\}$ y toda elección $A_j \in \mathcal{F}_j,\ j \in J$, se tiene que

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j).$$

ii) Dadas $X_1, \ldots, X_n$ variables aleatorias, decimos que son independientes si $\sigma(X_1, \ldots, \sigma(X_n)$ son independientes de acuerdo a i).

iii) Dados eventos $A_1, \ldots, A_n$, decimos que son independientes si $\mathbb{1}_{A_1}, \ldots, \mathbb{1}_{A_n}$ son independientes de acuerdo a ii).

Ejemplo. Sea X_1, X_2, X_3 variables aleatorias independientes con

$$\mathbb{P}(X_i = 1) = \frac{1}{2} = \mathbb{P}(X_i = 0) \quad \forall i \in \{1, 2, 3\}.$$

Definimos los siguientes eventos

$$A_1 = \{X_1 = X_3\}, \quad A_2 = \{X_1 = X_3\}, \quad A_3 = \{X_1 = X_2\}.$$

Notar que

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(\text{todas cara}) + \mathbb{P}(\text{todas sello}) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4},$$

con $\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_2 \cap A_3)$. Además,

$$\mathbb{P}(A_1) = \mathbb{P}(2 \text{ y } 3 \text{ con cara}) + \mathbb{P}(2 \text{ y } 3 \text{ con sello}) = \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2},$$

con $\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3)$. Pero

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1 \cap A_2) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2) \cdot \mathbb{P}(A_3).$$

Clase 5

16 de Marzo

Extendemos ahora la noción de independencia a familias arbitrarias.

Definición 1.39. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

- Dada una familia arbitraria $(\mathcal{F}_i)_{i \in I}$ de subclases de $\mathcal{F}$, diremos que son **independientes** si cualquier subfamilia finita lo es.
- Dada una familia arbitraria de variables aleatorias $(X_i)_{i \in I}$, diremos que son **independientes** si las σ-álgebras $(\sigma(X_i))_{i \in I}$ lo son (es decir, si cualquier subfamilia finita $X_{i_1}, \ldots, X_{i_n}$ es independiente).
- Dada una familia arbitraria de eventos $(A_i)_{i \in I} \subseteq \mathcal{F}$, diremos que son **independientes** si las variables aleatorias $(\mathbb{I}_{A_i})_{i \in I}$ lo son (es decir, si cualquier subfamilia finita $A_{i_1}, \ldots, A_{i_n}$ es independiente).

Tenemos el siguiente resultado:

Teorema 1.40. Si $(\mathcal{P}_i)_{i \in I}$ son π-sistemas independientes, entonces las σ-álgebras $(\sigma(\mathcal{P}_i))_{i \in I}$ también son independientes.

Demostración. Basta con demostrar que si $J = \{i_1, \ldots, i_n\} \subseteq I$ es finito, entonces las σ-álgebras $\sigma(\mathcal{P}_{i_1}), \ldots, \sigma(\mathcal{P}_{i_n})$ son independientes. Para ello, basta con probar la siguiente afirmación:

$Q_1, \ldots, Q_n$ π-sistemas independientes $\Rightarrow \sigma(Q_1), Q_2, \ldots, Q_n$ independientes $(*)$.

En efecto, como $\mathcal{P}_{i_1}, \ldots, \mathcal{P}_{i_n}$ son independientes por hipótesis (ya que son una subfamilia finita de $(\mathcal{P}_i)_{i \in I}$), tomando $\mathcal{Q}_1 := \mathcal{P}_{i_1}, \ldots, \mathcal{Q}_n := \mathcal{P}_{i_n}$, por $(*)$ concluimos que $\sigma(\mathcal{P}_{i_1}), \mathcal{P}_{i_2}, \ldots, \mathcal{P}_{i_n}$ son independientes. Tomando luego $\mathcal{Q}_1 := \mathcal{P}_{i_2}, \ldots, \mathcal{Q}_{n-1} := \mathcal{P}_{i_n}, \mathcal{Q}_n := \sigma(\mathcal{P}_{i_1})$, por $(*)$ de nuevo, $\sigma(\mathcal{P}_{i_2}), \mathcal{P}_{i_3}, \ldots, \mathcal{P}_{i_n}, \sigma(\mathcal{P}_{i_1})$ resultan independientes. Iterando este proceso, obtenemos finalmente que $(\sigma(\mathcal{P}_{i_j}))_{j=1,\ldots,n}$ son independientes.

Luego, mostremos $(*)$. Tenemos que ver que para toda elección de $1 \leq i_1 < i_2 < \cdots < i_k \leq n$ y toda elección de

$$A_i \in \begin{cases} \sigma(Q_1) & \text{si } i_1 = 1, \\ Q_{i_1} & \text{si } i_1 > 1, \end{cases}$$

$A_{i_j} \in Q_{i_j}$ si $j = 2, \ldots, n$, vale que

$$\mathbb{P}(A_{i_1} \cap A_{i_2} \cap \cdots \cap A_{i_k} = \mathbb{P}(A_{i_1}) \ldots \mathbb{P}(A_{i_k}).$$

Por un lado, si $i_1 > 1$, entonces $A_{i_j} \in Q_{i_j}$ para todo $j = 1, \ldots, k$, y la igualdad vale, pues $Q_{i_1}, \ldots, Q_{i_k}$ son independientes.

Por el otro, si $i_1 = 1$, tengo 2 casos:

a) $A_{i_1} \in Q_1$: en este caso, la igualdad vale por el mismo argumento que 1.

b) $A_{i_1} \in \sigma(Q_1)$: para ver que la igualdad vale en este caso, definimos $F \coloneqq \bigcap_{j=2}^{k} A_{i_j}$ y consideramos la clase

$$\mathscr{L}_1 \coloneqq \{B \in \sigma(Q_1) \ : \ \mathbb{P}(B \cap F) = \mathbb{P} \prod_{j=2}^{k} \mathbb{P}(A_{i_j})\}.$$

Observar que $Q_1 \subseteq \mathscr{L}_1$ por el caso a). Si mostramos además que $\mathscr{L}_1$ es un λ-sistema, entonces por el Teorema de Dynkin $\sigma(Q_1) \subseteq \mathscr{L}_1$ ($\sigma(Q_1) = \mathscr{L}_1$, de hecho) y luego vale la igualdad en el caso b).

Luego, para concluir la demostración sólo resta ver que $\mathscr{L}_1$ es un λ-sistema. Pero esto es una cuenta similar a la de la clase 3, así que omitimos los detalles.

$\square$

1.12.1 Aplicación

Si $X_1, \ldots, X_d$ son variables aleatorias definidas en un mismo EdP, definimos su *función de distribución acumulada conjunta* $F_{X_1 \cdots X_d} \colon \mathbb{R}^d \to [0, 1]$ por la fórmula

$$F_{X_1 \cdots X_d}(x_1, \ldots, x_d) \coloneqq \mathbb{P}(X_1 \leq x_1, \ldots, X_d \leq x_d).$$

Como consecuencia del Teorema anterior tenemos lo siguiente:

Teorema 1.41. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un EdP y $X_1, \ldots, X_d \colon \Omega \to \mathbb{R}$ variables aleatorias. Entonces, el vector $(X_1, \ldots, X_d) \colon \Omega \to \mathbb{R}^d$ es $\mathcal{F}$-medible (se dice un *vector aleatorio*) y las siguientes afirmaciones son equivalentes:

i) $X_1, \ldots, X_d$ son independientes;

ii) $F_{X_1 \cdots X_d} = \prod_{i=1}^d F_{X_i}$;

iii) $\mathbb{P}_{X_1 \cdots X_d} = \mathbb{P}_{X_1} \times \cdots \times \mathbb{P}_{X_d}$;

iv) Las proyecciones canónicas $\pi_i \colon \mathbb{R}^d \to \mathbb{R}$ $(i = 1, \ldots, d)$ son variables aleatorias independientes en $(\mathbb{R}^d, \beta(\mathbb{R}^d), \mathbb{P}_{X_1 \cdots X_d})$ cada π_i con distribución $\mathbb{P}_{X_i}$ respectivamente.

Demostración. Ver práctica 2. □

Nota. Si $X = (X_1, \ldots, X_d)$ es un vector aleatorio,

- $\mathbb{P}_X = \mathbb{P}_{X_1 \cdots X_d}$ se llama la *distribución conjunta* del vector X.
- Las distribuciones $\mathbb{P}_{X_j}$ $(i = 1, \ldots, d)$ se llaman *marginales* de X.

Notar que $\mathbb{P}_X$ determina las distribuciones marginales $\mathbb{P}_{X_i}$.

El Teorema dice que, en el caso independiente, vale la vuelta (en general no vale, $\mathbb{P}_X$ guarda más información que las $\mathbb{P}_{X_i}$).

El siguiente resultado nos será de utilidad:

Teorema 1.42. Sean X e Y variables aleatorias independientes. Entonces, si $h \colon \mathbb{R}^2 \to \mathbb{R}$ es medible Borel con $h \geq 0$ o $\mathbb{E}(|h(X,Y)|) < \infty$,

$$\mathbb{E}(h(X,Y)) = \int \int h(x,y) \; d\mathbb{P}_X(x) \; d\mathbb{P}_Y(y).$$

En particular, si $h(x,y) = f(x)g(y)$ con $f, g \colon \mathbb{R} \to \mathbb{R}$ medibles Borel tales que $f, g \geq 0$ o $\mathbb{E}(|f(X)|), \mathbb{E}(|g(Y)|) < \infty$, entonces

$$\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y)).$$

Demostración. Ver práctica 2. □

Observación. Notar que si $\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y)) \quad \forall f, g \colon \mathbb{R} \to \mathbb{R}_{\geq 0}$ medibles Borel, entonecs X e Y son independientes (o sea, ambas condiciones son equivalentes).

Corolario 1.43. Si X e Y son independientes, entonces, para todo $z \in \mathbb{R}$,

$$F_{X+Y}(z) := \int_{\mathbb{R}} F_X(z-y)\ d\mathbb{P}_Y(y) =: F_X * \mathbb{P}_Y(z).$$

En general,

$$\mathbb{P}_{X+Y}(B) = \int \mathbb{1}_B(x+y)\ d\mathbb{P}_X(x)\ d\mathbb{P}_Y(y) =: \mathbb{P}_X * \mathbb{P}_Y(B) \quad \forall B \in \beta(\mathbb{R}).$$

En particular, si X e Y son absolutamentes continuas, entonces $X+Y$ es absolutamente continua y $f_{X+Y} = f_X * f_Y$.

Demostración. Notar que

$$\begin{aligned}
\mathbb{P}_{X+Y}(B) = \mathbb{P}(X+Y \in B) &= \int \overbrace{\mathbb{1}_B(x+y)}^{h_B(x,y)}\ d\mathbb{P} \\
&= \int \mathbb{1}_B(x+y)\ d\mathbb{P}_{XY}(x,y) \\
(X, Y \text{ indep.}) &= \int\int \mathbb{1}_B(x+y)\ d\mathbb{P}_X(x)\ d\mathbb{P}_Y(y) \\
&= \mathbb{P}_X * \mathbb{P}_Y(B).
\end{aligned}$$

En particular, si $B = -\infty, z]$, obtenemos

$$\begin{aligned}
F_{X+Y}(z) = \mathbb{P}_{X+Y}(B) &= \int\int \mathbb{1}_{(-\infty, z-y]}(x)\ d\mathbb{P}_X(x)\ d\mathbb{P}_Y(y) \\
&= \int \mathbb{P}_X((-\infty, z-y])\ d\mathbb{P}_Y(y) \\
&= \int F_X(z-y)\ d\mathbb{P}_Y(y).
\end{aligned}$$

Además, si X e Y son absolutamente continuas,

$$\begin{aligned}
F_{X+Y}(z) &= \int\int \mathbb{1}_{(-\infty,z]}(x+y)\ d\mathbb{P}_X(x)\ d\mathbb{P}_Y(y) \\
&= \int\int \mathbb{1}_{(-\infty,z]}(x+y) f_X(x) f_Y(y)\ dx\ dy \\
(x' = x+y) &= \int\int \mathbb{1}_{(-\infty,z]}(x') f_X(x'-y) f_Y(y)\ dx'\ dy \\
&= \int \mathbb{1}_{(-\infty,z]}(x) \left(\int f_X(x'-y) f_Y(y)\ dy \right)\ dx' \\
&= \int_{-\infty}^{z} f_X * f_Y(x')\ dx.
\end{aligned}$$

□

Clase 6

18 de Marzo

1.13 Ley 0-1 de Kolmogorov

Dada una sucesión $(X_n)_{n\in\mathbb{N}}$ de variables aleatorias independientes, definimos la σ-álgebra **cola** asociada a $(X_n)_{n\in\mathbb{N}}$ como

$$\mathcal{C} = \bigcap_{n\in\mathbb{N}} \sigma(X_i : i \geq n).$$

Los eventos en $\mathcal{C}$ se llaman **eventos cola**.

La idea es que un evento cola queda determinado únicamente por el comportamiento de la cola de la sucesión $(X_n)_{n\in\mathbb{N}}$.

Ejemplo. Los siguientes son eventos cola:

i) $A = \{\lim_{n\to\infty} X_n = 5\}$.

ii) $B = \{(X_n)_{n\in\mathbb{N}} \text{ es de Cauchy}\}$.

iii) $C = \{(X_n)_{n\in\mathbb{N}} \text{ es acotada}\}$ (si cada X_n toma valores reales y no pueden valer $\pm\infty$).

Para eventos cola de $(X_n)_{n\in\mathbb{N}}$ independientes, tenemos:

Teorema 1.44 (Ley 0-1 de Kolmogorov)**.** Si $(X_n)_{n\in\mathbb{N}}$ son independientes y $A \in \mathcal{C}$ es un evento cola, entonces $\mathbb{P}(A) = 0$ ó $\mathbb{P}(A) = 1$.

Demostración. Sean $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$ y $\mathcal{G}_n = \sigma(X_{n+1}, X_{n+2}, \dots)$. Observar que si para $I \subseteq \mathbb{N}$ definimos

$$\mathcal{F}_I = \left\{ \bigcap_{j\in J} \{X_j \in B_j\} : B_j \in \mathcal{B}(\mathbb{R}),\ J \subseteq I \text{ finito} \right\},$$

entonces:

1. $\mathcal{F}_I$ es un π-sistema.
2. $\sigma(\mathcal{F}_I) = \sigma(X_i : i \in I)$.
3. si $I \cap I' = \emptyset$ entonces $\mathcal{F}_I$ y $\mathcal{F}_{I'}$ son independientes.
4. Se sigue del teorema visto la clase pasada que si $I \cap I' = \emptyset$ entonces $\sigma(\mathcal{F}_I)$ y $\sigma(\mathcal{F}_{I'})$ también lo son.
5. En particular, $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$ y $\mathcal{G}_n = \sigma(X_{n+1}, X_{n+2}, \dots)$ son independientes para todo n.
6. Luego, $\mathcal{F}_n$ es independiente de $\bigcup_{k\geq n} \mathcal{G}_k$.
7. Como $\bigcup_{k\geq n} \mathcal{G}_k$ es un π-sistema, por el mismo teorema, $\mathcal{F}_n$ es independiente de $\sigma\left(\bigcup_{k\geq n} \mathcal{G}_k\right) = \mathcal{C}$.

8. Por lo tanto, si $A \in \mathcal{C}$, entonces A es independiente de sí mismo, luego

$$\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A)\,\mathbb{P}(A) \quad \Longrightarrow \quad \mathbb{P}(A) \in \{0, 1\}.$$

□

1.14 Lemas de Borel-Cantelli

Definición 1.45. Dada una sucesión $(A_n)_{n\in\mathbb{N}} \subseteq \mathcal{F}$ de eventos, definimos el evento

$$\limsup_{n\to\infty} A_n := \{\text{ocurren infinitos } A_n\} = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k.$$

Notar que $\limsup A_n \in \mathcal{F}$. De hecho, se tiene que $\mathbf{1}_{\limsup A_n} = \limsup_{n\to\infty} \mathbf{1}_{A_n}$ (y por este motivo se llama lim sup de eventos).

Lema 1.46 (Borel-Cantelli)**.** Sea $(A_n)_{n\in\mathbb{N}}$ una sucesión de eventos. Entonces:

i) Si $\sum_{n\in\mathbb{N}} \mathbb{P}(A_n) < \infty$ entonces $\mathbb{P}(\text{ocurren infinitos } A_n) = 0$.

ii) Si $\sum_{n\in\mathbb{N}} \mathbb{P}(A_n) = \infty$ y $(A_n)_{n\in\mathbb{N}}$ son independientes, entonces $\mathbb{P}(\text{ocurren infinitos } A_n) = 1$.

1.15 Existencia de sucesiones independientes

¿Existe realmente una sucesión $(X_n)_{n\in\mathbb{N}}$ de variables aleatorias independientes? (o, equivalentemente, de eventos $(A_n)_{n\in\mathbb{N}}$ independientes?). Es decir, ¿existe un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ y una sucesión $(X_n)_{n\in\mathbb{N}}$ de variables aleatorias definidas sobre $(\Omega, \mathcal{F})$ tal que las $(X_n)_{n\in\mathbb{N}}$ sean independientes bajo $\mathbb{P}$?

Ejemplo. Basta considerar el caso en que las X_n son uniformes en $(0, 1)$; a partir de allí podemos cubrir cualquier otro caso.

- ¿Cómo construimos una variable $U \sim \text{Uniforme}(0, 1)$? Como $\mathbb{P} = \text{leb}_{[0,1]}$, construir U es equivalente a construir la medida de Lebesgue en $[0, 1]$.
- ¿Cómo conseguimos $U_1, \ldots, U_n$ independientes con distribución Uniforme$(0, 1)$? Por el teorema de construcción de medidas producto, $\mathbb{P}_{U_1,\ldots,U_n} = \mathbb{P}_{U_1} \times \cdots \times \mathbb{P}_{U_n} = \text{leb}_{[0,1]} \times \cdots \times \text{leb}_{[0,1]}$. Por lo tanto, construir $(U_1, \ldots, U_n)$ es equivalente a construir la medida de Lebesgue en el cubo unitario n-dimensional.
- Siguiendo esta lógica, construir $(U_n)_{n\in\mathbb{N}}$ independientes con $U_n \sim \text{Uniforme}(0, 1)$ es equivalente a construir la medida de Lebesgue en el cubo unitario infinito-dimensional $[0, 1]^{\mathbb{N}}$. Esto no es para nada trivial, pero puede hacerse. Lo haremos de dos formas:
    1. **Forma canónica**: construiremos $\text{leb}_{[0,1]^n}$ con el teorema de Carathéodory. (No ahora.)

2. **Forma constructiva**: construiremos $(U_n)_{n\in\mathbb{N}}$ en $([0,1], \mathcal{B}([0,1]), \mathrm{leb}_{[0,1]})$. Es la Práctica 2.

Chapter 2

Procesos Estocásticos (Notas de Anton Bovier)

Clase 7

23 de Marzo

Definición 2.1. Dados:

- Un EdP $(\Omega, \mathcal{F}, \mathbb{P})$;
- Un esp. medible (S, β) (típicamente, S métrico y separable y $\beta = \sigma$-álgebra de Borel);
- Un conjunto de índices I no vacío;

diremos que un *proceso estocástico con espacio de estados S indexado en I* es cualquier colección $(X_t)_{t \in I}$ de elementos aleatorios en (S, β), todos definidos en el mismo EdP $(\Omega, \mathcal{F}, \mathbb{P})$.

Nota.

- A veces se reserva el término "proceso estocástico" al caso en que $I = \mathbb{N},\ \mathbb{Z},\ \mathbb{R}_+$ ó $\mathbb{R}$. En estos casos, $t \in I$ es un *parámetro temporal* y hablamos de procesos a *tiempo discreto* o *continuo* dependiendo de si I lo es.
- Si $I = \mathbb{Z}^d,\ \mathbb{R}^d,\ G$ (grafo), hablamos de *campos estocásticos.*
- Para que $(X_t)_{t \in I}$ sea un PE, necesito que cada X_t sea $\mathcal{F}$-medible. En particular, $\sigma(X_t\ :\ t \in I) \subseteq \mathcal{F}$.

2.1 Perspectiva Trayectorial

En lugar de pensar que para cada $t \in I$ tenemos $X_t \colon \Omega \to \mathcal{S}$ tal que $\omega \mapsto X_t(\omega)$, podemos pensar que para cada $\omega \in \Omega$ tenemos $X(\omega) \colon I \to \mathcal{S}$ tal que $t \mapsto X_t(\omega)$. Llamamos a $X(\omega)$ una *trayectoria* o *realización* de $X = (X_t)_{t \in I}$.

Si ahora, variamos $\omega \in \Omega$, obtenemos una *trayectoria aleatoria*, i.e. podemos ver a $(X_t)_{t \in I}$ como un elemento aleatorio a valores en el espacio S^I de funciones. Es decir, $X \colon \Omega \to S^I$ tal que $\omega \mapsto X(\omega)$. Lo que nos gustaría es que X sea $\mathcal{F}$-medible. Para esto, necesitamos una σ-álgebra $\mathcal{G}$ en S^I.

Condición: Vamos a querer que $\mathcal{G}$ sea tal que si $X\colon \Omega \to S^I$ es $(\mathcal{F},\mathcal{G})$-medible $\Rightarrow X_t\colon \Omega \to S$ $(\mathcal{F},\beta)$-medible para todo $t \in I$.

Pero $X_t = \pi_t \circ X$, donde $\pi_t\colon S^I \to S$ tal que $(x_i)_{i\in I} \mapsto x_t$ es la *proyección* en t. Esto será cierto si $\mathcal{G}$ es tal que π_t es $(\mathcal{G},\beta)$-medible $\forall t \in I$.

Lema 2.2. Sea $\beta^I := \bigtimes_{i\in I} \beta$ (esto no es producto cartesiano, sino producto de σ-álgebras) la menor σ-álgebra en S^I que contiene a los conjuntos de la forma

$$C(t,B) := \{(x_i)_{i\in I} \in S^I \ : \ x_t \in B\} \quad (= \pi_t^{-1}(B))$$

con $t \in I,\ B \in \beta$. Entonces, β^I es la menor σ-álgebra en S^I que hace que π_t sea β-medible $\forall t \in I$.

A su vez, $\sigma(X_t \ : \ t \in I)$ es la menor σ-álgebra tal que $X\colon \Omega \to S^I$ resulta β^I-medible

Corolario 2.3. La aplicación $X\colon \Omega \to S^I$ es $(\mathcal{F},\beta^I)$-medible si y solo si $X_t\colon \Omega \to S$ es $(\mathcal{F},\beta)$-medible $\forall t \in I$. Es decir, β^I es **exactamente** la σ-álgebra $\mathcal{G}$ que necesitamos poner en S^I para que ambas "definiciones" de PE sean **equivalentes**.

Demostración (Corolario). $\boxed{\Rightarrow}$ $X_t = \pi_t \circ X$ es medible por ser composición de medibles (π_t es medible por el Lema).

$\boxed{\Leftarrow}$ X_t es $\mathcal{F}$-medible $\forall t \in I \Rightarrow \sigma(X_t \ : \ t \in I) \subseteq \mathcal{F} \Rightarrow X$ es $(\mathcal{F},\beta^I)$-medible (por el Lema). □

Demostración (Lema).

1. Observar que $C(t,B) = \pi_t^{-1}(B) \quad \forall t \in I,\ B \in \beta$. Luego,

$$\begin{aligned}\sigma(\pi_t \ : \ t \in I) &= \sigma(\pi_t^{-1}(B) \ : \ B \in \beta,\ t \in I)\\ &= \sigma(C(t,B) \ : \ B \in \beta,\ t \in I) = \beta^I\end{aligned}$$

   y esto implica la primera afirmación.

2. Sea $\mathcal{G} \subseteq \mathcal{F}$ una σ-álgebra.

$$\begin{aligned}X \text{ es } (\mathcal{G},\beta^I)\text{-medible } &\Leftrightarrow X^{-1}(C(t,B)) \in \mathcal{G} \quad \forall t \in I,\ B \in \beta\\ (C(t,B) = \pi_t^{-1}(B)) &\Leftrightarrow X^{-1}(\pi_t^{-1}(B)) \in \mathcal{G} \quad \forall t \in I,\ B \in \beta\\ &\Leftrightarrow (\pi_t \circ X)^{-1}(B) \in \mathcal{G} \quad \forall t \in I,\ B \in \beta\\ &\Leftrightarrow X_t \text{ es } (\mathcal{G},\beta)\text{-medible } \forall t \in I\\ &\Leftrightarrow \sigma(X_t \ : \ t \in I) \subseteq \mathcal{G}.\end{aligned}$$

   Luego, vale la segunda afirmación.

□

Nota. Llamaremos a β^I la σ-álgebra producto en S^I.

Definición 2.4. Si $J \subseteq I$ es finito y no vacío, dado $B \in \beta^J$ (σ-álgebra producto en S^J, decimos que el conjunto

$$C(J,B) := \{(x_i)_{i\in I} \in S^I \ : \ (x_j)_{j\in J} \in B\} \quad (\text{"} = B \times S^{I-J}\text{"})$$

es un *cilindro finito-dimensional* (de dimensión $n = |J|$).

Si B es de la forma $B = \bigtimes_{j\in J} B_j$ con $B_j \in \beta$, entonces $C(J,B) = \bigcap_{j\in J} C(j, B_j)$ se dice un *cilindro especial*.

Clase 8

25 de Marzo

Dados I conjunto de índices no vacío, (S^I, β^I) y (S, β) espacios medibles, sea $J \subseteq I$ finito y no vacío. Luego,

- Cilindro finito-dimensional:

$$C(J,B) = \{(x_i)_{i\in I} \in S^I \ : \ (x_j)_{j\in J} \in B\} \quad (B \in \beta).$$

- Cilindro especial:

$$C\Big(J, \bigtimes_{j\in J} B_j\Big) = \bigcap_{j\in J} C(j, B_j).$$

- $\beta^I = \sigma(C(i,B) \ : \ i \in I, B \in \beta)$.

Observación. 1. Los cilindros especiales forman un π-sistema (si I es finito, son la clase de rectángulos en $S^{|I|}$).

2. Los cilintros finito-dimensionales forman un álgebra.

3. Ambas clases generan a β^I.

Dado un PE $(X_t)_{t\in I}$, vimos que podemos verlo como elemento aleatorio X en (S^I, β^I). Luego, definimos la *distribución del proceso* como aquella medida de probabilidad $\mathbb{P}_X$ inducida por el elemento aleatorio X sobre (S^I, β^I).

Tener en cuenta que, dado un proceso estocástico con distribución μ sobre (S^I, β^I), siempre podemos construir una versión del proceso en el EdP (S^I, β^I, μ), tomando como X a la identidad; i.e. $X\colon S^I \to S^I$ tal que $x \mapsto X(x) = x$. Este X se conoce como la *versión canónica* del PE con distribución μ (o, simplemente, *proceso canónico*).

Observación. Si S es un espacio topológico y β es su σ-álgebra de Borel, también podemos considerar en S^I a $\beta(S^I)$, la σ-álgebra generada por los abiertos en S^I con la *topología producto*.

Pregunta. ¿Es cierto que $\beta(S^I) = \beta^I$?

Respuesta. En general, NO. Aunque siempre se tiene que $\beta^I \subseteq \beta(S^I)$. Si $\tau(S^I)$ admite una base numerable e I a lo sumo numerable, entonces SI (por ejemplo, $S^I = \mathbb{R}^{\mathbb{N}}$).

2.1.1 Construcción de medidas en S^I

Sea $I \neq \varnothing$ un conjunto de índices. Definimos

$$\mathbb{F}(I) := \{J \subseteq I \ : \ J \text{ finito y no vacío}\}.$$

Dados $J_1 \subseteq J_2 \subseteq I$, definimos la proyección $\pi_{J_2 \to J_1} \colon S^{J_2} \to S^{J_1}$ como

$$\pi_{J_2 \to J_1}((x_j)_{j \in J_2}) := (x_j)_{j \in J_1}.$$

En el caso en que $J_2 = I$, abreviamos $\pi_{J_1} := \pi_{I \to J_1}$.

Dada una medida μ sobre (S^I, β^I), definimos para $J \in \mathbb{F}(I)$ la medida μ_J sobre (S^J, β^J) por la fórmula

$$\mu_J(A) := \pi_J \mu(A) := \mu(\pi_J^{-1}(A)) = \mu(\underbrace{C(J, A)}_{\text{"}A \times S^{I-J}\text{"}}).$$

Llamaremos a la colección $\mathbb{F}(\mu) := \{\mu_J \colon J \in \mathbb{F}(I)\}$ la *colección de distribuciones finito-dimensionales de* μ.

Como ejemplo, notemos que si

$$\mu = \mathbb{P}_{(U_n)_{n \in \mathbb{N}}} = \prod_{n \in \mathbb{N}} \mathscr{L}|_{[0,1]}$$

entonces,

$$\mathbb{F}(\mu) = \{\mathscr{L}|_{[0,1]^{|J|}} \colon J \in \mathbb{F}(I)\}.$$

Teorema 2.5 (Extensión de Kolmogorov-Daniell)**.** Sea $I \neq \varnothing$ un conjunto de índices. Sea S un espacio métrico completo y separable con β su σ-álgebra de Borel. Supongamos que tenemos una familia $\mathscr{C} = \{\mu_J \colon J \in \mathbb{F}(I)\}$ tal que:

i) para cada $j \in J$, μ_J es una medida de probabilidad en (S^J, β^J);

ii) $\mathscr{C}$ es *consistente*; i.e. si $J_1, J_2 \in \mathbb{F}(I)$ son tal que $J_1 \subseteq J_2$, entonces $\pi_{J_2 \to J_1} \mu_{J_2} = \mu_{J_1}$ (i.e. $\mu_{J_2}(A \times S^{J_2 - J_1}) = \mu_{J_1}(A) \quad \forall A \in \beta^{J_1}$).

Entonces, existe una única medida μ sobre (S^I, β^I) tal que $\pi_J \mu = \mu_J \quad \forall J \in \mathbb{F}(I)$; i.e. $\mathscr{C} = \mathbb{F}(\mu)$.

Demostración (Idea)**.** Sea $\mathcal{A}$ el álgebra de cilindros finito-dimensionales de S^I. Definimos $\mu \colon \mathcal{A} \to [0,1]$ por $\mu(C(J,B)) := \mu_J(B)$. Usando la consistencia, se puede ver que μ está bien definida.

Luego, si demostramos que μ es σ-aditiva en $\mathcal{A}$, por Carathéodory se puede extender a todo $\sigma(\mathcal{A}) = \beta^I$. Esto prueba la existencia.

Por otro lado, como $\mathcal{A}$ es un π-sistema que genera β^I, $\mathbb{F}(\mu_1) = \mathbb{F}(\mu_2) \Rightarrow \mu_1, \mu_2$ coinciden en $\mathcal{A} \Rightarrow \mu_1 = \mu_2$ (esto último por Dynkin). $\square$

Corolario 2.6. Sea S espacio métrico completo y separable, con β su σ-álgebra de Borel. Supongamos que tenemos una familia $\mathscr{C} = \{P_n : n \in \mathbb{N}\}$ tal que

i) P_n es una medida en $(S^n, \beta^n := \beta \times \cdots \times \beta)$ para cada $n \in \mathbb{N}$;

ii) $\mathscr{C}$ es *consistente*; i.e. $\pi_{\{1,\ldots,n+1\} \to \{1,\ldots,n\}} P_{n+1} = P_n \quad \forall n \in \mathbb{N}$.

Entonces, existe una única medida $\mathbb{P}$ en $(S^{\mathbb{N}}, \beta^{\mathbb{N}})$ tal que $\pi_{\{1,\ldots,n\}}\mathbb{P} = P_n \quad \forall n \in \mathbb{N}$.

Clase 9

30 de Marzo

Teorema 2.7. Sea I un conjunto de índices no vacío y sean $(\mu_t)_{t \in I}$ un colección de probabilidades sobre (S, β) con S un espacio métrico completo y separable, y β su σ-álgebra de Borel. Entonces, existe una *única* medida de probabilidades μ en (S^I, β^I) tal que para todo $J \in \mathbb{F}(I)$ y $\bigtimes_{j \in J} B_j \in \beta^J$ vale que

$$\mu\left(C\left(J, \bigtimes_{j \in J} B_j\right)\right) = \prod_{j \in J} \mu_j(B_j).$$

En particular, en (S^I, β^I, μ), las proyecciones $(\pi_t)_{t \in I}$ son variables aleatorias independientes, cada π_t con distribución μ_t. Decimos que

$$\mu = \bigtimes_{t \in I} \mu_t = \prod_{t \in I} \mu_t$$

es la *medida producto* de $(\mu_t)_{t \in I}$.

Demostración. Dado $J \in \mathbb{F}(I)$, sea $\mu^{(J)} := \bigtimes_{j \in J} \mu_j$, la medida producto sobre (S^J, β^J). Sea $\mathscr{C} := \{\mu^{(J)} \ : \ J \in \mathbb{F}(I)\}$.

Notar que:

(i) $\mu^{(J)}$ es una medida de probabilidad en (S^I, β^I) para cada $J \in \mathbb{F}(I)$;

(ii) $\mathscr{C}$ es consistente: Si $J_1 \subseteq J_2,\ J_1, J_2 \in \mathbb{F}(I)$ y $(B_j)_{j\in J_1} \subseteq \beta$, entonces

$$\begin{aligned}
\left(\pi_{J_2\to J_1}\mu^{(J_2)}\right)\left(\bigtimes_{j\in J_1} B_j\right) &:= \mu^{(J_2)}\left(\pi^{-1}_{J_2\to J_1}\left(\bigtimes_{j\in J_1} B_j\right)\right) \\
&= \mu^{(J_2)}\left(\text{"}\left(\bigtimes_{j\in J_1} B_j\right)\times S^{J_2-J_1}\text{"}\right) \\
&= \left(\prod_{j\in J_1}\mu_j(B_j)\right)\left(\prod_{j\in J_2-J_1}\underbrace{\mu_j(S)}_{=1}\right) \\
&= \prod_{j\in J_1}\mu_j(B_j) \\
&= \mu^{(J_1)}\left(\bigtimes_{j\in J_1} B_j\right).
\end{aligned}$$

Como los conjuntos de la forma $\bigtimes_{j\in J_1} B_j$ generan β^{J_1} y son un π-sistema (que contiene a S^J), resulta que $\pi_{J_2\to J_1}\mu^{(J_2)} = \mu^{(J_1)}$ (i.e $\mathscr{C}$ es consistente).

Por el Teorema de extensión de Kolmogorov, existe una única medida μ sobre (S^I, β^I) tal que $\pi_J\mu = \mu^{(J)}$ para todo $J \in \mathbb{F}(I)$.

En particular,

$$\begin{aligned}
\mu\left(C\left(J, \bigtimes_{j\in J} B_j\right)\right) &= \pi_J\mu\left(\bigtimes_{j\in J} B_j\right) \\
&= \mu^{(J)}\left(\bigtimes_{j\in J} B_J\right) \\
&= \prod_{j\in J}\mu_j(B_j), \qquad (*)
\end{aligned}$$

para todo $J \in \mathbb{F}(I)$ y $(B_j)_{j\in J} \subseteq \beta$.

Por último, como los cilindros especiales del tipo $C(J, \bigtimes_{j\in J} B_j)$ son un π-sistema que genera β^I, μ es la única medida que cumple $(*)$.

La afirmación sobre las proyecciones $(\pi_t)_{t\in I}$ es un Ej. de la práctica 2. $\square$

Nota. Hasta acá la I1. Además, hasta acá con las notas de Anton Bovier (volver al Durrett).

Repasemos las formas de convergencia conocidas:

1. **Convergencia en probabilidad:** $X_n \xrightarrow{\mathbb{P}} X$ si para todo $\varepsilon > 0$ vale que
$$\lim_{n\to\infty}\mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

2. **Convergencia casi segura:** $X_n \xrightarrow[(a.s)]{c.s} X$ casi seguramente, i.e
$$\mathbb{P}(\{\omega\ :\ X_n(\omega) \not\longrightarrow X(\omega)\}) = 0.$$

3. **Convergencia en L^p:** $X_n \xrightarrow{L^p} X$ si

$$\|X_n - X\|_p := (\mathbb{E}(|X_n - X|^p))^{1/p} \xrightarrow{n\to\infty} 0, \quad (p \in [1, \infty)).$$

Similarmente, $X_n \xrightarrow{L^\infty} X$ si

$$\|X_n - X\|_\infty \longrightarrow 0.$$

Proposición 2.8. Valen las siguientes propiedades:

1. Se cumple

$$X_n \xrightarrow{c.s} X \Leftrightarrow \mathbb{P}(|X_n - X| > \varepsilon \text{ i.o}) = 0 \quad \forall \varepsilon > 0$$

($\Leftrightarrow \forall \varepsilon > 0,\ \lim_{n\to\infty} \mathbb{P}(\bigcup_{i\geq n}\{|X_i - X| > \varepsilon\}) = 0$). Donde i.o quiere decir "infinitely often" y

$$|X_n - X| > \varepsilon \text{ i.o} = \limsup_{n\to\infty}\{|X_n - X| > \varepsilon\}.$$

2. $\sum_{n\in\mathbb{N}} \mathbb{P}(|X_n - X| > \varepsilon) < \infty \quad \forall \varepsilon > 0 \Rightarrow X_n \xrightarrow{c.s} X$.

3. $X_n \xrightarrow{\mathbb{P}} X \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k\in\mathbb{N}}$ admite ella misma una subsucesión $(X_{n_{k_j}})_{j\in\mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow{c.s} X \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k\in\mathbb{N}}$ admite ella misma una subsucesión $(X_{n_{k_j}})_{j\in\mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow{\mathbb{P}} X$.

4. **Desigualdad de Tchebychev:** si f es creciente, entonces $f(\delta)\mathbb{P}(X \geq \delta) \leq \mathbb{E}(f(X)\mathbb{1}_{\{X\geq\delta\}})$. En particular, si $f(\delta) > 0$, entonces $\mathbb{P}(X \geq \delta) \leq \mathbb{E}(f(X)\mathbb{1}_{\{X\geq\delta\}})$.

5. **Desigualdad de Jensen:** Si φ es convexa y $\mathbb{E}(|X|), \mathbb{E}(|\varphi(X)|) < \infty$, entonces $\varphi(\mathbb{E}(X)) \leq \mathbb{E}(\varphi(X))$. En particular, si $p \leq q$, entonces $\|X\|_p \leq \|X\|_q$ ($L^q \subseteq L^p$).

En particular, se tiene que:

i) $X_n \xrightarrow{c.s} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{c.s} X$.

ii) $X_n \xrightarrow{L^p} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{L^p} X$.

iii) $X_n \xrightarrow{L^q} X \Rightarrow X_n \xrightarrow{L^p} X \quad \forall\ 1 \leq p \leq q$.

Definición 2.9. Dada una V.A y $p > 0$, a la cantidad $\mathbb{E}(X^p)$ (si está bien definida) se la llama el *p-ésimo momento de X*.

Observar. Si X tiene q-ésimo momento finito entonces también tiene p-ésimo momento finito para todo $1 \leq p \leq q$.

Definición 2.10. Dada una V.A X con $\mathbb{E}(X^2) < \infty$, definimos su *varianza* como $\mathrm{Var}(X) := \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \in [0, \infty)$.

Definición 2.11. Dadas V.A's X e Y definidas en el mismo EdP con $\mathbb{E}(X^2), \mathbb{E}(Y^2) < \infty$, definimos su *covarianza* como

$$\mathrm{Cov}(X, Y) := \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Nota. $\mathrm{Var}(X) = \mathrm{Cov}(X, X)$.

Definición 2.12. Una colección $(X_i)_{i \in I}$ de V.A's se dicen *no correlacionadas* si $\mathrm{Cov}(X_i, X_j) = 0 \quad \forall i \neq j,\ i, j \in I$.

Definición 2.13. Una colección $(X_i)_{i \in I}$ de V.A's se dicen *i.i.d* si son *independientes e idénticamente distribuidas*; i.e $X_i \overset{d}{=} X_j \quad \forall i, j \in I$.

Observar. $(X_i)_{i \in I}$ independientes $+ \ \mathbb{E}(X_j^2) < \infty \quad \forall i \in I \Rightarrow (X_i)_{i \in I}$ no correlacionadas (la otra dirección no vale).

Clase 10

1 de Abril

Chapter 3

Leyes de los grandes números

Definición 3.1. Diremos que una sucesión $(X_n)_{n\in\mathbb{N}}$ de VA's definidas en un mismo EdP satisface una *ley de los grandes números* si existen constantes $(a_n)_{n\in\mathbb{N}}, (b_n)_{n\in\mathbb{N}} \subseteq \mathbb{R}$ tales que

$$\frac{\left(\sum_{i=1}^n X_i - a_n\right)}{b_n} \xrightarrow{(*)} 0,$$

donde la convergencia en $(*)$ es en algún sentido apropiado.

Si la convergencia en $(*)$ es en probabilidad, decimos que la ley es *débil*.

Si la convergencia en $(*)$ es casi segura, decimos que la ley es *fuerte*.

Nota. Vamos a empezar a estudiar la validez de LGN's en distintos contextos. De ahora en más, $S_0 := 0,\ S_n := X_1 + \cdots + X_n$.

Teorema 3.2. Si $(X_n)_{n\in\mathbb{N}}$ son VA's *no correlacionadas* tal que

$$\begin{cases} \mathbb{E}(X_n) =: \mu \\ \mathrm{Var}(X_n) \leq X < \infty \quad \forall n \in \mathbb{N}, \end{cases}$$

entonces $\frac{S_n}{n} \xrightarrow[L^2]{\mathbb{P}} \mu$.

Demostración. Basta con ver la convergencia en L^2. En efecto, observemos que:

$$\begin{aligned} \mathbb{E}\Big(\frac{S_n}{n}\Big) &= \frac{1}{n}\mathbb{E}(S_n) \\ &= \frac{1}{n}\Big(\sum_{i=1}^n \mathbb{E}(X_i) \\ &= \frac{1}{n} n\mu = \mu. \end{aligned}$$

y

$$\begin{aligned}\left\|\frac{S_n}{n}-\mu\right\|_2^2 &= \mathbb{E}\Big(\Big(\frac{S_n}{n}-\mu\Big)^2\Big)\\ &= \operatorname{Var}\left(\frac{S_n}{n}\right)\\ &= \frac{1}{n^2}\operatorname{Var}(S_n)\\ &\leq \frac{1}{n^2}cn = \frac{c}{n} \longrightarrow 0.\end{aligned}$$

Luego,

$$\begin{aligned}\operatorname{Var}(S_n) = \operatorname{Cov}(S_n, S_n) &= \operatorname{Cov}\Big(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\Big)\\ &= \sum_{i,j=1}^n \operatorname{Cov}(X_i, X_j)\\ &= \sum_{i=1}^n \operatorname{Var}(X_i) \leq cn. \qquad \square\end{aligned}$$

Observación. 1. Si $(X_n)_{n\in\mathbb{N}}$ son N.C, entonces $\operatorname{Var}(X_1+\cdots+X_n) = \operatorname{Var}(X_1)+\cdots+\operatorname{Var}(X_n)$.

2. Que converga en L^2 implica convergencia en $\mathbb{P}$ se deduce de la siguiente desigualdad:

$$\mathbb{P}(|X-\mathbb{E}(X)|>\delta) \leq \frac{\mathbb{E}(|X-\mathbb{E}(X)|^2)}{\delta^2} = \frac{\operatorname{Var}(X)}{\delta^2}.$$

Nota. A la desigualdad

$$\mathbb{P}(|X-\mathbb{E}(X)|>\delta) \leq \frac{\operatorname{Var}(X)}{\delta^2}$$

se la llama Desigualdad de Tchebychev, y a la

$$\mathbb{P}(|X|>\delta) \leq \frac{\mathbb{E}(X)}{\delta}$$

se la llama desigualdad de Markov.

Nota. Las hipótesis sobre los momentos de $(X_n)_{n\in\mathbb{N}}$ se pueden relajar madiante *truncamientos* de las variables, i.e cambiar X_n por $\widetilde{X}_n = X_n \mathbb{1}_{|X_n|\leq b_n}$.

Teorema 3.3. Sean $(X_n)_{n\in\mathbb{N}}$ VA's i.i.d. Entonces, existe $(a_n)_{n\in\mathbb{N}} \subseteq \mathbb{R}$ tal que

$$\frac{S_n}{n} - a_n \xrightarrow{\mathbb{P}} 0$$

si y solo si

$$\lim_{x\to\infty} x\mathbb{P}(|X_1| > x) = 0.$$

Además, en tal caso se puede tomar

$$a_n := \mathbb{E}(X_n \mathbb{1}_{|X_n|\leq n}).$$

Demostración. Ver Durrett. □

Observación. Se cumple que $\mathbb{E}(|X|) < \infty \Rightarrow \lim_{x\to\infty} x\mathbb{P}(|X| > x) = 0$. Eso sí, el converso no vale. Además, esto último implica que $\mathbb{E}(|X|^{1-\varepsilon}) < \infty \quad \forall \varepsilon > 0$.

Para ver la primera implicancia, notar que (por Tchebychev)

$$x\mathbb{P}(|X| > x) \leq \mathbb{E}(|X|\mathbb{1}_{|X|>x}).$$

Para ver la última implicancia, recordar que

$$\mathbb{E}(|X|^p) = \int_0^\infty p|x|^{p-1}\mathbb{P}(X > x)\, dx.$$

Corolario 3.4 (LA Ley débil de los grandes números)**.** Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d con $\mathbb{E}(|X_n|) < \infty$ y $\mu := \mathbb{E}(X_n)$, entonces $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$.

Demostración. Por el Teorema anterior, $\frac{S_n}{n} - a_n \xrightarrow{\mathbb{P}} 0$. Luego, basta ver que $a_n \xrightarrow{n\to\infty} \mu$. Pero,

$$\begin{aligned} a_n := \mathbb{E}(X_n \mathbb{1}_{|X_n|\leq n}) &= \mathbb{E}(f_n(X_n)) \\ &= \mathbb{E}(f_n(X_1)) \\ &= \mathbb{E}(\underbrace{X_1 \mathbb{1}_{|X_1|\leq n}}_{|\cdot|\leq|X_1|}) \longrightarrow \mathbb{E}(X_1) = \mu, \end{aligned}$$

donde la convergencia está dada por Teorema de Convergencia Dominada. □

Teorema 3.5 (LA Ley fuerte de los grandes números)**.** Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d con primer momento finito y $\mu := \mathbb{E}(X_n)$, entonces

$$\frac{S_n}{n} \xrightarrow{c.s} \mu.$$

Observación. La hipótesis de independencia se puede rebajar al menos de 2 formas:

i) Basta que las $(X_n)_{n\in\mathbb{N}}$ sean independietes 2 a 2 (demostración de Etenadi, ver Durrett).

ii) Basta que las $(X_n)_{n\in\mathbb{N}}$ tengan una σ-álgebra cola trivial (todos los elementos tienen probabilidad 0 o 1) y que $(X_n)_{n\in\mathbb{N}}$ sea *estacionario*, i.e $(X_n)_{n\in\mathbb{N}} \overset{d}{=} (X_{n+k})_{n\in\mathbb{N}} \quad \forall k \in \mathbb{N}$.

A diferencia de la ley débil, para la ley fuerte es necesario el primer momento finito.

Teorema 3.6. Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d con $\mathbb{E}(|X_n|) = \infty$, entonces

$$\mathbb{P}\Big(\lim_{n\to\infty} \frac{S_n}{n} \in (-\infty, \infty)\Big) = 0.$$

Demostración. Ver Durrett (Teorema 2.3.8). □

Nota. No obstante, si $\mathbb{E}(|X_n|) = \infty$, pero X es $\mathbb{P}$-débil integrable, sigue valiendo la LFGN en el sentido esperable.

Teorema 3.7. Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d con $\mathbb{E}(X_n^+) = \infty$ y $\mathbb{E}(X_n^-) < \infty$, entonces

$$\frac{S_n}{n} \xrightarrow{c.s} \infty.$$

Lo análogo vale si $\mathbb{E}(X_n^-) = \infty$ y $\mathbb{E}(X_n^+) < \infty$.

Demostración. Ver Durrett (Teorema 2.4.5). □

Ejemplo. Se tira n veces una moneda equilibrada. Entonces,

$$\frac{\#\text{ veces que salió cara}}{n} \xrightarrow{c.s} \frac{1}{2}.$$

En efecto, si definimos

$$X_i := \begin{cases} 1 & \text{si la } i\text{-ésima moneda fue cara,} \\ 0 & \text{si no,} \end{cases}$$

entonces $X_1, \ldots, X_n$ son i.i.d con $\mathrm{Be}\left(\frac{1}{2}\right)$. Por la ley fuerte para las $(X_i)_{i\in\mathbb{N}}$,

$$\frac{\#\text{ caras}}{n} = \frac{X_1 + \cdots + X_n}{n} \xrightarrow{c.s} \mathbb{E}(X_1) = \frac{1}{2}.$$

Clase 11

6 de Abril

3.1 Convergencia en distribución.

Definición 3.8. Diremos que:

i) Una sucesión $(F_n)_{n\in\mathbb{N}}$ de funciones de distribución *converge débilmente* a una función de distribución F_∞, y lo denotamos por $F_n \Longrightarrow F_\infty$, si $\lim_{n\to\infty} F_n(x) = F_\infty(x)$ para todo x punto de continuidad de F_∞.

ii) Una sucesión $(X_n)_{n\in\mathbb{N}}$ de VA's *converge débilmente* o *converge en distribución* (o en ley) a una VA X_∞, y lo denotamos por $X_n \Longrightarrow X_\infty$ o $X_n \xrightarrow{d} X_\infty$, si $F_{X_n} \Longrightarrow F_{X_\infty}$.

Ejemplo.

- X_∞ VA;
- $X_n := X_\infty + \frac{1}{n}$;
- $F_{X_n}(x) = \mathbb{P}(X_n \leq x) = \mathbb{P}(X_\infty \leq x - \frac{1}{n}) = F_{X_\infty}(x - \frac{1}{n}) \xrightarrow{n\to\infty} F_{X_\infty}(x^-)$.

Luego, $F_{X_n}(x) \longrightarrow F_{X_\infty}(x)$ si y solo si x es punto de continuidad de F_{X_∞}. En particular, $X_n \xrightarrow{d} X_\infty$.

Ejemplo (Aproximación Poisson a la Binomial)**.** Si $X_n \sim \mathrm{Bi}(n, p_n)$ con $\lim_{n\to\infty} n \cdot p_n = \lambda > 0$ y $X_\infty \sim \mathcal{P}(\lambda)$, entonces $X_n \xrightarrow{d} X_\infty$ (es decir, $\mathrm{Bi}(n,p) \overset{d}{\approx} \mathcal{P}(\lambda)$ si $n \gg 1$ y $np \approx \lambda$).

Ejemplo. Si $X_n \sim \mathcal{G}(p_n)$ con $p_n \xrightarrow{n\to\infty} 0$ y $X_\infty \sim \varepsilon(1)$, entonces $p_n X_n \xrightarrow{d} X_\infty$.

Propiedad 3.9.

i) $X_n \xrightarrow{\mathbb{P}} X_\infty \Rightarrow X_n \xrightarrow{d} X_\infty$ (el converso no vale).

ii) $X_n \xrightarrow{d} c \in \mathbb{R} \Rightarrow X_n \xrightarrow{\mathbb{P}} x$. (ejemplo: $U \sim \mathcal{U}([0,1])$, $X_n \equiv U \quad \forall n \in \mathbb{N}$, $X_\infty := 1 - U$. Así, $X_n \xrightarrow{d} X_\infty$ pero $X_n \overset{\mathbb{P}}{\not\longrightarrow} X_\infty$ pues $U \neq 1 - U$).

iii) $X_n \xrightarrow{d} X_\infty$, $Y_n \xrightarrow{d} c \Rightarrow \begin{cases} X_n Y_n \xrightarrow{d} cX_\infty \\ X_n + Y_n \xrightarrow{d} X_\infty + c \end{cases}$ (Teoremas de Slutzky).

iv) $X_n \xrightarrow{X}_\infty \Leftrightarrow$ Toda subsucesión $(X_{n_k})_{k\in\mathbb{N}}$ tiene ella misma una subsucesión $(X_{n_{k_j}})_{j\in\mathbb{N}}$ tal que $X_{n_{k_j}} \xrightarrow[j\to\infty]{d} X_\infty$.

Teorema 3.10 (Representación de Skorokhod)**.** Si $X_n \xrightarrow{d} X_\infty$, entonces existe un EdP $(\Omega, \mathcal{F}, \mathbb{P})$ y VA's $(Y_n)_{n\in\mathbb{N}\cup\{\infty\}}$, todas definidas en dicho espacio, tales que:

i) $Y_n \overset{d}{=} X_n \quad \forall n \in \mathbb{N} \cup \{\infty\}$;

ii) $Y_n \xrightarrow{cs} Y_\infty$.

Decimos que $(Y_n)_{n\in\mathbb{N}\cup\{\infty\}}$ es un *acoplamiento* de las $(X_n)_{n\in\mathbb{N}\cup\{\infty\}}$

Demostración. Sea $(\Omega, \mathcal{F}, \mathbb{P}) := ([0,1], \beta([0,1]), \mathscr{L}|_{[0,1]})$. Definimos

$$Y_n(\omega) := F_{X_n}^{-1}(\omega) = \sup\{x \ : \ F_{X_n}(x) < \omega\}, \quad \omega \in [0,1].$$

Ya vimos que $F_{Y_n} = F_{X_n}$ antes. Luego, $X_n \overset{d}{=} Y_n \quad \forall n \in \mathbb{N} \cup \{\infty\}$. Para ver que $Y_n \xrightarrow{cs} Y_\infty$, bastará ver que $Y_n(\omega) \longrightarrow Y_\infty(\omega)$ para $\mathscr{L}$-casi todo $\omega \in (0,1)$.

Definimos para cada $y \in \mathbb{R}$,

$$a_y := \sup\{x \ : \ F_{X_\infty}(x) < y\}, \quad b_y := \inf\{x \ : \ F_{X_\infty}(x) > y\}.$$

Sea $\Omega_0 := \{y \in (0,1) \ : \ a_y = b_y\}$.

- Si $y \notin \Omega_0$ entonces $F_{X_\infty} \cong y$ en (a_y, b_y);
- Hay a lo sumo numerables $y \notin \Omega_0$ (los (a_y, b_y) son disjuntos y cada uno contiene al menos un racional [distintos entre sí {creo}]).

Entonces, $\mathscr{L}([0,1] \setminus \Omega_0) = 0$.

Luego, basta con ver que $Y_n(\omega) \longrightarrow Y_\infty(\omega)$ para todo $\omega \in \Omega_0$.

Primero, veamos que $\liminf_{n\to\infty} Y_n(\omega) \geq Y_\infty(\omega)$:

- Sean $(y_k)_{k\in\mathbb{N}}$ puntos de continuidad de F_{X_∞} tal que $y_k \nearrow Y_\infty(\omega)$.
- $y_k < Y_\infty(\omega) \Rightarrow F_{X_\infty}(y_k) < \omega \Rightarrow F_{X_n}(y_k) < \omega$ para todo $n \in \mathbb{N}$ grande (notar que la última implicancia está dada pues $F_{X_n}(y_k) \longrightarrow F_{X_\infty}(y_k)$ pues y_k punto de continuidad de F_{X_∞}.) $\Rightarrow y_k \leq Y_n(\omega) \quad \forall n$ grande $\Rightarrow y_k \leq \liminf_{n\to\infty} Y_n(\omega) \quad \forall k \in \mathbb{N} \Rightarrow Y_\infty(\omega) \leq \liminf_{n\to\infty} Y_n(\omega)$.

En segundo lugar, veamos que $\limsup_{n\to\infty} Y_n(\omega) \leq Y_\infty(\omega)$:

- Sean $(y_k)_{k\in\mathbb{N}}$ puntos de continuidad de F_{X_∞} tal que $y_k \searrow Y_\infty(\omega)$.
- $y_k > Y_\infty(\omega) = a_\omega \overset{\omega\in\Omega_0}{\Rightarrow} y_k > b_w \Rightarrow F_{X_\infty}(y_k) > \omega \Rightarrow F_{X_n}(y_k) > \omega \quad \forall n$ grande $\Rightarrow \limsup_{n\to\infty} Y_n(\omega) \leq Y_\infty(\omega)$.

$\square$

Corolario 3.11. $X_n \xrightarrow{d} x \Rightarrow X_n \xrightarrow{\mathbb{P}} c$.

Demostración. Debemos ver que, dado $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathbb{P}(|X_n - c| > \varepsilon) = 0.$$

Pero

$$\begin{aligned}\mathbb{P}(|X_n - c| > \varepsilon) &= \mathbb{P}(X_n \notin \overline{B(x,\varepsilon)}) \\ &= \mathbb{P}(Y_n \notin \overline{B(c,\varepsilon)}) \\ &= \mathbb{P}(|Y_n - c| > \varepsilon) \xrightarrow[n\to\infty]{} 0,\end{aligned}$$

pues $Y_n \xrightarrow{cs} c$ ($\Rightarrow Y_n \xrightarrow{\mathbb{P}} c$). □

Clase 12

8 de Abril

Corolario 3.12. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(X_\infty)) \quad \forall f\colon \mathbb{R} \to \mathbb{R}$ continua y acotada.

Demostración. $\boxed{\Rightarrow}$ Por Skorokhod, existen $(Y_n)_{n\in\mathbb{N}\cup\{\infty\}}$ tal que $Y_n \overset{d}{=} X_n \quad \forall n \in \mathbb{N}\cup\{\infty\}$ e $Y_n \xrightarrow{c.s} Y_\infty$. Luego:

- $Y_n \xrightarrow{c.s} Y_\infty \Rightarrow f(Y_n) \xrightarrow{c.s} f(Y_\infty) \Rightarrow \mathbb{E}(f(Y_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(Y_\infty))$. (donde la primera implicancia está dada por la continuidad de f y la segunda por T.C.D.)
- $Y_n \overset{d}{=} X_n \Rightarrow \mathbb{E}(f(Y_n)) = \mathbb{E}(f(X_n))$. En combinación con lo anterior, esto nos da ($\Rightarrow$).

$\boxed{\Leftarrow}$ Sea para cada $x \in \mathbb{R}$ y $\varepsilon > 0$, la función $g_{x,\varepsilon}$ de gráfico (foto). Notar que cada $g_{x,\varepsilon}$ es continua y acotada. Además, tenemos que $\mathbb{1}_{(-\infty,x]} \leq g_{x,\varepsilon} \leq \mathbb{1}_{(-\infty,x+\varepsilon]} \quad \forall x \in \mathbb{R}, \varepsilon > 0$. En particular,

$$\begin{aligned}\limsup_{n\to\infty} \mathbb{P}(X_n \leq x) &\leq \limsup_{n\to\infty} \mathbb{E}(g_{x,\varepsilon}(X_n)) \\ &= \mathbb{E}(g_{x,\varepsilon}(X_\infty)) \\ &\leq \mathbb{P}(X_\infty \leq x + \varepsilon) \\ &= F_{X_\infty}(x+\varepsilon).\end{aligned}$$

En conclusión, $\limsup_{n\to\infty} F_{X_n}(x) \leq F_{X_\infty}(x+\varepsilon) \quad \forall \varepsilon > 0$.

Tomando $\varepsilon \longrightarrow 0^+$, resulta $\limsup_{n\to\infty} F_{X_n}(x) \leq F_{X_\infty}(x)$. (pues F_{X_∞} es continua a derecha.)

Por otro lado,

$$\liminf_{n\to\infty} \mathbb{P}(X_n \leq x) \geq \liminf_{n\to\infty} \mathbb{E}(g_{x-\varepsilon,\varepsilon}(X_n)) = \mathbb{E}(g_{x-\varepsilon,\varepsilon}(X_\infty)).$$

Tomando, $\varepsilon \longrightarrow 0^1$, resulta $\liminf n \to \infty \mathbb{P}(X_n \leq x) \geq \mathbb{P}(X_\infty < x) = F_{X_\infty}(x^-)$. Pero, si x es punto de continuidad de F_{X_∞}, entonces $F_{X_\infty}(x^-) = F_{X_\infty}(x)$ y, por lo tanto, $\lim_{n\to\infty} \mathbb{P}(X_n \leq x) = \mathbb{P}(X_\infty \leq x)$, lo cual muestra que $X_n \xrightarrow{d} X_\infty$. $\square$

Observación. La demostración anterior muestra que $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \longrightarrow \mathbb{E}(f(X_\infty)) \quad \forall f \in \mathscr{C}$ donde $\mathscr{C}$ es cualquier clase de funciones continuas y acotadas con la siguiente propiedad:

(A) Dado $x \in \mathbb{R}$ y $\varepsilon > 0$, existe $f_{x,\varepsilon} \in \mathcal{C}$ tal que $\mathbb{1}_{(-\infty,x]} \leq f_{x,\varepsilon} \leq \mathbb{1}_{(-\infty,x+\varepsilon]}$.

Definición 3.13. Sea E un espacio métrico. Diremos que:

i) Una sucesión $(X_n)_{n\in\mathbb{N}}$ de elementos aleatorios a valores en E *converge débilmente o en distribución* a un elemento aleatorio X_∞, y lo notamos $X_n \Longrightarrow X_\infty$ ó $X_n \xrightarrow{d} X_\infty$, si $\mathbb{E}(f(X_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(X_\infty)) \quad \forall f\colon E \to \mathbb{R}$ continua y acotada.

ii) Una sucesión $(\mu_n)_{n\in\mathbb{N}}$ de medidas sobre el espacio $(E, \beta(E))$ *converge débilmente* a una medida μ_∞ y lo notamos $\mu_n \Longrightarrow \mu_\infty$ ó $\mu_n \xrightarrow{\omega} \mu_\infty$, si se cumple que

$$\lim_{n\to\infty} \int_E f \, d\mu_n = \int_E f \, d\mu_\infty \quad \forall f\colon E \to \mathbb{R} \text{ continua y acotada.}$$

Observación.

1. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{P}_{X_n} \xrightarrow{\omega} \mathbb{P}_{X_\infty}$.
2. Si R es un espacio métrico compacto y $\mathcal{C}(E) := \{f\colon E \to \mathbb{R} \mid f \text{ continua}\}$, entonces

$$(\mathcal{C}(E))^* := \{\varphi\colon \mathcal{C}(E) \to \mathbb{R} \mid \varphi \text{ lineal y continua}\} = \mathscr{M}(E),$$

donde

$$\mathscr{M}(E) := \{\mu \ : \ \mu \text{ medida con signo finito en } (E, \beta(E))\}.$$

Es decir,

i. Para todo $\varphi \in (\mathcal{C}(E))^*$ existe una única $\mu_\varphi \in \mathscr{M}(E)$ tal que $\varphi(f) = \int f \, d\mu_\varphi$ para toda $f \in \mathcal{C}(E)$. (por eso, a veces se nota $\int f \, d\mu =: \mu(f)$.) Además, $\|\varphi\| = \|\mu_\varphi\| \ (:= |\mu_\varphi|(E))$.

ii. Para toda $\mu \in \mathscr{M}(E)$, la aplicación $\varphi_\mu\colon \mathcal{C}(E) \to \mathbb{R}$ dada por $\varphi_\mu(f) := \int f \, d\mu$, cumple que $\varphi_\mu \in (\mathcal{C}(E))^*$ y $\|\varphi_\mu\| = \|\mu\|$.

En particular, si $(\mathbb{P}_n)_{n\in\mathbb{N}\cup\{\infty\}}$ son medidas de probabilidad en $(E, \beta(E))$, entonces

$$\begin{aligned} \mathbb{P}_n \xrightarrow{\omega} \mathbb{P}_\infty &\Leftrightarrow \int f \, d\mathbb{P}_n \longrightarrow \int f \, d\mathbb{P}_\infty \quad \forall f \in \mathcal{C}(E) \\ &\Leftrightarrow \varphi_{\mathbb{P}_n}(f) \longrightarrow \varphi_{\mathbb{P}_\infty}(f) \quad \forall f \in \mathcal{C}(E) \\ &\Leftrightarrow \varphi_{\mathbb{P}_n} \xrightarrow{\omega^*} \varphi_{\mathbb{P}_\infty}. \end{aligned}$$

Es decir, la convergencia es distribución (cuando E es compacto, es un caso particular de la convergencia débil-$*$ de Análisis Funcional.

Teorema 3.14 (de la aplicación medible)**.** Sean $h\colon \mathbb{R} \to \mathbb{R}$ medible Borel y $D_h := \{x \ : \ h \text{ es discontinua en } x\}$. Entonces, si $X_n \xrightarrow{d} X_\infty$ y $\mathbb{P}(X_\infty \in D_n) = 0$, vale que $h(X_n) \xrightarrow{d} h(X_\infty)$.

Si además h es acotada, entonces $\mathbb{E}(h(X_n)) \longrightarrow \mathbb{E}(h(X_\infty))$.

Demostración. Ejercicio de la práctica 5. □

Nota. $\mathrm{Var}(X) = 0 \Leftrightarrow X = \mathbb{E}(X)$ c.s.

Teorema 3.15 (Central del Límite)**.** Sea $(X_n)_{n\in\mathbb{N}}$ una sucesión de VA's i.i.d, con:

- $\mathbb{E}(X_n) =: \mu \in \mathbb{R}$;
- $\mathrm{Var}(X_n) =: \sigma^2 \in (0, \infty)$.

Entonces, en el límite cuando $n \to \infty$,

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0,1).$$

Observación.

1. En particular, el TCL dice que para todo $a < b$,

$$\lim_{n\to\infty} \mathbb{P}\left(a < \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b\right) = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\, dx.$$

2. Observar que $n\mu = \mathbb{E}(S_n)$ y $\mathrm{Var}(S_n) = n\sigma^2$, de modo que

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{S_n - \mathbb{E}(S_n)}{\sqrt{\mathrm{Var}(S_n)}}.$$

   (i.e, estamos centrando y normalizando para que tenga media 0 y varianza 1.)

3. El TCL nos dice "esencialmente" que, bajo las hipótesis del Teorema,

$$S_n \overset{d}{\approx} n\mu + \sigma\sqrt{n} \cdot N(0,1) \sim N(n\mu, \sigma^2 n)$$

   para n grande. Equivalentemente

$$\frac{S_n}{n} \overset{d}{\approx} \mu + \frac{\sigma}{\sqrt{n}} \cdot N(0,1).$$

   Por la LGN, ya sabíamos que $\frac{S_n}{n} \longrightarrow \mu$. El TCLL va más allá y nos dice cómo son las *fluctuaciones* de $\frac{S_n}{n}$ alrededor de su límite μ: de orden $\frac{1}{\sqrt{n}}$ y distribución asintóticamente normal.

Clase 13

13 de Abril

Nota. En el TCL, podemos reescribir:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \sqrt{n}\left(\frac{\frac{S_n}{n} - \mu}{\sigma}\right).$$

Además, notar que $\frac{S_n}{n} = \overline{X_n}$.

Nota.

- No basta con que las VA's sean independientes de a pares (Ver Durrett, Ejemplo 3.4.9);
- Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d con $\mathbb{E}(X_n) = 0$ y $\sigma^2 := \mathrm{Var}(X_n) \in (0,\infty)$, entonces $\frac{S_n}{\sqrt{n}} \xrightarrow{d} N(0,\sigma^2)$, pero:

  i) $\limsup_{n\to\infty} \frac{S_n}{\sqrt{n}} = \infty$ $\mathbb{P}$-c.s.

  ii) $(\frac{S_n}{\sqrt{n}})_{n\in\mathbb{N}}$ no converge en probabilidad.

  (i y ii parte del ejercicio 3.4.2 del Durrett.)
- Si $(X_n)_{n\in\mathbb{N}}$ i.i.d y $(S_n/\sqrt{n})_{n\in\mathbb{N}}$ converge en distribución, entonces $\mathbb{E}(X_n^2) < \infty$. (Ejercicio 3.4.3 Durrett.)

  En general, si $\mathbb{E}(X_n^2) = \infty$, entonces $S_n - n\mu \neq O(\sqrt{n})$ y, además, puede que la distribución asintótica tampoco sea normal.

3.1.1 Aplicaciones

1. **Aproximación normal a la Binomial.** Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d $\mathrm{Be}(p)$ con $p \in (0,1)$, entonces

$$\begin{aligned}\mathrm{Bi}(n,p) \sim X_1 + \cdots + X_n = S_n &\overset{d}{\approx} n\mu + \sigma\sqrt{n}N(0,1)\\ &= np + \sqrt{p(1-p)}\sqrt{n}N(0,1)\\ &\overset{d}{=} N(np, np(1-p))\end{aligned}$$

   $\Rightarrow \mathrm{Bi}(n,p) \overset{d}{\approx} N(np, np(1-p))$.

2. **Aproximación normal a la Poisson.** Si $(X_n)_{n\in\mathbb{N}}$ son i.i.d $\mathcal{P}(1)$, entonces $S_n = X_1 + \cdots + X_n \sim \mathcal{P}(n)$. Luego,

$$\begin{aligned}\mathcal{P}(n) \sim S_n &\overset{d}{\approx} n\mu + \sigma\sqrt{n}N(0,1)\\ &= n.1 + 1.\sqrt{n}N(0,1)\\ &\overset{d}{=} N(n,n).\end{aligned}$$

   En general, vale que $\mathcal{P}(\lambda) \overset{d}{\approx} N(\lambda,\lambda)$ cuando $\lambda \longrightarrow \infty$. (Ejercicio Práctica 5.)

Pregunta. ¿Cuál es la velocidad de convergencia?

Teorema 3.16 (Berry-Esseen)**.** Sean $(X_n)_{n\in\mathbb{N}}$ i.i.d con $\mathbb{E}(X_i) = 0$ y $\mathrm{Var}(X_n) =: \sigma^2 \in (0,\infty)$. Entonces, si $\rho := \mathbb{E}(|X_n|^3) < \infty$, entonces

$$\sup_{x\in\mathbb{R}} \left| F_{\frac{S_n}{\sigma\sqrt{n}}}(x) - F_{N(0,1)}(x) \right| \leq \frac{3.\rho}{\sigma^3} \cdot \frac{1}{\sqrt{n}}.$$

Además, puede verse que la tasa de convergencia no puede ser más rápida que $\frac{1}{\sqrt{n}}$.

Demostración. En el Durrett (de todas maneras, esto es más curiosidad que algo importante para el curso). □

Para demostrar el TCL, vamos a usar lo siguiente:

Proposición 3.17. $X_n \xrightarrow{d} X_\infty \Leftrightarrow \mathbb{E}(f(X_n)) \longrightarrow \mathbb{E}(f(X_\infty)) \quad \forall f \in C_b^\infty(\mathbb{R})$.

La Proposición es un corolario directo de lo que ya hemos visto y el siguiente lema:

Lema 3.18. Dado $x \in \mathbb{R}$ y $\varepsilon > 0$, existe $f_{x,\varepsilon} \in C_b^\infty(\mathbb{R})$ tal que $\mathbb{1}_{(-\infty,x]} \leq f_{x,\varepsilon} \leq \mathbb{1}_{(-\infty,x+\varepsilon]}$.

Demostración (Idea)**.** Sean

$$\varphi(t) := \begin{cases} e^{-1/t} & t > 0 \\ 0 & t \leq 0 \end{cases}$$

y $\rho(x) := k.\varphi(1-x^2)$, donde $k > 0$ es tal que $\int_{\mathbb{R}} \rho(x)\, dx = 1$. Observar que $\varphi \in C^\infty$ y, por lo tanto, $\rho \in C^\infty$ también. Además, $\rho \geq 0$ y $\rho(x) > 0$ si y solo si $|x| < 1$. En particular, $\rho \in C_b^\infty$.

Ahora, dado $\varepsilon > 0$, consideramos $\rho_\varepsilon(x) := \frac{1}{\varepsilon}\rho\left(\frac{x}{\varepsilon}\right)$. Observar que $\rho_\varepsilon \in C_b^\infty$, $\int_{\mathbb{R}} \rho_\varepsilon(x)\, dx = 1$, $\rho \geq 0$ y $\rho_\varepsilon(x) > 0$ si y solo si $|x| < \varepsilon$.

Con todo esto, definimos

$$f_{x,\varepsilon}(z) := \left(\mathbb{1}_{(-\infty,x+\frac{\varepsilon}{2}]} * \rho_{\frac{\varepsilon}{2}}\right)(z) = \int_{-\infty}^{x+\frac{\varepsilon}{2}} \rho_{\frac{\varepsilon}{2}}(z-y)\, dy.$$

Resulta que $f_{x,\varepsilon}$ cumple lo pedido. □

Demostración (TCL)**.** Sin pérdida de generalidad, podemos asumir $\mu = 0$ y $\sigma^2 = 1$. En caso contrario, consideramos $X_n' := \frac{X_n-\mu}{\sigma}$, que cumplen $\mathbb{E}(X_n') = 0$, $\mathrm{Var}(X_n') = 1$ y son i.i.d. Si probamos el TCL para las $(X_n')_{n\in\mathbb{N}}$, entonces $\frac{S_n'}{\sqrt{n}} \xrightarrow{d} N(0,1)$, pero $\frac{S_n'}{\sqrt{n}} = \frac{S_n-n\mu}{\sigma\sqrt{n}}$, de modo que también vale el TCL para las $(X_n)_{n\in\mathbb{N}}$.

Por otro lado, la validez del TCL para las $(X_n)_{n\in\mathbb{N}}$ es una propiedad que

depende sólo de su distribución $\mathbb{P}_{(X_n)_{n\in\mathbb{N}}}$. En particular, bastará con probar el TCL para alguna sucesión $(\tilde{X}_n)_{n\in\mathbb{N}}$ de VA's i.i.d con $\mathbb{P}_{(\tilde{X}_n)_{n\in\mathbb{N}}} = \mathbb{P}_{(X_n)_{n\in\mathbb{N}}}$ para que valga para $(X_n)_{n\in\mathbb{N}}$ también.

Teniendo esto en cuenta, si pérdida de generalidad, podemos asumir, que en el mismo EdP en donde están definidas las $(X_n)_{n\in\mathbb{N}}$, tenemos definida también una sucesión $(Y_n)_{n\in\mathbb{N}}$ de VA's i.i.d con distribución $N(0,1)$ independiente de $(X_n)_{n\in\mathbb{N}}$.

Con todo esto, definimos las variables

$$S_{n,i} := \frac{X_1 + \cdots + X_{i-1} + 0 + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 0, \ldots, n$$
$$Z_{n,i} := \frac{X_1 + \cdots + X_{i-1} + X_i + Y_{i+1} + \cdots Y_n}{\sqrt{n}} \quad i = 0, \ldots, n.$$

Observar que:

$$Z_{n,n} = \frac{S_n}{\sqrt{n}} \text{ y } Z_{n,0} = \frac{Y_1 + \cdots + Y_n}{\sqrt{n}} \sim N(0,1).$$

Por la proposición, basta con mostrar

$$\mathbb{E}(f(Z_{n,n})) - \mathbb{E}(f(\underbrace{Z_{n,0}}_{\sim N(0,1)})) \xrightarrow[n\to\infty]{} 0 \quad \forall f \in C_b^\infty.$$

□

Clase 14

15 de Abril

Demostración. $(X_n)_{n\in\mathbb{N}}$ i.i.d $\mathbb{E}(X_n) = 0$, $\mathrm{Var}(X_n) = 1$. $(Y_n)_{n\in\mathbb{N}}$ i.i.d $N(0,1)$, indep. de $(X_n)_{n\in\mathbb{N}}$.

$$S_{n,i} := \frac{X_1 + \cdots X_{i-1} + 0 + Y_{i+1} + \cdots Y_n}{\sqrt{n}} \quad i = 1, \ldots, n$$
$$Z_{n,i} := \frac{X_1 + \cdots + X_i + Y_{i+1} + \cdots + Y_n}{\sqrt{n}} \quad i = 0, \ldots, n$$
$$Z_{n,n} = \frac{X_1 + \cdots + X_n}{\sqrt{n}}$$
$$Z_{n,0} = \frac{Y_1 + \cdots + Y_n}{\sqrt{n}} \sim N(0,1).$$

Ahora, como X_i y $S_{n,i}$ son independientes,

- $\mathbb{E}\left(\frac{f'(S_{n,1}).X_i}{\sqrt{n}}\right) = \frac{1}{\sqrt{n}}\mathbb{E}(f'(S_{n,1})).\mathbb{E}(X_i) = 0$;
- $\mathbb{E}\left(\frac{f''(S_{n,i}).X_i^2}{2n}\right) = \frac{1}{2n}\mathbb{E}(f''(S_{n,i})).\mathbb{E}(X_i^2) = \frac{1}{2n}\mathbb{E}(f''(S_{n,i}))$;

de modo que lo anterior resulta

$$|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(S_{n,i})) - \frac{1}{2n}\mathbb{E}(f''(S_{n,i}))| \leq \frac{\varepsilon}{n}.$$

Como $Z_{n,i-1} - S_{n,i} = Y_i$, el mismo argumento empleado para $Z_{n,i}$ y $S_{n,i}$, obtenemos que, si n es suficientemente grande, para todo $i = 1, \ldots, n$,

$$|\mathbb{E}(f(Z_{n,i-1})) - \mathbb{E}(f(S_{n,i})) - \frac{1}{2n}\mathbb{E}(f''(S_{n,i}))| \leq \frac{\varepsilon}{n}.$$

Juntando ambas desigualdades,

$$|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(Z_{n,i-1}))| \leq \frac{2\varepsilon}{n} \quad \forall i = 1, \ldots, n.$$

Sumando en i, concluimos que

$$|\mathbb{E}(f(Z_{n,n})) - \mathbb{E}(f(Z_{n,0}))| \leq \sum_{i=1}^{n} \underbrace{|\mathbb{E}(f(Z_{n,i})) - \mathbb{E}(f(Z_{n,i-1}))|}_{\leq \frac{2\varepsilon}{n}} \leq 2\varepsilon$$

si n es suficientemente grande. $\square$

Chapter 4

Esperanza Condicional

Problema. Dado un vector (X, Y), buscar la mejor predicción del valor de X basada en le valor de Y.

Más precisamente, buscamos una VA Z tal que

1. $Z = g(Y)$, donde $g(y) =$ "mejor predicción del valor de X cuando $Y = y$" es medible Borel. Es decir, Z es $\sigma(Y)$-medible.
2. Z es la "mejor aproximación" de X dentro de las variables $\sigma(Y)$-medibles.

Trabajamos este problema primero en L^2.

- $L^2(\Omega, \mathcal{F}, \mathbb{P}) := \{Z \colon \Omega \to \overline{\mathbb{R}} \mid Z \text{ es } \mathcal{F}\text{-medible y } \mathbb{E}(Z^2) < \infty\}$,
- L^2 es un espacio de Hilbert con producto interno $\langle Z_1, Z_2 \rangle := \mathbb{E}(Z_1 Z_2)$.
- $\|Z\|_2 := \sqrt{\langle Z, Z \rangle}$, $d(Z_1, Z_2) = \|Z_1 - Z_2\|_2$.

Luego, si pensamos que $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, buscamos $Z \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ que sea $\sigma(Y)$-medible y tal que

$$d(X, Z) = \min\{d(X, W) \ : \ w \in L^2, \ \sigma(Y)\text{-medible}\}.$$

Defino $\mathcal{G} := \sigma(Y)$ y

$$L^2(\Omega, \mathcal{G}, \mathbb{P}) := \{W \in L^2(\Omega, \mathcal{F}, \mathbb{P}) \ : \ W \text{ es } \mathcal{G}\text{-medible}\}.$$

Notar que $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es un subespacio vectorial de $L^2(\Omega, \mathcal{F}, \mathbb{P})$. Luego, nuestra pregunta se reduce a encontrar la proyección ortogonal Z de X sobre $L^2(\Omega, \mathcal{F}, \mathbb{P})$.

Existirá tal proyección (y será única) si $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es un subespacio cerrado de $L^2(\Omega, \mathcal{F}, \mathbb{P})$ (y esto siempre vale pues $L^2(\Omega, \mathcal{G}, \mathbb{P})$ es completo). Luego, existe tal Z y es única.

Notemos que, en la definición de Z,

1) Z es $\mathcal{G}$-medible;

2) $d(X, Z) = \min\{d(X, W) \ : \ W \in L^2(\Omega, \mathcal{G}, \mathbb{P})\}$;

Podemos reemplazar 2) por:

2') $\langle X - Z, W \rangle = 0 \quad \forall W \in L^2(\Omega, \mathcal{G}, \mathbb{P})$ (ó $\langle X, W \rangle = \langle Z, W \rangle$).

O, equivalentemente, por:

2") $\langle X, \mathbb{1}_A \rangle = \langle Z, \mathbb{1}_A \rangle \quad \forall A \in \mathcal{G}$.

Notar que, (1) y (2") tienen sentido para una σ-álgebra $\mathcal{G} \subset \mathcal{F}$ cualquiera y X no necesariamente en L^2.

Definición 4.1. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un EdP, $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$ una σ-álgebra. Diremos que $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ es una *esperanza condicional de* X *dada* $\mathcal{G}$ y lo notamos $Y = \mathbb{E}(X|\mathcal{G})$, si satisface:

i) Y es $\mathcal{G}$-medible;

ii) $\int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P} \quad \forall A \in \mathcal{G}$.

Teorema 4.2. Sean $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y $\mathcal{G} \subset \mathcal{F}$ una σ-álgebra. Entonces,

1. **Existencia:** existe $Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ esperanza condicional de X dada $\mathcal{G}$;
2. **Unicidad:** si Y, Y' son esperanza condicional de X dada $\mathcal{G}$, $\mathbb{P}(Y = Y') = 1$.